小红书帖子热度研究报告

数据分析与预测模型实证研究

研究主题：小红书笔记热度影响因素分析与发布前预测

研究范围：数据清洗、探索性分析、分类模型、回归模型与可解释性分析

复现说明：数据、Notebook、机器可读实验输出与报告源码均按项目目录归档。

Contents

I Part I: 研究背景与文献综述

1 研究背景与文献综述 11

1.1 研究背景与意义 11

1.2 国内外研究现状 12

1.2.1 社交媒体内容传播与影响力研究综述 12

1.2.2 多模态社交媒体数据分析方法 12

1.3 内容热度预测与广告效果优化方法 13

II Part II: 小红书数据获取与数据处理

2 数据获取与来源 17

2.1 数据来源 17

2.1.1 主要数据源：小红书平台 17

2.1.2 数据领域划分方式 18

2.1.3 辅助数据源说明 20

2.2 数据采集方法 20

2.2.1 采集工具与框架 21

2.2.2 采集流程设计 23

2.2.3 反爬策略与伦理考量 23

2.3 数据描述与特征工程 24
2.3.1 时间特征构建 . . . 24
2.3.2 互动行为特征 . . . 24
2.3.3 发布地点特征 . . . 25
2.3.4 标签特征 . . . 25
2.4 数据预处理与清洗 25
2.4.1 异常与冗余数据清理 . . . 25
2.4.2 缺失值处理策略 . . . 25
2.4.3 特征编码与一致性控制 . . . 25

III Part III: 小红书笔记多维度数据分析与探索

3 笔记内容质量分析 . . . 29
3.1 文本内容深度与可读性分析 29
3.1.1 变量构建与样本处理 . . . 29
3.1.2 文本长度与互动关系 . . . 30
3.1.3 文本情感与互动关系 . . . 30
3.1.4 互动分布特征 . . . 30
3.1.5 非线性趋势识别 . . . 30
3.1.6 回归结果与稳健性检验 . . . 31
3.1.7 分组分析 . . . 31
3.1.8 情感分组结果 . . . 32
3.2 主题相关性与信息价值分析 32
3.2.1 变量构建与共线性修正 . . . 32
3.2.2 信息价值回归结果与检验 . . . 33
3.2.3 信息密度的“干货溢价”效应 . . . 33
3.2.4 标题匹配度的负向关联及可能解释 . . . 33
3.2.5 信息分布的可视化特征 . . . 34

4 笔记形式特征与多媒体数据边界 . . . 35
4.1 多媒体数据的可用性审计 35
4.2 当前可复现的文本形式特征 35

5 发布者基础影响力与用户数据边界 . . . 37
5.1 粉丝规模与互动的描述性关联 37
5.2 未纳入的用户历史、认证与社交网络变量 38

6 发布时机与上下文分析 39
6.1 星期分组的互动差异 39
6.2 节假日与调休日期的分组差异 40
6.3 发布地点的样本分布与互动差异 40

7 标签数量分析与话题数据边界 43
7.1 标签数量的描述性结果 43
7.2 标签类型与热点响应的识别边界 44

8 多维度相关性分析 45
8.1 特征间相关性分析 45
8.2 特征与目标变量相关性分析 46
8.3 非线性关系探索 48

9 特征选择与重要性评估 51
9.1 筛选原则与实际输入特征 51
9.2 已实施的模型重要性评估 51

IV Part IV: 基于机器学习的笔记热度分类预测模型

10 基准分类模型 55
10.1 预测问题描述 55
10.2 逻辑回归 55
10.3 线性支持向量机 56
10.4 集成学习模型 56
10.4.1 随机森林 56
10.4.2 梯度提升决策树 56
10.5 神经网络基准与后续候选 56
10.5.1 多层感知机 56
10.5.2 卷积神经网络 57
10.5.3 循环神经网络 57
10.6 实证设置与基准结果 57

11 针对小红书数据特点的模型改进 59
11.1 类别不平衡与代价敏感学习 59
11.2 阈值优化与概率校准 60

11.3 特征表达与多模态扩展 60
11.4 社交传播与时间外验证 60

12 模型评估、比较与结论 61
12.1 评估口径 61
12.2 混淆矩阵与错误结构 61
12.3 综合比较与模型选择 62
12.4 稳健性、局限与本部分结论 62

V PartV: 小红书帖子热度预测模型

13 候选模型与基准选择 65
13.1 预测问题描述 65
13.2 线性回归模型 65
13.2.1 经典线性模型 66
13.2.2 正则化线性模型 66
13.3 候选方法：支持向量回归（SVR） 66
13.4 本轮采用的树集成模型 67
13.5 后续候选：深度学习与多模态模型 67
13.5.1 时序深度学习模型：LSTM/GRU 67
13.5.2 文本深度学习模型：BERT + TextCNN 68
13.6 其他未验证候选方法 68
13.6.1 宽度学习系统（Broad Learning System, BLS） 68
13.6.2 生存分析模型（Survival Analysis） 68

14 扩展模型的数据前提与验证方案 69
14.1 模型架构设计 69

15 热度回归模型实证 71
15.1 任务定义与数据处理 71
15.2 模型与评估指标 71
15.3 基准结果与模型比较 72
15.4 可解释性、局限与应用建议 72

VI Part VI: 统一实验总结

16 统一实验设置 77
16.1 数据口径与任务划分 77
16.2 评价原则与复现材料 77

17 分类与回归结果的统一比较 79
17.1 分类任务：排序、覆盖与误报的权衡 79
17.2 回归任务：相对排序优于绝对量预测 79
17.3 跨任务一致的特征信号 80

18 有效性边界与后续验证 81
18.1 本轮实际完成范围 81
18.2 时间外与博主分组验证 81
18.3 内部与外部有效性限制 82
18.4 下一轮验证顺序 82

VII Part VII: 结论与展望

19 研究结论 85
19.1 主要发现 85
19.2 实践含义 85

20 研究局限与未来工作 87
20.1 研究局限 87
20.2 未来工作 87
20.3 总结 88

Part I: 研究背景与文献综述

1 研究背景与文献综述 11
1.1 研究背景与意义
1.2 国内外研究现状
1.3 内容热度预测与广告效果优化方法



1. 研究背景与文献综述

1.1 研究背景与意义

随着移动互联网的普及和社交媒体平台的发展，内容创作与分享已成为信息传播和消费决策的重要环节。小红书（RED）已由早期的海外购物攻略平台演变为覆盖图文、短视频和直播等形式的生活方式内容社区。小红书开放平台公开的运营口径显示，平台月活跃用户约为 3 亿，用户生成内容（UGC）约占平台内容的 90% [1]。在此背景下，品牌方、商家及个人创作者如何在海量信息中提高内容的可见度与互动表现，已成为兼具研究价值和实践意义的问题。

然而，社交媒体平台的内容分发机制复杂且通常不完全公开。既有研究显示，内容的情绪与实用价值、媒体和表达形式、发布时间、发布者影响力以及社交网络结构都可能与传播和互动表现相关 [2–5]。因此，即使内容经过精心策划，其实际传播仍可能受到平台环境和受众反馈的共同影响。这种不确定性增加了内容创作者与营销者的试错成本，也使广告投放效果与投资回报率（ROI）难以稳定评估。

本研究基于公开可获得的小红书笔记数据，量化分析文本、发布时间、地区、话题标签和发布者规模等特征与笔记热度之间的关系，并构建发布前的分类与回归基准模型。研究目标是识别具有稳定预测价值的特征，为内容策划和发布规划提供可检验的数据依据。需要强调的是，观测数据中的统计关联不等同于因果效应；本研究的模型首先服务于描述与预测，策略效果仍需通过受控实验或更严格的因果识别设计加以验证。

1.2 国内外研究现状

1.2.1 社交媒体内容传播与影响力研究综述

社交媒体内容传播与影响力研究横跨传播学、市场营销学和数据科学，其核心问题是哪些因素与转发、点赞、评论等用户参与（Engagement）相关。根据研究视角，现有工作大致可分为三类。第一类关注文本情绪、主题、语言风格和信息实用性等内容特征。Berger 与 Milkman 基于在线新闻数据发现，情绪唤醒程度和实用价值与内容分享存在系统性关系 [2]。第二类关注媒体形式与视觉内容；品牌主页研究表明，媒体类型、内容类型及发布时间与点赞、评论和分享表现相关 [3,4]，大规模图像研究则显示，视觉内容线索与发布者的社会情境共同影响图片流行度的预测 [6]。第三类关注发布者影响力与网络扩散结构；对 Twitter 大规模扩散事件的研究表明，个体影响力存在显著异质性，同时仅凭静态用户属性并不容易准确识别未来的高影响力传播者 [5]。

随着数据获取与分析技术的进步，问卷调查和案例分析逐渐与大规模数据挖掘、自然语言处理（NLP）和计算机视觉（CV）结合。研究者可分别从文本和图像中提取情感、主题、对象与场景等特征，再与用户和时间等上下文信息联合建模；多模态机器学习中的表示、对齐与融合框架为这一过程提供了系统方法 [7]。与此同时，回归和分类模型被用于预测内容热度，因果推断方法则用于回答特定内容干预是否产生效果。两类任务的目标与识别假设不同，不应仅依据预测相关性作因果解释。

1.2.2 多模态社交媒体数据分析方法

传统统计与计量方法

在社交媒体数据分析的早期阶段，传统统计与计量经济学方法扮演了基础角色。这些方法主要用于检验特定因素与内容表现（如点赞数、转发数）之间是否存在显著的相关关系。多元线性回归（Multiple Linear Regression）是最常用的模型之一，它将内容热度（因变量）表示为一系列可量化特征（自变量，如文本长度、图片数量、发布小时等）的线性组合，通过估计系数来评估各因素的贡献度。为了处理计数数据（如点赞数）的离散性和过度分散问题，泊松回归（Poisson Regression）或负二项回归（Negative Binomial Regression）也常被采用。

然而，社交媒体数据通常具有复杂的特征：因变量（如热度指标）分布高度偏斜（存在大量零值和少数极端的“爆款”）；自变量之间可能存在多重共线性（例如，高质量内容可能同时具备优质图文和合适的发布时间）；并且存在大量的潜在混淆变量。为了解决这些问题，研究者引入了更复杂的模型。例如，分位数回归（Quantile Regression）可用于研究不同热度水平下（如普通笔记 vs. 爆款笔记）影响因素的不同作用；而面板数据模型（Panel Data Model）则能利用同一创作者或同一主题的多次发布数据，控制个体或主题的固定效应，从而更准确地识别特定因素的作用。尽管这些方法在控制变量和估计参数方面非常严谨，但它们通常假设变量间的关系是线性的或可预定义形式的，对于捕捉文本、图像等高维复杂特征内部的非线性模式和交互作用能力有限。

机器学习与深度学习方法

机器学习和深度学习技术的发展，为分析和预测社交媒体内容热度提供了更强大、更灵活的工具。这些方法能够自动从原始数据（如原始文本、图像像素）中学习有效的特征表示，并建模复杂的非线性关系。

在特征工程方面，自然语言处理技术如词袋模型（Bag-of-Words）、TF-IDF 以及词嵌入（Word Embedding，如 Word2Vec, GloVe）可以将非结构化的文本转化为结构化特征，用于后续的回归或分类任务。对于图像，除了手动提取的颜色、纹理、物体检测等特征外，卷积神经网络（CNN）预训练模型（如 ResNet, VGG）可以提取深层、抽象的视觉特征向量。

在预测建模方面，随机森林和梯度提升树等集成学习方法能够处理非线性关系和特征交互，常被用于回归或分类基准。随机森林通过随机化的树集成降低单棵树的方差 [8]；XGBoost 则在梯度提升框架中进一步引入稀疏感知和可扩展训练机制 [9]。特征重要性可以辅助解释模型，但其数值表示的是预测贡献而非因果贡献。

更进一步，深度学习模型可以端到端地处理文本、图像和关系网络。例如，LSTM 能够表示序列中的长期依赖 [10]，ResNet 等卷积网络可用于提取图像表示 [11]，二者可在多模态融合框架下共同用于互动量预测 [7]。图神经网络（GNN）则适合表示用户--内容交互或话题传播网络中的非欧氏关系 [12]。不过，这些模型通常需要更完整的图像、用户历史或网络关系数据；在仅有结构化发布字段时，树模型和线性模型仍是更透明且可复现的基准。

1.3 内容热度预测与广告效果优化方法

传统预测与优化模型

在内容热度预测中，统计回归可用于单篇内容的横截面预测，时间序列模型则更适合描述账号或话题热度随时间的总体变化。早期研究显示，内容发布后的初期访问或投票轨迹可用于预测其长期流行度 [13]；如果目标是严格的发布前预测，则必须排除这些发布后信号，只使用创作时即可获得的特征。在广告效果优化方面，在线受控实验或 A/B 测试通过随机分配版本来估计改动对点击率、转化率等指标的因果影响，是互联网产品评估的重要方法 [14]。其局限包括对流量、实验周期、干扰控制以及多重检验管理的要求。

响应面方法（Response Surface Methodology, RSM）等实验设计方法可以用于探索多个因素（如标题长度、图片风格、发布时间）及其交互作用对结果指标的最优组合。但这类方法通常假设响应面是连续的且可用低阶多项式近似，在面对社交媒体内容这种离散、高维且存在大量噪声的优化问题时，其应用受到一定限制。

机器学习驱动的内容策略优化

机器学习方法为实现智能化、自动化的内容策略优化提供了新的路径。一方面，预测模型本身可以作为优化工具：通过构建一个能够相对准确预测内容热度的模型（即“代理模型”或“元模型”），创作者或营销者可以在内容发布前，模拟调整不同的内容属性（如尝试不同的标题关键词、选择不同的发布时间段），利用模型预测哪种组合可能获得更好的效果，从而指导决策。这本质上是一种基于模型的“假设分析”（What-if Analysis）。

另一方面，强化学习及其简化形式---上下文多臂老虎机---为动态环境中的探索与利用提供了框架。相关研究已将用户与文章特征作为上下文，根据点击反馈持续更新新闻推荐策略 [15]。此外，因果森林可用于估计不同内容干预在用户或内容子群体中的异质性处理效应 [16]。但此类方法依赖随机试验或可辩护的可忽略性等识别条件；仅凭普通观测数据，不能自动消除未观测混淆。

综上，本研究将多模态分析和动态优化视为后续扩展方向，当前工作则聚焦于公开结构化字段下可复现的热度描述与基准预测。该定位能够把“哪些特征有预测价值”与“改变某项策略是否会造成效果提升”区分开来，并为后续受控实验和因果分析奠定基础。

Part II: 小红书数据获取与数据处理

2 数据获取与来源 17

2.1 数据来源

2.2 数据采集方法

2.3 数据描述与特征工程

2.4 数据预处理与清洗



2. 数据获取与来源

2.1 数据来源

小红书内容传播效果的研究高度依赖于高质量、大规模的真实用户笔记数据。为系统分析影响笔记互动表现（如点赞、评论、收藏等）的关键因素，本研究以小红书平台公开发布的用户笔记为主要研究对象，通过自动化数据采集方式构建研究所需的数据集。在数据采集过程中，严格遵循相关法律法规及平台使用规范，仅采集用户公开可见的信息，并对涉及用户身份的数据进行脱敏处理，确保数据仅用于学术研究目的。

2.1.1 主要数据源：小红书平台

本研究的主要数据来源为小红书平台的公开笔记信息，数据采集覆盖家电与美妆两个典型内容垂直领域。通过对不同领域笔记内容及互动数据的对比分析，探究内容形式、文本特征及用户影响力等因素对笔记传播效果的影响。

当前仓库保存了家电、美妆两个领域的三个业务数据压缩包。统一建模流水线从其中的明细表共读取 323,598 行原始记录；按照笔记链接去重（链接缺失时使用编号、标题与博主名称组合），并剔除互动指标缺失或为负的记录后，得到 199,473 条可用笔记。可解析的发布日期覆盖 2023 年至 2024 年 10 月。不同章节还会因所需字段完整性采用更严格的筛选，因此其分析样本量可能小于统一建模样本，相关数字均在对应章节单独说明。

采集的核心数据字段主要包括以下几类：

- 笔记元数据：包括笔记唯一标识（ID）、笔记标题、正文内容、话题标签（关键词）、笔记发布时间及发布地点。
- 互动数据：包括笔记的点赞数、评论数和收藏数，用于衡量笔记的传播效果与用户参与度。
- 内容形式线索：部分原始表可能包含媒体链接或类型文本，但当前归档没有与每条

笔记稳定配对的图片文件、视频文件及完整媒体元数据，因此这些字段不进入本轮可复现实证模型。

- 用户信息：包括博主名称及其粉丝数量，用于刻画发布者影响力水平，并作为后续分析中的控制变量。

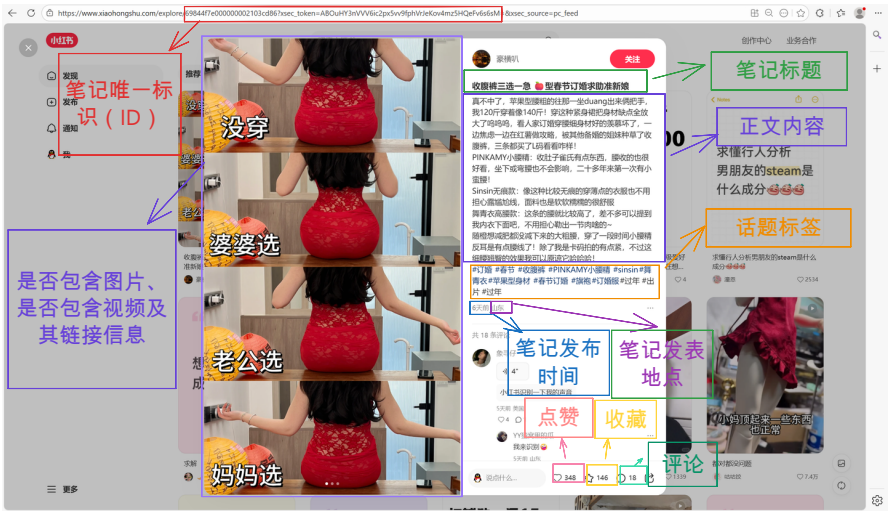


图 2.1: 小红书笔记页面与采集字段示意

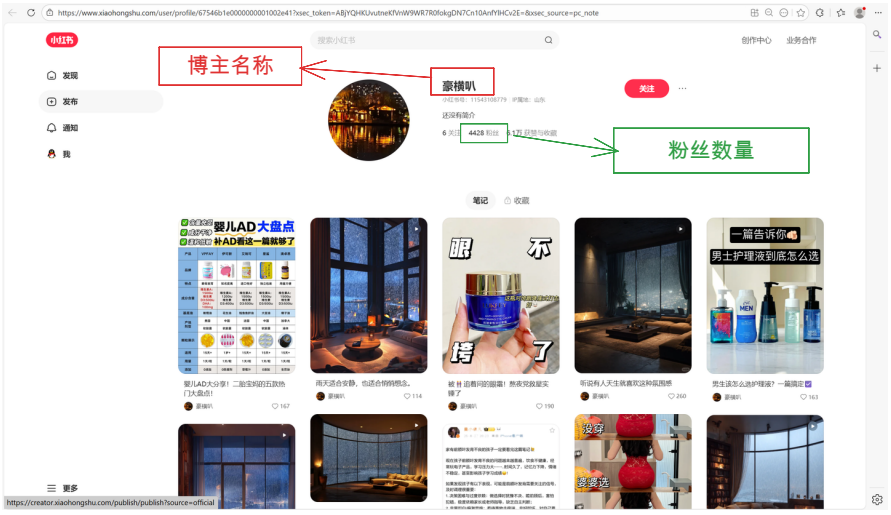


图 2.2: 用户页面采集字段示意

2.1.2 数据领域划分方式

为保证不同内容领域样本的准确性与可区分性，本研究在数据采集阶段即对内容领域进行前置区分，采用不同访问入口 URL 分别获取家电与美妆领域的笔记数据。

其中，家电领域的数据通过平台搜索入口进行采集，基于以“家电”为核心关键词构建的搜索结果页面获取笔记列表；美妆领域的数据则通过平台官方内容频道入口进行采集，

直接访问美妆频道对应的内容流页面获取笔记列表。由于不同入口页面在平台内容组织逻辑上已完成领域划分，因此能够在源头上减少跨领域内容混入的情况。

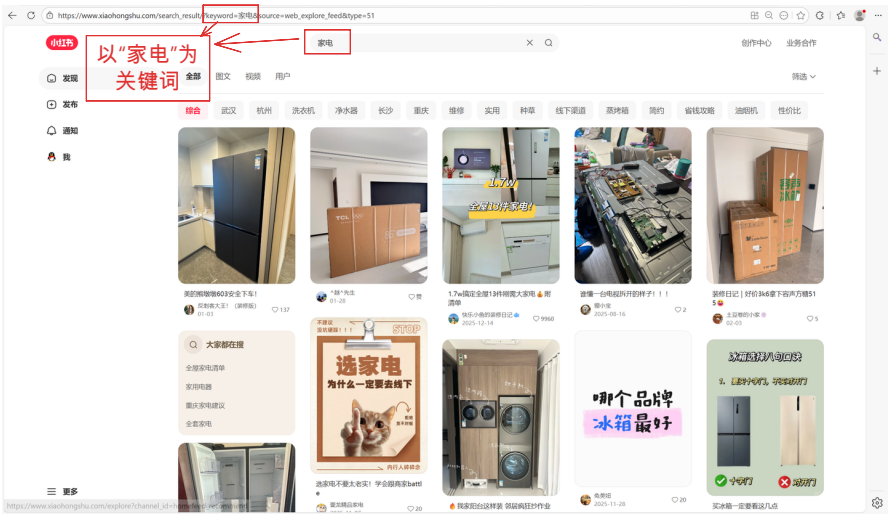


图 2.3: 以“家电”为核心关键词构建的搜索结果页面

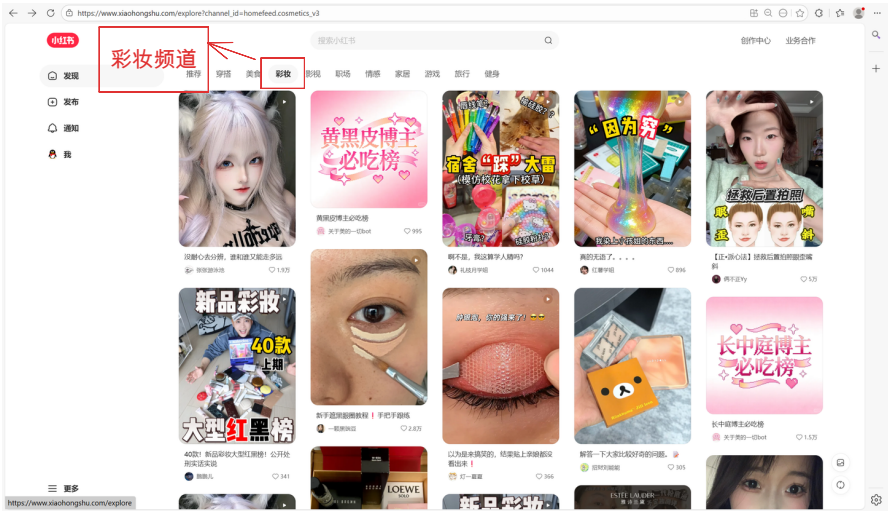


图 2.4: 美妆频道对应的内容流页面

在具体采集过程中，分别从上述不同入口页面解析并提取笔记唯一标识（ID），再基于笔记 ID 进一步访问笔记详情页获取完整内容信息。通过这种“入口区分—ID 提取—详情采集”的两阶段方式，实现了家电与美妆两个内容领域样本的独立采集与明确区分。

不同领域入口 URL 设置示例:

```
# 本代码仅为过程抽象示例，非实际运行代码。

# 不同领域入口URL设置
```

```
ENTRY_URLS = {
    "家电": (
        "https://www.xiaohongshu.com/search_result/?"
        "keyword=家电&source=web_explore_feed&type=51"
    ),
    "美妆": (
        "https://www.xiaohongshu.com/explore?"
        "channel_id=homefeed.cosmetics_v3"
    )
}
def collect_ids_by_field(field_name):
    """
    根据领域名称选择不同入口URL
    """
    url = ENTRY_URLS[field_name]
    print(f"当前采集领域: {field_name}")
    print(f"使用入口: {url}")

    response = session.get(url, headers=get_headers(), cookies=cookies)
    soup = BeautifulSoup(response.text, "html.parser")

    # 后续统一执行ID提取逻辑
    # ...

# 调用示例
collect_ids_by_field("家电")
collect_ids_by_field("美妆")
```

2.1.3 辅助数据源说明

本研究未引入任何辅助数据源，如微博热搜、百度指数或第三方社交媒体监测平台的数据。所有分析均基于所采集的小红书平台笔记数据展开。通过构建大规模、高维度的原始笔记数据集，直接从平台内部数据中挖掘影响内容传播效果的关键因素，以避免外部数据噪声对分析结果的干扰。

2.2 数据采集方法

研究采用基于 Python 的自动化网页数据采集方法，对平台公开页面进行结构化解析。在采集过程中，通过合理控制请求频率与访问行为，尽量降低连续请求对平台服务的影响。

采集任务按“入口访问—ID 发现---详情抓取---结构化存储”的流水线组织，以支持分批执行、断点续采和后续维护。

2.2.1 采集工具与框架

数据采集主要基于 Python 语言实现，使用 requests 库完成网页请求，利用 BeautifulSoup 对 HTML 页面进行解析与信息提取。通过维护会话状态、设置随机 User-Agent 及请求延时，有效降低高频访问带来的风险，提高采集过程的稳定性。

整体爬虫程序采用模块化设计，分为笔记 ID 采集模块与笔记详情信息采集模块，便于后续维护与扩展。

- 第一阶段：ID 收集爬虫：该模块负责从平台信息流中持续发现新的笔记 ID。它模拟访问指定的频道发现页（如美妆、家电频道），解析页面源码，提取笔记详情页链接并剥离出唯一的笔记 ID。
- 第二阶段：详情页采集爬虫：该模块读取第一阶段生成的 ID 列表，批量构建详情页 URL 并发起请求。通过解析详情页的 <meta> 标签和特定 DOM 元素，精确提取 2.1.1 节中定义的各类信息。

小红书笔记 ID 采集流程示例：

```
import time
import random
import requests
from bs4 import BeautifulSoup

def get_note_ids_from_page(url):
    headers = {
        "User-Agent": "Mozilla/5.0"
    }
    response = requests.get(url, headers=headers)
    soup = BeautifulSoup(response.text, "html.parser")

    note_ids = []
    for link in soup.find_all("a", href=True):
        if "/explore/" in link["href"]:
            note_id = link["href"].split("/explore/")[-1]
            note_ids.append(note_id)

    time.sleep(random.uniform(2, 5)) # 随机延时
    return note_ids
```

在获取笔记唯一标识后，进一步访问笔记详情页面，对笔记的文本内容、互动数据及

发布时间等关键信息进行解析。其基本实现流程如代码示例所示：

```
import requests
from bs4 import BeautifulSoup
import time
import random

def get_note_detail(note_id):
    url = f"https://www.xiaohongshu.com/explore/{note_id}"
    headers = {
        "User-Agent": "Mozilla/5.0"
    }

    response = requests.get(url, headers=headers)
    soup = BeautifulSoup(response.text, "html.parser")

    # 提取笔记标题
    try:
        title = soup.select_one('meta[name="og:title"]')['content']
    except:
        title = ""

    # 提取正文描述
    try:
        description =
            soup.select_one('meta[name="description"]')['content']
    except:
        description = ""

    # 提取互动数据
    try:
        like_count =
            soup.select_one('meta[name="og:xhs:note_like"]')['content']
        comment_count =
            soup.select_one('meta[name="og:xhs:note_comment"]')['content']
        collect_count =
            soup.select_one('meta[name="og:xhs:note_collect"]')['content']
    except:
        like_count, comment_count, collect_count = 0, 0, 0
```

```
34
35      # 提取发布时间
36      try:
37          publish_time = soup.select_one('span.date').text.strip()
38      except:
39          publish_time = ""
40
41      time.sleep(random.uniform(2, 4)) # 控制访问频率
42
43      return {
44          "note_id": note_id,
45          "title": title,
46          "description": description,
47          "like": like_count,
48          "comment": comment_count,
49          "collect": collect_count,
50          "publish_time": publish_time
51      }
```

2.2.2 采集流程设计

本研究的数据采集流程主要包括以下几个步骤：

1. **确定采集范围**：明确研究领域为家电与美妆两个内容类别，并按批次记录采集时间；当前归档中可解析的笔记发布日期覆盖 2023 年至 2024 年 10 月。
2. **笔记 ID 获取**：分别通过搜索页面与频道页面获取笔记列表，从页面中解析并提取笔记唯一标识（ID），并对已采集 ID 进行去重处理。
3. **笔记详情采集**：基于已获取的笔记 ID，进一步访问笔记详情页面，采集页面当时公开展示的文本内容、互动数据、发布时间及博主粉丝数等信息。
4. **数据存储**：将结构化字段统一存储为 CSV 文件，并按采集批次归档于压缩包。当前仓库保留的是这些结构化表，不包含可供统一分析的原始图片、视频帧或音频文件。

数据采集过程为连续多日运行完成，通过分轮采集与断点续爬机制，保证在长时间运行条件下的数据完整性与稳定性。

2.2.3 反爬策略与伦理考量

为降低对平台服务器的访问压力并遵守网络爬虫伦理，本研究在数据采集过程中采取了以下措施：

- 设置随机请求延时，避免高频访问；
- 控制单轮采集规模，防止异常请求行为；

- 仅采集平台公开展示的数据内容；
- 所有数据仅用于学术研究，分析结果以聚合统计形式呈现，不涉及任何个人隐私信息的公开。

本研究所采集的全部数据均为小红书平台上的公开信息。在数据使用上，我们郑重承诺：所有数据仅用于本项学术研究的统计分析，绝不会用于任何商业目的，也不会以任何形式公开披露能识别到具体用户或个人身份的原始信息。论文中的所有结论均基于聚合后的统计结果呈现。

2.3 数据描述与特征工程

原始采集的小红书笔记数据以文本和半结构化字段为主，包含大量非标准化表达形式，无法直接用于统计分析与建模。因此，本研究在数据清洗的基础上，围绕时间信息、互动行为、发布地点与标签等核心要素，构建了一套结构化特征体系，将原始字段转化为可量化、可编码的分析变量。

2.3.1 时间特征构建

小红书平台中的发布时间以多种自然语言形式呈现，如“3 天前”“昨天 20:15”“06-20”“编辑于今天”等。针对该特点，本文对发布时间字段进行统一解析与推断，主要步骤包括：

- 识别相对时间表达（如“x 天前”“昨天”“今天”），并基于数据采集日期反推出实际发布日期；
- 对仅包含“月-日”或“x 月 x 日”的时间表达，结合采集时间补全年份信息；
- 对已为标准日期格式（如 YYYY-MM-DD）的记录直接保留。

经过处理后，所有笔记的发布日期被统一转换为标准日期格式（YYYY-MM-DD），并在此基础上进一步派生出以下时间特征：

- **发布日期**：推断后的笔记实际发布时间；
- **星期特征**：根据发布日期计算星期几，并编码为数值型变量，用于刻画发布时点的周期性特征。

2.3.2 互动行为特征

互动行为是衡量笔记热度的核心信息来源，包括点赞数、评论数、收藏数以及发布者粉丝数。然而，这些字段在原始数据中通常以非标准数值形式出现，如“1.2 万”“3 万+”“10+”等。

为保证数据的可计算性，本文对上述字段进行统一数值化处理：

- 将带有“万”“万 +”等单位的文本数值转换为对应的整数数量级；
- 对带“+”的数值，在保留数量级信息的基础上进行近似修正；
- 最终生成相对准确的点赞数、评论数、收藏数及粉丝数数值特征。

该处理过程在一定程度上缓解了平台展示规则带来的信息模糊问题，使互动数据能够直接参与后续统计分析与建模。

2.3.3 发布地点特征

发布地点信息来源于笔记发布时间字段中附带的文本描述。本文通过正则匹配与字符串解析方法，从相关字段中抽取用户填写的发布地点信息，并构建地点特征。

在此基础上，采用字典映射方式对地点文本进行编码处理：

- 对已识别的发布地点建立全局唯一编号映射表；
- 对同时包含多个地点的情况，保留多值编码结果；
- 对未填写或无法识别发布地点的笔记，设置统一的缺失标记。

此外，为便于模型区分地点信息的完整性，额外构建“是否填写发布地点”的辅助二元特征。

2.3.4 标签特征

笔记中的话题标签反映了内容的主题属性。本文对笔记中包含的标签词进行统计与整理，并采用与发布地点相同的字典化编码策略：

- 统计全体数据中出现过的标签词集合；
- 构建标签词到数值 ID 的映射关系；
- 对缺失标签或无标签笔记设置统一缺失编码；
- 构建“是否填写标签”的辅助特征。

通过上述处理，原始文本标签被转化为可用于建模的离散类别特征。

2.4 数据预处理与清洗

原始采集的数据在结构和内容层面均存在噪声与不一致问题。为保证数据质量，本文在特征工程之前实施了系统的数据预处理与清洗流程。

2.4.1 异常与冗余数据清理

在数据整理过程中，主要执行以下清洗操作：

- 删除在合并或追加过程中产生的重复表头行；
- 剔除关键字段（如粉丝数）中包含明显异常字符串的记录；
- 对无法解析发布时间或缺失核心标识信息的样本予以剔除。

2.4.2 缺失值处理策略

考虑到社交平台数据中缺失现象普遍存在，本文未采用简单均值或众数填补，而是通过显式标注缺失状态的方式进行处理：

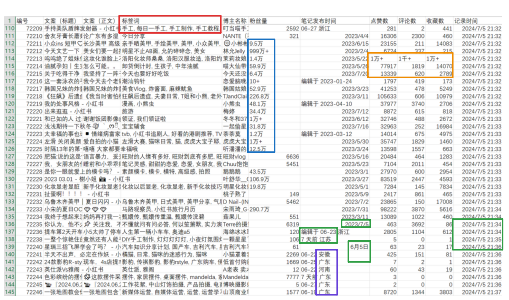
- 对发布地点、标签等非关键特征，使用特定编码值表示缺失；
- 同时构建“是否填写该信息”的辅助特征，保留缺失本身所蕴含的信息；
- 对关键字段（如笔记 ID、互动数据）严重缺失的样本直接剔除。

2.4.3 特征编码与一致性控制

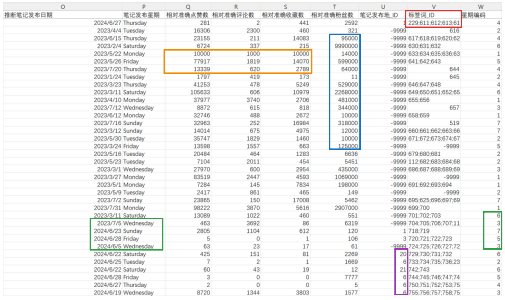
为保证多文件、多批次数据处理结果的一致性，代码采用增量式字典编码策略：

- 地点与标签编码字典在处理过程中持续更新并全局共享；
- 相同文本特征在不同数据文件中始终对应相同的数值编码；
- 对未匹配到的异常类别设置统一的异常标识值。

该策略有效避免了因分批处理导致的特征含义不一致问题，为后续建模提供了稳定的数据基础。



(a) 清洗前的原始字段



(b) 清洗后的结构化字段

图 2.5: 小红书笔记数据清洗前后对比

Part III: 小红书笔记多维度数据分析与探索

3 笔记内容质量分析 29

3.1 文本内容深度与可读性分析

3.2 主题相关性与信息价值分析

4 笔记形式特征与多媒体数据边界 35

4.1 多媒体数据的可用性审计

4.2 当前可复现的文本形式特征

5 发布者基础影响力与用户数据边界 37

5.1 粉丝规模与互动的描述性关联

5.2 未纳入的用户历史、认证与社交网络变量

6 发布时机与上下文分析 39

6.1 星期分组的互动差异

6.2 节假日与调休日期的分组差异

6.3 发布地点的样本分布与互动差异

7 标签数量分析与话题数据边界 43

7.1 标签数量的描述性结果

7.2 标签类型与热点响应的识别边界

8 多维度相关性分析 45

8.1 特征间相关性分析

8.2 特征与目标变量相关性分析

8.3 非线性关系探索

9 特征选择与重要性评估 51

9.1 筛选原则与实际输入特征

9.2 已实施的模型重要性评估



3. 笔记内容质量分析

3.1 文本内容深度与可读性分析

本研究从文本长度、可读性与情感三个维度考察小红书笔记内容质量与互动表现之间的关系。由于可读性计算成本较高，本文采用“全量基础清洗 + 固定随机种子抽样计算特征 + 回归稳健性检验”的方式开展分析。

3.1.1 变量构建与样本处理

首先，本文从三个 ZIP 中的 76 份符合字段要求的明细 CSV 读取 323,598 行，互动字段清洗后为 313,003 行；再以“粉丝量高于第 90 百分位且互动率低于 1%”的历史规则做敏感性筛选，保留 297,031 行。该规则仅用于统计诊断，不能据此认定账号存在“买粉”行为。可读性固定抽取 50,000 条计算，其中 49,912 条得到有效值，最终 OLS 再固定抽取 20,000 条。本章沿用早期探索的“不跨文件去重”口径，不与后文统一去重后的 199,473 条建模样本混用。

在核心变量构建上，本文将互动表现定义为：

$$\text{engagement} = \text{likes} + \text{favs} + 4 \times \text{comments}$$

并对其取对数得到以缓解长尾分布对回归估计的影响。文本长度方面，本文计算了标题长度、正文长度以及全文长度，其中全文长度作为主分析变量进入回归模型。情感变量则由情感预测值构造得到，进一步计算情绪极端程度

$$\text{emotion_extreme} = |\text{emotion_strength} - 0.5|$$

3.1.2 文本长度与互动关系

为了考察文本长度与用户互动的关联，本文首先对全文长度与互动水平进行了可视化分析。结合后续回归结果，长度的一次项系数为负、二次项系数为正，表明二者在当前样本中呈现一定的 U 型统计关系：较短文本对应的平均互动较高，长度增加后互动先下降，并在部分较长文本区间出现回升。该形态不能单独证明调整文本长度会引起互动变化。

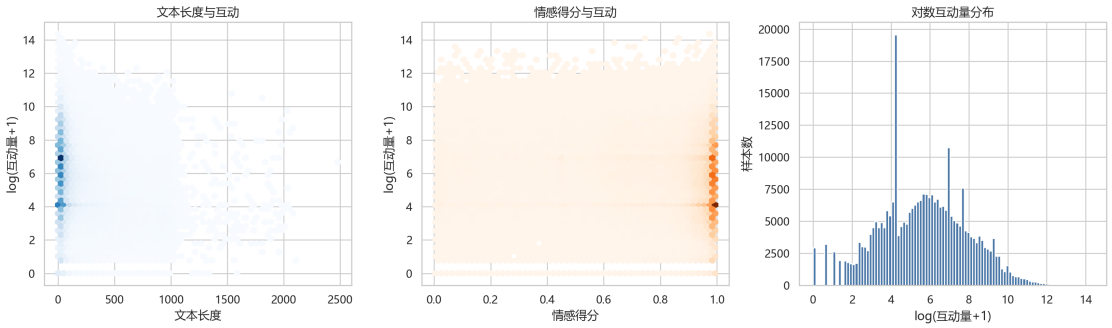


图 3.1: 文本长度、情感得分与对数互动量的探索性分布

3.1.3 文本情感与互动关系

在情感维度上，本文进一步分析了情感强度与互动表现之间的关系。回归结果表明，情感变量与互动水平呈现负相关趋势。情感强度和情绪极端程度在主模型与稳健性模型中均表现为显著负相关，说明在本样本中，越偏离中性、越强烈的情绪表达，平均互动反而更低。

3.1.4 互动分布特征

从整体分布来看，笔记互动量呈现明显的长尾特征。大多数样本集中在较低互动区间，只有少量内容获得了极高互动。这也解释了为何本文对互动变量采用对数变换后再进行建模，以提高回归估计的稳定性并减弱极端值的影响。

3.1.5 非线性趋势识别

为了进一步识别长度变量与互动之间的非线性结构，本文对抽样样本进行了 LOWESS 平滑拟合。结果显示，文本长度与互动之间存在较明显的弯曲趋势，这说明简单线性模型不足以完整描述二者关系。因此，在后续 OLS 回归中，本文加入了长度平方项，以刻画可能存在的非线性效应。

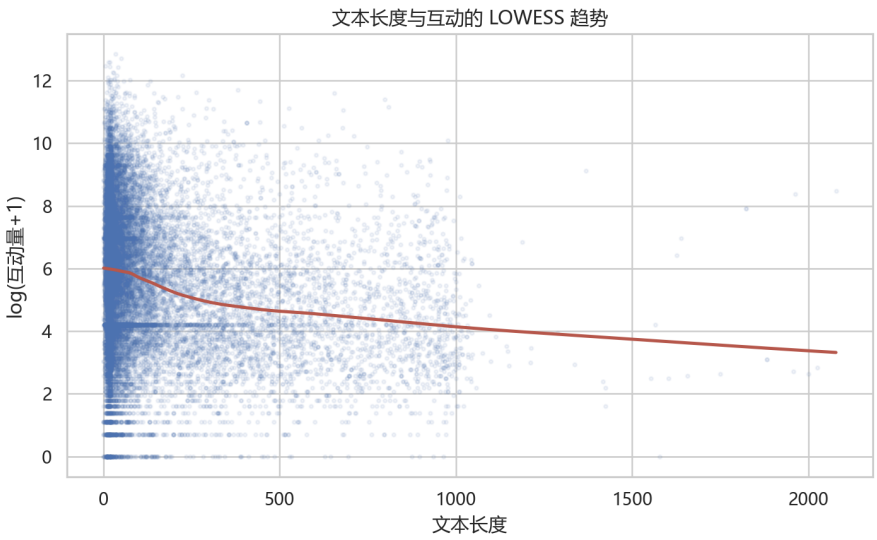


图 3.2: 文本长度与对数互动量的 LOWESS 趋势

3.1.6 回归结果与稳健性检验

在主回归模型中，本文以 *engagement_log* 为因变量，以文本长度、长度平方项、情感强度、情绪极端程度和可读性为自变量进行 OLS 估计。结果显示，模型整体显著，但解释力有限，R^2 约为 0.050。这说明文本特征对互动具有统计意义上的解释力，但笔记热度仍受到账号属性、发布时间、封面质量、主题类别等其他因素影响。

具体而言，文本长度一次项系数显著为负，而二次项系数显著为正，说明长度关联具有非线性特征；情感强度与情绪极端程度的系数均显著为负，表明在本样本中，情绪越强或越极端，平均互动反而更低。可读性系数的绝对值很小，主模型中 $p < 0.001$，去除互动量最高 1% 样本后为 $p = 0.018$；方向保持但证据减弱，不宜赋予较强的实际解释。

进一步地，本文剔除互动前 1% 的极端值后重新估计模型，核心变量的方向和显著性基本保持一致，说明这些样本内关联并非完全由少数极端爆款观测驱动。不过，稳健性检验并未消除账号基础、主题与发布时间等潜在混杂因素，结果仍不应解释为因果效应。

3.1.7 分组分析

为更直观地观察长度关联，本文进一步将文本长度按分位数分组，比较不同长度区间的平均互动水平。结果表明，不同长度组的平均互动存在差异，整体形态与回归结果一致；但这些分组均值只能描述当前样本，不能直接据此确定普遍适用的“最优长度”。

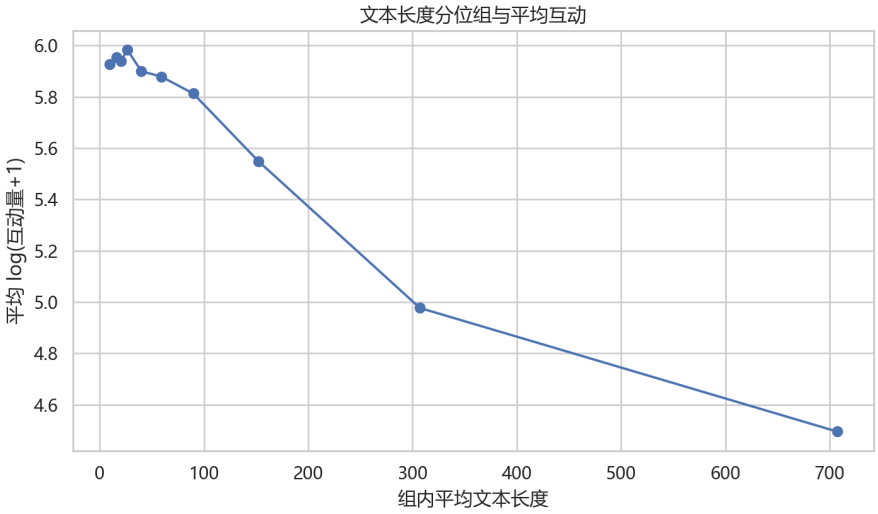


图 3.3: 文本长度分位数组的互动表现

3.1.8 情感分组结果

最后，本文对情感强度与情绪极端程度进行了分组比较。结果表明，情感强度较低、情绪更接近中性的样本平均互动更高；而情绪极端程度越高，平均互动水平总体越低。这一结果与回归分析保持一致，进一步说明在小红书笔记场景中，过强或过于极端的情绪表达并不一定带来更高互动。

综合来看，文本长度与互动呈现非线性统计关系，情感强度及情绪极端程度总体上与互动负相关，可读性关联较弱且不够稳健。由于模型解释度较低且仍可能存在未观测混杂，本章将这些结果作为描述性与预测性证据，而不将其表述为内容特征对热度的确定性作用。

3.2 主题相关性与信息价值分析

在社交媒体中，内容传递的信息集中程度以及“标题---正文”间的词汇重合，可能与用户互动同时变化。本节基于 TF–IDF 算法提取文本核心词，从“信息密度”与“标题匹配度”两个维度考察其与互动表现的关联。

3.2.1 变量构建与共线性修正

为量化笔记的信息分布情况，本文首先利用 TF-IDF 算法提取单篇笔记中的高权重核心词汇。“信息密度（info_density）”定义为正文高权重词汇数占局部总有效词数的比重；“标题匹配度（title_match）”则定义为标题关键词与正文关键词的交集词数占标题总词数的比例，主要用于衡量笔记是直接“白描”还是存在一定的内容悬念差。

在将上述变量引入回归模型前，本文利用 Z-score 对连续型自变量进行标准化，再由标准化后的长度构造平方项。处理后，各变量的方差膨胀因子（VIF）介于 1.12 至 7.88 之间，模型总体条件数（Cond. No.）为 8.64。个别变量仍存在中等程度的共线性，解释单个

系数时需保持谨慎。

3.2.2 信息价值回归结果与检验

本文将标准化后的各特征变量纳入 OLS 回归模型，因变量为对数互动量，而非除以粉丝数后的互动率。回归估计结果如表 3.1 所示。整体模型达到统计显著（F 统计量 = 254.6，Prob(F) < 0.001），但 R^2 仅为 0.071。

表 3.1: 信息价值与互动表现的多元线性回归结果

变量	标准化系数 (β)	标准误 (Std.Err)	t 值	P>|t|
截距项 (Intercept)	5.4294	0.021	254.91	<0.001 ***
内容长度 (*content_len*)	-0.5052	0.043	-11.76	<0.001 ***
内容长度平方 (*content_len*^{2})	0.0768	0.015	5.19	<0.001 ***
情感强度 (*emotion_strength*)	-0.1138	0.018	-6.23	<0.001 ***
极端情感 (*emotion_extreme*)	-0.0981	0.019	-5.29	<0.001 ***
信息密度 (*info_density*)	0.1057	0.025	4.23	<0.001 ***
标题匹配度 (*title_match*)	-0.1698	0.016	-10.48	<0.001 ***
样本量 = 20,000	R^2 = 0.071	总体条件数 (Cond. No.) = 8.64		

注：*** 代表 1% 的显著性水平。

由于引入了标准化处理，相较于前述基础回归模型，本模型中的系数可用于比较不同特征与对数互动量的样本内关联强度。加入新特征后，长度的非线性形态及极端情绪的负向系数仍然存在；信息密度和标题匹配度则提供了两个额外的关联信号。这里的因变量是对数互动量而非互动率，系数也不代表因果作用。

3.2.3 信息密度的“干货溢价”效应

回归结果表明，信息密度与互动表现呈显著正相关（$\beta = 0.1057, p < 0.001$）。在控制模型中其他文本变量后，高权重词汇占比较高的笔记通常具有更高的平均互动量。这一结果与“信息更集中、更便于检索的内容可能更符合用户决策需求”的解释一致。不过，本文的信息密度来自 TF–IDF 阈值构造，且模型尚未控制全部账号与主题差异，因此该结果应理解为相关性证据，而非信息密度对互动的确定性因果效应。

3.2.4 标题匹配度的负向关联及可能解释

模型同时揭示了一个值得关注的反直觉现象：标题匹配度与互动表现呈显著负相关（$\beta = -0.1698, p < 0.001$），且其标准化系数绝对值在模型中仅次于文本长度。这意味着，在当前样本和词汇重合度定义下，标题关键词被正文直接重复得越多，笔记的平均互动量反而越低。

这一现象可能与信息缺口或标题的悬念表达有关：过分直白的重复可能降低读者继续探索的意愿，而适度的信息差可能保留阅读动机。不过，当前指标衡量的是分词后的词汇

重合，而不是严格的语义一致性；标题较短、正文缺失或不同主题的语言习惯也可能影响该指标。因此，“悬念留白”只能作为一种可能解释，尚不能由本模型直接验证。

3.2.5 信息分布的可视化特征

为直观呈现变量的联合分布，本文绘制信息密度、标题匹配度与互动强度的二维六边形密度图（Hexbin Plot）。如图 3.4 所示，信息密度较高的部分区间延伸至较高互动区域，而标题匹配度较高区域的样本更多集中在较低互动水平。该图与回归系数方向一致，但二维分布仍会受到粉丝规模、主题和文本长度等变量影响，不能单独验证“干货溢价”或“悬念留白”等行为机制。

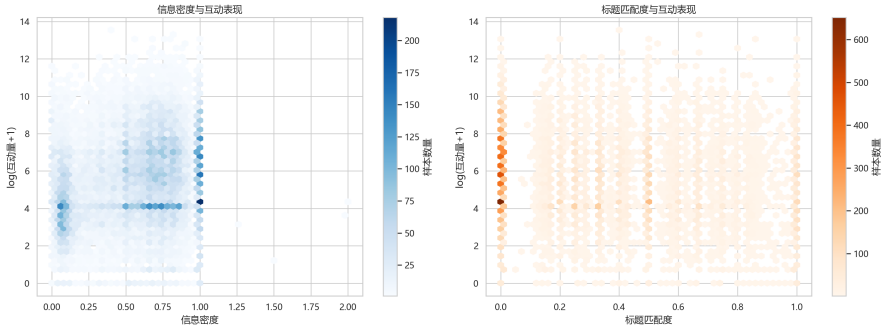


图 3.4: 信息密度、标题匹配度与互动量的二维密度分布



4. 笔记形式特征与多媒体数据边界

4.1 多媒体数据的可用性审计

小红书具有明显的视觉内容属性，但视觉重要性并不意味着当前数据可以支持视觉效果评估。仓库内的结构化明细表以标题、正文、标签、互动量、粉丝量、时间和地点等字段为主；部分批次虽保留媒体链接或类型文本，却没有与每条笔记稳定对应的原始图片、视频文件、视频时长、字幕或背景音乐等元数据。链接还可能随时间失效，无法作为可重复实验的固定输入。

因此，本轮研究没有计算图片数量、色彩、构图、清晰度、美学质量、视频时长或完播率，也不报告“图片越多”“视频存在最优时长”等未经验证的结论。分类与回归实验中的 10 项输入特征均来自发布前可获得的结构化字段，不包含视觉特征。若后续补充媒体资产，应先用笔记唯一标识校验图文配对，并记录抓取时间与缺失机制；在同一数据切分上提取色彩、清晰度、视觉语义和视频元数据后，才能与当前结构化基准进行增量比较。

4.2 当前可复现的文本形式特征

现有数据能够稳定构造的形式变量包括标题长度、正文长度、标签数量、感叹号数量、问号数量、Emoji 数量以及标题---正文词汇重合度。这些指标描述的是文本表层结构，不等同于完整排版质量：CSV 中的换行、富文本加粗和平台端渲染样式未必被一致保留，因此本研究没有推断分段质量、视觉层级或阅读停留时间。

第 8 章的统一相关性分析显示，标签、Emoji、感叹号和问号等变量与互动量的 Spearman 相关系数绝对值均小于 0.05；部分检验在大样本下达到统计显著，但实际效应较弱。它们仍作为低成本结构化特征进入后续模型，用于检验与粉丝量、文本长度、情感及时间变量组合后是否提供预测增量。无论相关性还是模型重要性，都不能证明增加某种符号或改变

格式必然提高互动。

5. 发布者基础影响力与用户数据边界

5.1 粉丝规模与互动的描述性关联

当前归档能够较稳定使用的发布者变量是采集时展示的粉丝数量。鉴于该变量呈明显长尾分布，相关性与模型分析均使用 log(1 + fans)。图5.1按粉丝数分位组展示平均点赞数：从 Q1 到 Q5，组均值总体递增。这是一个清晰的描述性梯度，但不能据此断言粉丝增长会按相同比例带来点赞增长，因为账号主题、内容质量、发布时间与平台推荐均可能同时影响二者。

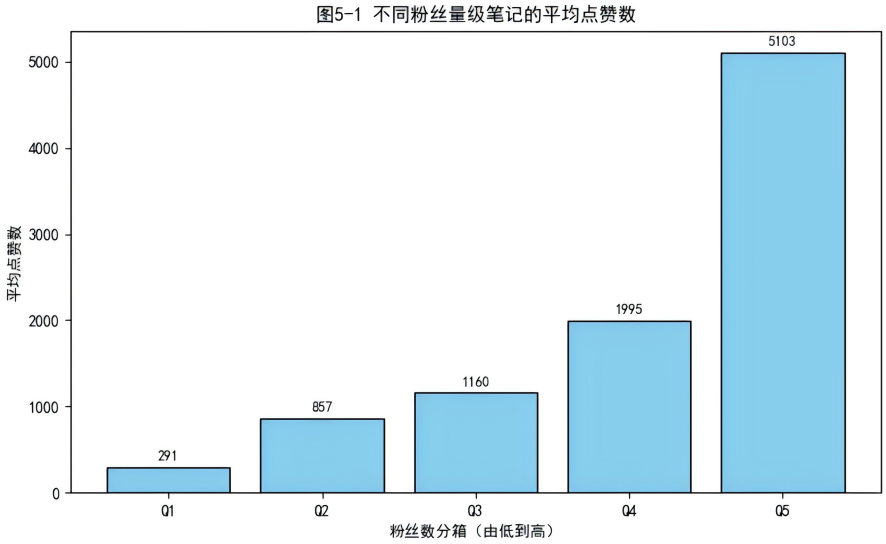


图 5.1: 不同粉丝量级笔记的平均点赞数（描述性分组）

在统一去重后的相关性样本中，粉丝数对数与对数互动量的 Pearson 和 Spearman 相关

系数分别为 0.489 和 0.469；爆款组与普通组的粉丝数对数差异对应 Cohen's $d = 0.696$。这些结果表明粉丝规模是当前字段中最稳定的关联信号之一。后续随机森林分类和梯度提升回归也将其识别为主要预测特征，但预测重要性仍不等于因果效应。

5.2 未纳入的用户历史、认证与社交网络变量

当前数据不能稳定构造发布者在每条笔记发布前 7 天、30 天或 90 天的完整历史表现，也没有一致的认证状态、粉丝人口属性和用户---笔记交互边。因此，本轮研究没有填补或模拟以下变量：历史平均点赞与发帖频率、企业号或达人认证、账号内容垂直度、粉丝画像及社交网络中心性。若以采集后的互动反推发布前历史，还会造成时间泄漏。

未来若补充按时间排序且覆盖完整的发布者历史，可只使用每条样本发布时间之前的记录构造滚动统计，并用作者分组或时间外切分验证；内容垂直度可基于历史主题分布的熵值定义，认证与粉丝画像则必须来自明确、合法且可审计的字段。在这些数据到位前，本章不对“高垂直度更忠诚”或“认证带来额外流量”等命题给出实证结论。



6. 发布时机与上下文分析

本章对具有可解析发布日期或发布地点的记录进行探索性分组，比较星期、日期类型与省份之间的互动差异。章节中的样本筛选服务于对应图表，与后文统一去重的建模样本口径不同；“高粉丝、低互动”规则仅用于异常值敏感性检查，不被解释为真实的买粉标签。以下结果反映的是同期样本的条件关联，而非发布时机或地域对互动的因果效应。

6.1 星期分组的互动差异

单因素方差分析显示，不同星期组的对数互动量存在统计差异（$F = 946.56$，$p < 0.001$，$\eta^2 = 0.018$）。效应量 η^2 表明星期仅解释约 1.8% 的组间变异：样本量较大使检验容易达到显著，但星期本身的实际解释力有限。

在该探索性样本及平均对数互动指标下，周一均值最高（5.95），周五最低（5.01）；Tukey HSD 事后比较也显示周五与多个日期组存在显著差异。该结果只能说明不同星期发布的样本构成和互动水平不同。内容类别、账号规模、采集批次与推荐流量都可能造成组间差异，现有数据不足以验证“心理补偿”“线上线下替代”等具体行为机制。第 8 章使用严格去重样本和爆款比例得到的星期排序略有不同，也说明结论会随指标和样本口径变化。

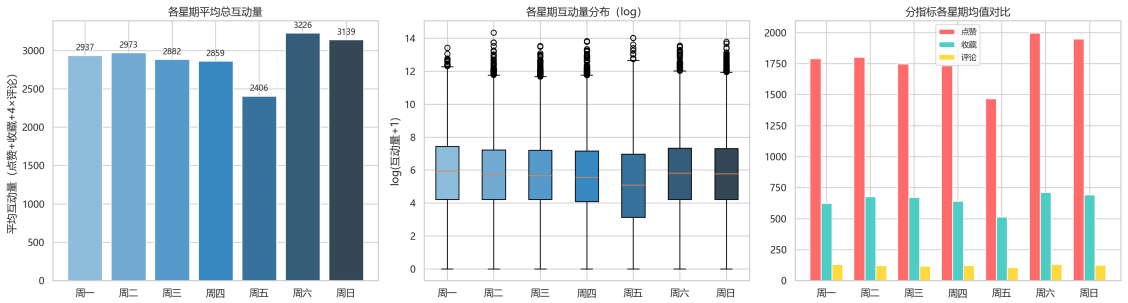


图 6.1: 不同星期组的笔记互动分布

6.2 节假日与调休日期的分组差异

本文依据公开日历将可解析日期划分为普通工作日、普通周末、法定节假日和调休工作日。四组的 ANOVA 检验显示均值存在差异（$F = 305.53$，$p < 10^{-190}$）。在该样本中，调休工作日的平均总互动为 4,744、平均对数互动为 6.28，法定节假日的平均总互动为 4,202；节假日与非节假日的 Welch 检验亦达到统计显著（$t = 18.75$，$p < 0.001$）。

上述均值是描述性结果。原始互动量长尾明显，少量爆款可能显著抬高组均值；同时，日期类型与主题、营销活动、账号结构和采集批次可能共同变化。由于数据不含曝光量、浏览频率和连续早期互动轨迹，本研究不能据此推断调休导致用户浏览增加，也不能将某类日期视为确定性的发布优势。

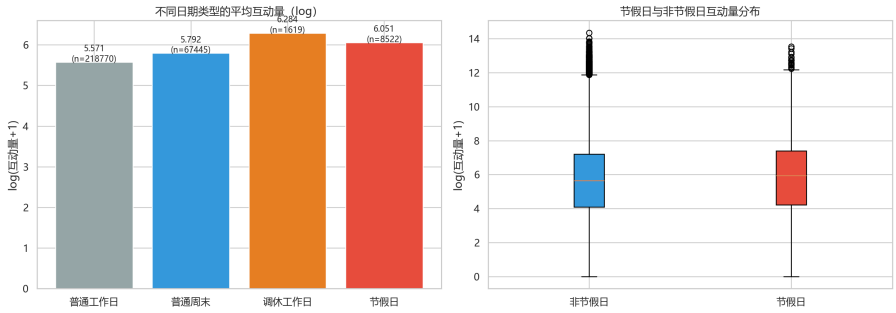


图 6.2: 不同日期类型的互动表现分布

6.3 发布地点的样本分布与互动差异

发布地点为用户自行展示且存在大量缺失，其含义可能是发布地、常驻地或内容标注地。本文在剔除空值和无法识别的文本后，对样本量较多的省级地区进行描述。广东样本最多，为 25,624 条；其平均对数互动为 5.23。浙江、四川和上海的平均对数互动分别为 5.97、5.88 和 5.87，在图示地区中相对较高。

这些差异不能直接归因于地区经济、代运营产业或生活方式文化。不同地区的领域构成、账号粉丝规模及地点填写倾向均可能不同，且地点缺失并非随机。因而图6.3用于呈现样本覆盖和组均值，不作为地域文化或产业链影响的因果证据。

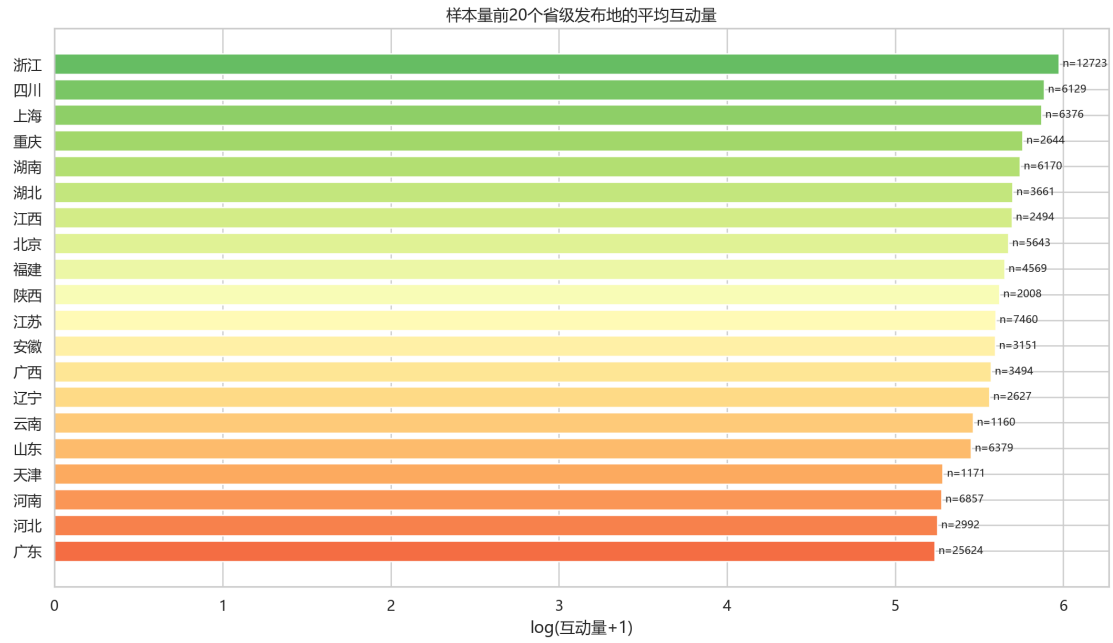


图 6.3: 发布地点样本量与互动水平的描述性比较

7. 标签数量分析与话题数据边界

7.1 标签数量的描述性结果

现有明细表能够从标签字段计算每篇笔记的标签数量。图7.1按标签数分组后显示，0–2 个、3–4 个、5–6 个、7–10 个和超过 10 个标签的笔记，平均点赞数依次约为 2,358、2,119、2,047、1,422 和 1,586。该样本中的组均值并未呈现“标签越多点赞越高”的关系。

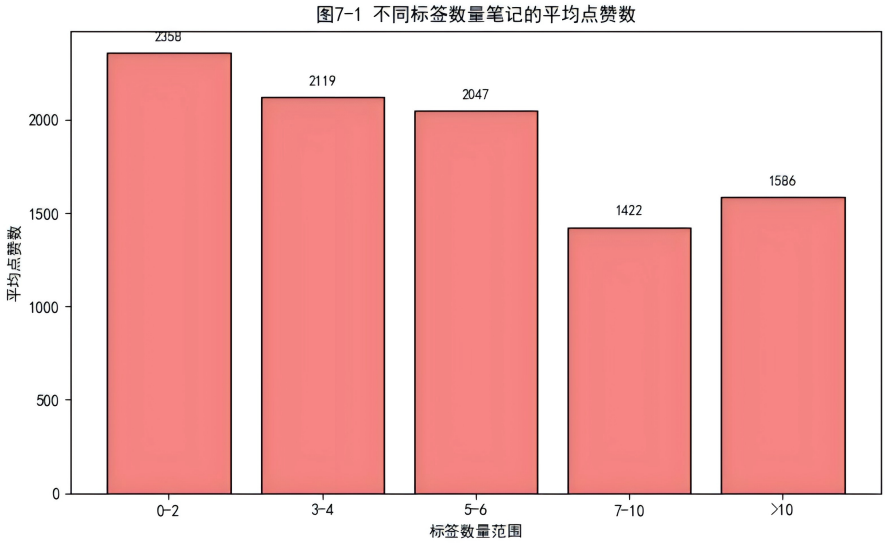


图 7.1: 不同标签数量笔记的平均点赞数（描述性分组）

统一相关性分析进一步表明，标签数量与互动量的相关系数绝对值较小，爆款组与普通组的标准化差异也较弱。标签数量可能同时反映领域习惯、账号策略和文本长度，简单组均值没有控制这些混杂因素。因此，本研究不把 0–2 个标签解释为普遍最优方案，也不

依据该图给出确定性的标签数量建议。

7.2 标签类型与热点响应的识别边界

当前归档没有经过人工验证的标签类型词典、外部热点事件时间线，也没有笔记发布后 0–72 小时的连续互动快照。基于单次采集的最终互动量，无法可靠识别笔记何时介入热点，更无法估计热点响应的净效应或衰减曲线。因此，本轮没有实施“黄金标签组合”挖掘、倾向得分匹配、逆概率加权或热点生命周期建模，也不报告相关数值结果。

后续若补充可追溯的热点事件表和连续互动快照，可预先定义热门、垂直、地点及品牌标签，记录事件起止时间，再在严格时间切分下比较介入阶段。即使使用匹配或加权方法，也需检验共同支持与未观测混杂，不能仅凭方法名称将观察性差异表述为因果效应。



8. 多维度相关性分析

8.1 特征间相关性分析

为避免原始文件、筛选文件及中间结果重复计入，本章仅读取文件名中包含“笔记详细信息”的数据，并优先按照笔记链接去重；链接缺失时，采用编号、标题和博主名称的组合去重。完成互动指标清洗后，共得到 182,103 条可用笔记，其中 168,323 条具有有效粉丝数。由于现有数据不包含可靠的图片数量、认证状态和发布小时，本章不对这些变量进行推断，而使用实际可获得的粉丝数、文本长度、标签数、标点与表情符号、情感得分、标题正文重合度、星期和地点完整性等特征。

考虑到互动量和粉丝数均呈明显长尾分布，本文分别构造

$$y = \log(1 + \text{engagement}), \qquad x_{fans} = \log(1 + \text{fans}),$$

并同时计算 Pearson 相关系数与 Spearman 秩相关系数。前者用于识别线性关系，后者对极端值更稳健，可用于判断变量之间是否存在稳定的单调关系。图8.1给出了特征间 Pearson 相关系数矩阵。

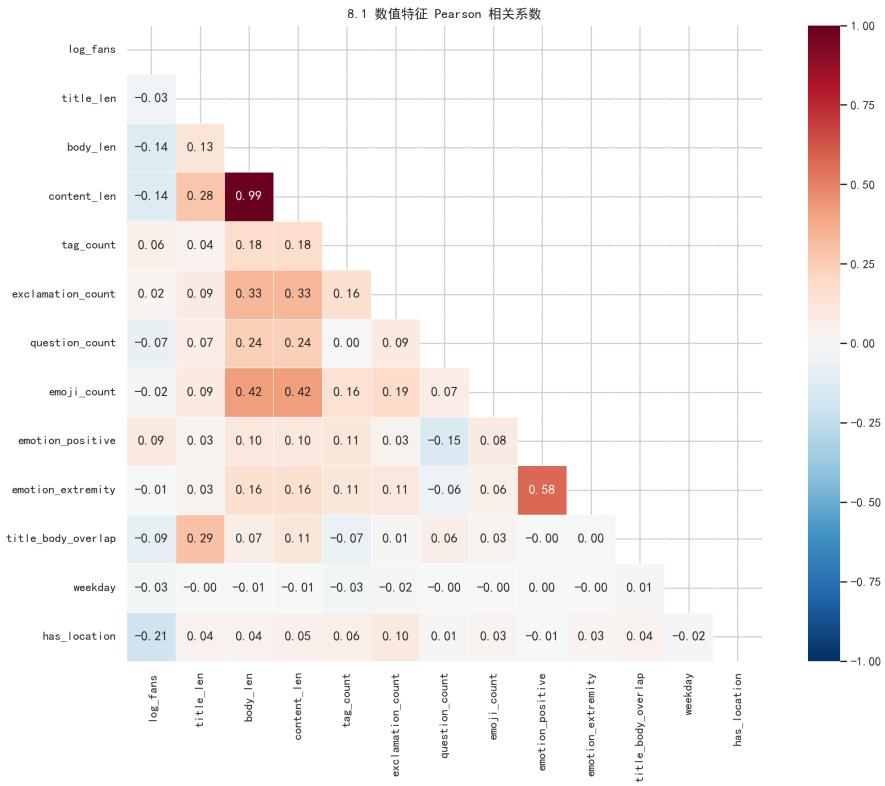


图 8.1: 数值特征间的 Pearson 相关系数矩阵

结果显示，正文长度与全文长度的相关系数达到 $r = 0.988$，是唯一满足 $|r| \geq 0.8$ 的特征对。这一高度相关主要源于全文长度由标题和正文共同构成，属于变量定义带来的机械相关。在后续多变量模型中不宜同时保留正文长度与全文长度，本文建议保留含义更完整的全文长度。其余变量之间未出现绝对相关系数超过 0.8 的组合，说明除长度变量外，当前特征集合不存在严重的两两线性共线性。需要强调的是，两两相关较低并不能完全排除多变量共线性，后续回归仍应结合 VIF 进行诊断。

8.2 特征与目标变量相关性分析

本文首先以对数互动量为连续型目标，分别计算各特征的 Pearson 和 Spearman 相关系数，并采用 Benjamini–Hochberg 方法对多重检验的 p 值进行 FDR 校正。图8.2按照 Spearman 相关系数绝对值展示变量排序。

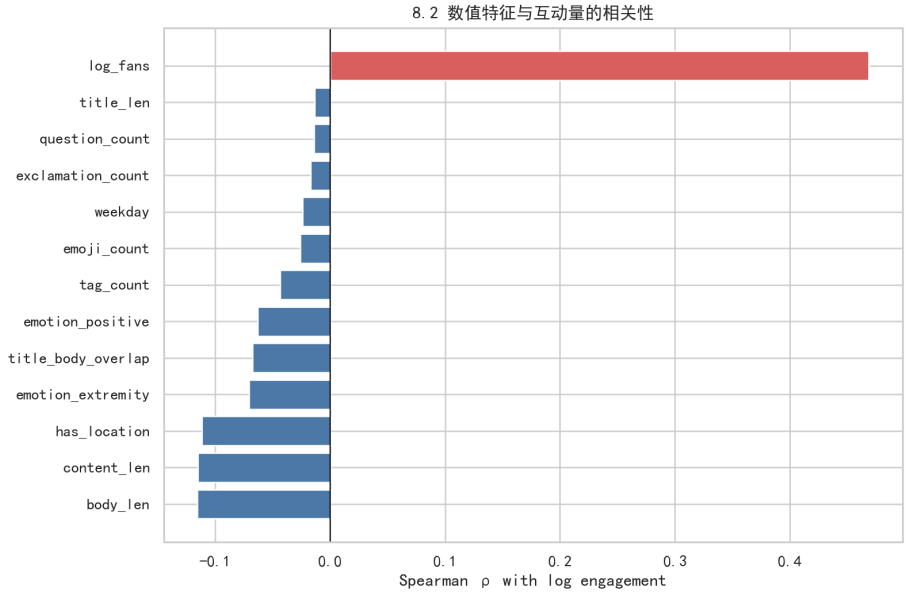


图 8.2: 数值特征与对数互动量的 Spearman 相关系数排序

粉丝数对数与对数互动量的相关性最强，Pearson 相关系数为 0.489，Spearman 相关系数为 0.469，均在 FDR 校正后显著。这表明发布者既有受众规模仍是笔记互动表现最重要的单一关联因素，但相关系数未达到高度相关水平，笔记热度并不能仅由粉丝基数解释。正文长度和全文长度与互动量呈弱负相关，Spearman 系数分别为 −0.116 和 −0.115；是否具有有效发布地点的系数为 −0.111。情绪极端程度、标题正文重合度和正向情感概率的 Spearman 系数分别为 −0.070、−0.068 和 −0.063，方向与第 3 章的回归结果基本一致，但效应强度较小。标签数量、表情符号、星期、感叹号和问号等变量的绝对相关系数均小于 0.05，统计显著性主要受大样本量影响，不宜解释为具有较强的实际作用。

为进一步比较高热度内容，本文将总互动量位于样本前 10% 的笔记定义为“爆款”，并对连续特征实施点二列相关、Welch 独立样本 t 检验和 Mann–Whitney U 检验，同时报告 Cohen's d。粉丝数对数的组间差异最明显：普通组均值为 7.613，爆款组均值为 9.589，$d = 0.696$，属于中等偏大的效应。相比之下，爆款组正文长度和全文长度更短，对应效应量分别为 −0.213 和 −0.211；标签数量、情绪极端程度与表情数量的效应量绝对值约为 0.12 至 0.14，其余变量的效应量更小。问号数量和星期编码在 FDR 校正后均未表现出稳定的爆款组差异。

星期编码本身不适合作为严格连续变量解释，因此本文另行进行分组描述。如图8.3所示，周六和周日的爆款比例分别为 10.91% 和 10.86%，周一为 10.42%，周五最低，为 8.54%。该结果说明星期差异主要体现为类别间波动，而非随编码增加或减少的线性趋势。

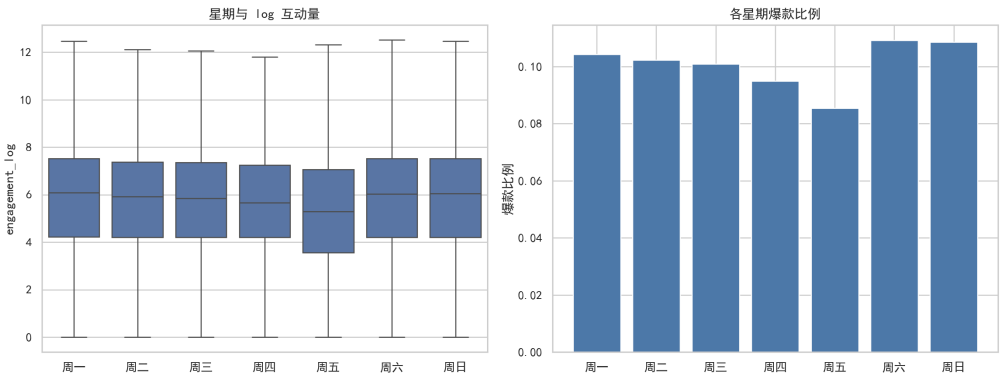


图 8.3: 不同星期的互动量分布与爆款比例

总体而言，粉丝规模是与互动量及爆款状态关联最稳定的特征；文本长度表现出弱负相关；情感、标签及格式变量虽然在大样本下多达到统计显著，但实际效应普遍较弱。因此，后续预测模型不应仅根据 p 值筛选变量，而应综合考虑效应量、非线性结构与变量的理论意义。

8.3 非线性关系探索

线性相关系数可能掩盖阈值、平台期或转折关系。为此，本文对粉丝数对数、全文长度、标签数量、正向情感概率、情绪极端程度和标题正文重合度进行 LOWESS 局部加权平滑，并将全部有效样本划分为 20 个分位数组计算组内平均互动。为减少极端值对曲线边界的影响，作图时剔除各自变量上下 0.5% 的观测；散点和 LOWESS 最多随机抽取 20,000 条记录，而分位数组均值仍使用全部有效数据。

图8.4展示了粉丝规模与文本长度的主要非线性形态。粉丝数对数与互动量总体呈明显正向关系，但曲线并非全程保持相同斜率，说明粉丝增长带来的互动增量存在阶段差异。全文长度曲线则表现出较明显的弯曲：短文本区间互动水平相对较高，随着长度增加先下降，随后在部分较长文本区间趋于平缓或出现局部回升。这与第 3.1 节在 OLS 中加入长度平方项后得到的非线性结论相互印证。

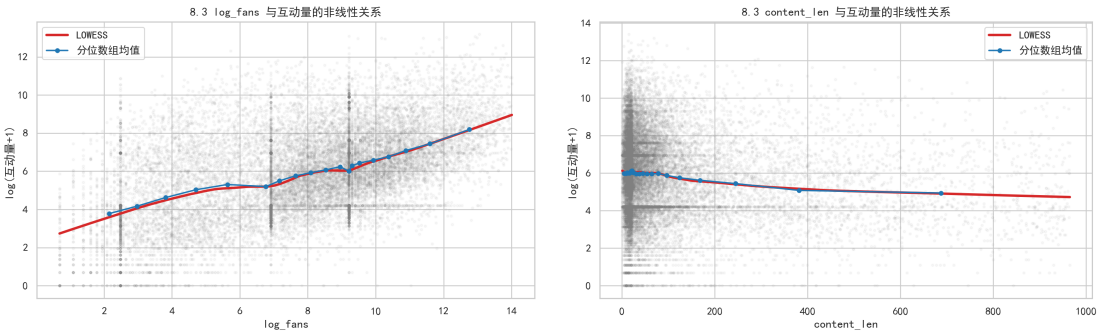


图 8.4: 粉丝规模与全文长度的 LOWESS 非线性关系

情绪极端程度的 LOWESS 结果见图8.5。总体趋势显示，越偏离中性区间，平均对数

互动量越低，但局部区间存在波动。这说明情感效应不宜简单表述为严格线性下降，更适合在后续模型中使用二次项、限制性立方样条或树模型检验。标签数量、正向情感概率和标题正文重合度也呈现不同程度的局部弯曲，但其总体变化幅度明显小于粉丝规模和文本长度。

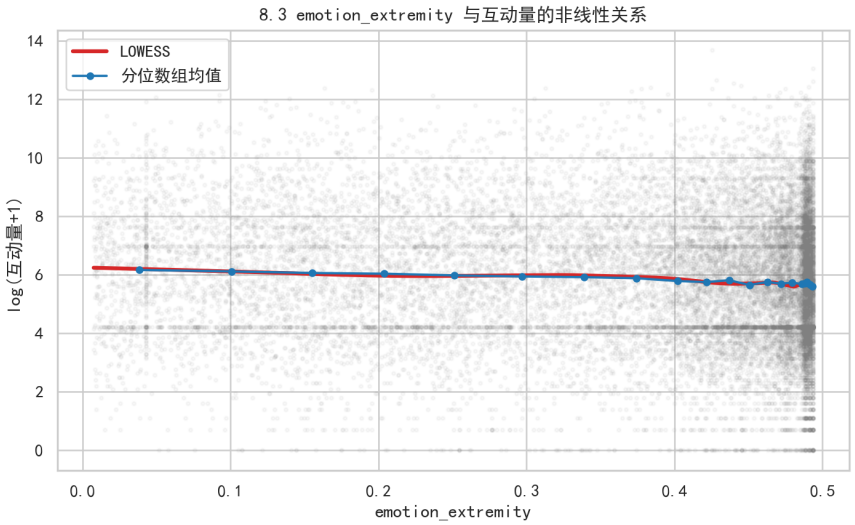


图 8.5: 情绪极端程度与互动量的 LOWESS 关系

需要指出，LOWESS 属于探索性可视化方法，曲线形态不能直接证明因果关系。账号粉丝基础、内容类别、采集时间以及平台推荐机制都可能同时影响文本特征和互动结果。因此，本节的非线性发现主要用于为后续模型设定提供依据，而不将曲线转折点直接解释为普遍适用的内容运营最优值。



9. 特征选择与重要性评估

9.1 筛选原则与实际输入特征

第 8 章同时报告相关系数、FDR 校正后的显著性、组间检验和效应量。由于样本量较大，较小的差异也可能产生很低的 p 值，因此本研究没有采用“$p < 0.05$ 即保留、否则删除”的单一规则。筛选时优先考虑变量是否能在发布前获得、是否存在目标泄漏、缺失程度、效应量与业务含义，并以非线性模型检验弱单变量特征的组合价值。

正文长度与全文长度的 Pearson 相关系数达到 0.988，属于变量定义造成的机械共线，因此统一模型不同时纳入两者。后续分类与回归实验最终使用相同的 10 项输入：粉丝量对数、标题长度、正文长度、标签数、感叹号数、问号数、Emoji 数、情感得分、星期和是否标注发布地。点赞、收藏和评论共同构成目标变量，不作为输入；图片、认证、用户历史与热点变量则因当前数据不足而不进入模型。

9.2 已实施的模型重要性评估

分类实验报告随机森林的基于不纯度的重要性：粉丝量对数为 0.310，情感得分、正文长度和标题长度依次为 0.181、0.131 和 0.108，四项合计约占 73%。回归实验对最佳梯度提升树使用测试集排列重要性；打乱粉丝量对数使对数尺度误差增加 2.620，星期、正文长度、情感得分和是否标注发布地的重要性均值分别为 0.154、0.136、0.136 和 0.105。两类任务均将粉丝基础识别为主要预测信号，并显示内容与上下文特征提供一定增量。

两种重要性的定义与量纲不同，不能直接相加或据此生成未经验证的“综合得分”；不纯度重要性还可能偏向可分裂点较多的变量，排列重要性也会在相关特征间分摊贡献。本轮没有实施 SHAP、Lasso 筛选或将多种重要性归一化后加权，因此不报告相应结果。以上数值用于解释模型的预测依据，不表示改变某一特征会造成同等幅度的热度变化。

Part IV: 基于机器学习的笔记热度分类预测模型

10 基准分类模型 55

10.1 预测问题描述
10.2 逻辑回归
10.3 线性支持向量机
10.4 集成学习模型
10.5 神经网络基准与后续候选
10.6 实证设置与基准结果

11 针对小红书数据特点的模型改进 59

11.1 类别不平衡与代价敏感学习
11.2 阈值优化与概率校准
11.3 特征表达与多模态扩展
11.4 社交传播与时间外验证

12 模型评估、比较与结论 61

12.1 评估口径
12.2 混淆矩阵与错误结构
12.3 综合比较与模型选择
12.4 稳健性、局限与本部分结论



10. 基准分类模型

10.1 预测问题描述

在小红书内容传播效果研究中，一个核心任务是根据发布前可获得的特征判断笔记是否具有较高互动潜力。本文将全体有效样本互动量第 80 百分位作为阈值，把任务定义为“高热度”与“普通热度”的二分类。离散化会损失连续热度信息，却能降低少数极端互动量对平方误差的影响，并直接支持候选内容筛选。模型输出反映预测关联，不等同于加大推广后会产生的因果增量。

10.2 逻辑回归

逻辑回归（Logistic Regression）是二分类问题中常用的线性模型。它假设特征与正类对数几率之间存在线性关系，限制了其捕捉复杂非线性模式的能力，但形式简单、训练高效，适合作为性能基准。标准化后的系数方向可用于描述条件预测关联，但不能直接解释为某一特征变化造成热度变化的因果效应。

- **模型原理**：通过 Sigmoid 函数将特征的线性组合映射到 (0,1) 区间，输出样本属于正类（高热度）的概率。决策边界为线性超平面。
- **优势**：计算速度快，模型参数（系数）直接可解释，能直观看出各特征对结果的正/负向影响及相对强度。
- **局限**：无法自动捕捉特征间复杂的交互作用和非线性关系，对数据线性可分性要求较高。

10.3 线性支持向量机

支持向量机（Support Vector Machine, SVM）通过寻找具有较大分类间隔的超平面实现分类。本轮使用线性 SVM，以便在相同 10 项结构化特征上与逻辑回归比较；没有采用 RBF 核，也没有输入文本向量、图片或多标签高维表示。

- **损失函数**：线性 SVM 使用间隔损失惩罚落入间隔内或被错分的样本，并由正则化参数控制间隔宽度与训练误差之间的权衡。
- **本轮设置**：数值特征经训练集标准化后输入模型，并使用类别权重缓解约 1:4 的类别不平衡。
- **解释边界**：线性决策面不能自动表达复杂交互，其分数主要用于排序；若需要概率，必须另行进行概率校准。

10.4 集成学习模型

集成学习通过组合多个基学习器表达非线性和特征交互。本轮比较随机森林与直方图梯度提升分类器；是否优于线性模型由统一测试集指标判断，而不预先假定。

10.4.1 随机森林

随机森林（Random Forest）通过自助采样（Bootstrap）构建多棵决策树，并综合所有树的投票结果进行分类。其引入的随机特征选择有效降低了模型的方差，防止过拟合。

- **优势**：能表达非线性关系，通常不需要标准化，并可提供基于树分裂的特征重要性。
- **本轮应用**：模型输入仍是粉丝量对数、文本长度、符号计数、情感、星期和位置标记等 10 项特征，不包含封面图或完整文本语义。

10.4.2 梯度提升决策树

梯度提升决策树（Gradient Boosting Decision Trees, GBDT）以串行方式迭代训练弱学习器，每一轮根据当前模型的误差继续改进。本轮采用 scikit-learn 的直方图梯度提升分类器，没有运行 XGBoost 或 LightGBM。

- **优势**：直方图分箱可以降低连续特征分裂搜索的计算成本，模型能够自动表达一定程度的非线性与交互。
- **本轮应用**：该模型在统一测试集上取得最高 PR-AUC 和 ROC-AUC；这一结果只支持当前特征与数据范围内的排序比较，不量化改变某个标签带来的因果提升。

10.5 神经网络基准与后续候选

本轮只在 10 项结构化特征上运行多层感知机。CNN 和 RNN/LSTM 需要稳定对齐的图片、完整文本序列或时间序列，本节保留其方法说明，但不把它们列入数值结果。

10.5.1 多层感知机

多层感知机（Multilayer Perceptron, MLP）是最基本的深度学习模型，由全连接层和非线性激活函数堆叠而成。它可以作为深度学习方法的入门基准，用于验证经过特征工程的

结构化数据是否包含足够预测信息。

- **优势**：能够学习特征间的复杂非线性组合，相比逻辑回归具有更强的表示能力。
- **应用**：可将经过预处理和特征工程的所有数值和类别特征（经过编码后）输入 MLP，作为与其他更复杂深度学习模型对比的基线。

10.5.2 卷积神经网络

卷积神经网络（Convolutional Neural Network, CNN）在图像处理领域取得巨大成功，但其局部感知和参数共享的思想也可应用于一维序列数据。

- **应用**：对于文本数据，可将词嵌入序列视为一维“图像”，使用一维 CNN 来提取短语级别的局部语义特征。对于图像特征，可以直接使用预训练的 CNN（如 ResNet）提取的深度特征向量作为输入的一部分。CNN 能有效捕捉如“标题中的特定关键词组合”或“封面图中同时出现人脸和产品”等局部模式对热度的信号。

10.5.3 循环神经网络

循环神经网络（Recurrent Neural Network, RNN）及其变体长短期记忆网络（LSTM）专门为序列数据设计，能捕捉时间或顺序上的依赖关系。

- **应用**：在小红书笔记分类中，LSTM 可用于建模文本的序列信息（如正文的语义流），或建模用户历史行为序列（如发布者过去笔记的互动趋势）以捕捉其内容质量的时序演变。然而，对于单篇笔记的静态特征分类，LSTM 的优势可能不如 CNN 或 MLP 明显，除非考虑时间上下文（如当前热点话题）。

10.6 实证设置与基准结果

为将上述模型由方案说明落实为可复现实验，本文读取工作区三个业务数据压缩包中的笔记详情表，合并后共得到 323,598 条原始记录。按笔记链接（无链接时按编号、标题和博主）去重并剔除互动指标缺失或为负的记录后，保留 199,473 条有效笔记。互动量定义为“点赞数 + 收藏数 +4× 评论数”，达到全样本第 80 百分位（2,134）的笔记记为高热度，正类比例为 20.01%。建模输入仅使用发布前或内容本身可获得的 10 项特征，包括粉丝量对数、标题和正文长度、标签数、感叹号数、问号数、Emoji 数、情感得分、星期和是否标注发布地；点赞、收藏和评论没有作为输入，以避免目标泄漏。

考虑计算成本，从有效数据中按类别分层抽取 60,000 条用于比较，再按 8:2 分层随机划分训练集与测试集。数值缺失以训练集的中位数填补；逻辑回归、线性 SVM 和 MLP 同时进行标准化。逻辑回归与 SVM 使用类别权重平衡，随机森林使用 300 棵树，梯度提升采用直方图梯度提升分类器，MLP 包含 64 和 32 个神经元的两个隐藏层并使用早停。表10.1报告固定测试集结果。鉴于正类仅占约 20%，模型选择以 PR-AUC 为主，ROC-AUC、F1、精确率和召回率为辅。

梯度提升树的排序能力最佳（PR-AUC=0.440，ROC-AUC=0.736），说明结构化特征与热度之间存在明显的非线性关系；随机森林和 MLP 次之。逻辑回归与线性 SVM 的 PR-AUC 接近，但在类别加权后召回率均约为 0.65，更适合“尽量不漏掉潜在爆款”的初筛场景。

表 10.1: 第 10 章基准分类模型测试集结果

模型	ROC-AUC	PR-AUC	F1	精确率	召回率
逻辑回归	0.700	0.405	0.414	0.303	0.649
线性 SVM	0.700	0.406	0.413	0.302	0.651
随机森林	0.725	0.424	0.373	0.479	0.305
梯度提升树	**0.736**	**0.440**	0.263	**0.600**	0.169
多层感知机	0.718	0.423	0.299	0.562	0.203

梯度提升树默认阈值下精确率最高而召回率较低，若用于候选内容筛选，应在验证集上按业务成本降低分类阈值，而不能只依据默认 0.5 阈值下的 F1 作结论。

本轮完成了 10.1 至 10.5.1 的可运行实证。10.5.2 的 CNN 与 10.5.3 的 RNN/LSTM 未给出数值结果：现有压缩包没有与每条笔记稳定对应的原始图片张量或发布者连续历史序列，直接把静态汇总特征重塑为“图像”或伪序列会制造不具业务含义的结构。虽然正文文本可形成词序列，但在没有独立时间外测试和文本模型调参预算的条件下，其结果不能与本节结构化基准作公平比较。因此本研究保留 CNN 与 RNN 的模型设计说明，待补齐图片、严格的用户历史序列和时间切分后再实施，避免报告不可复现或误导性的深度模型成绩。



11. 针对小红书数据特点的模型改进

第 10 章的实证结果表明，仅使用发布前可获得的结构化特征，模型已经能够形成高于随机排序的有效判别能力，但类别不平衡、特征表达有限和决策阈值固定仍然制约实际效果。本章据此给出与现有数据相匹配的改进方案，并明确哪些方法已经在基准实验中落实、哪些方法需要新增数据后才能实施。

11.1 类别不平衡与代价敏感学习

本研究将互动量位于前 20% 的笔记定义为高热度样本，因此正负样本比例约为 1:4。若仅追求总体准确率，把所有笔记判为普通类即可获得约 80% 的准确率，却完全失去识别爆款的能力。因此，实验没有把准确率作为核心指标，而是以 PR-AUC 衡量少数类的排序质量，并同时报告精确率、召回率与 F1。

在模型训练阶段，逻辑回归和线性 SVM 采用与类别频率成反比的类别权重。该设置使两种线性模型在测试集上的召回率分别达到 0.649 和 0.651，在数值上高于其他模型默认阈值下的召回率，说明代价敏感设置减少了当前测试集中的潜在爆款漏判。不过，召回率的提高伴随着较多假阳性：逻辑回归和线性 SVM 分别产生 3,579 和 3,611 个假阳性样本。因此，这两类模型更适合低成本初筛，而不宜直接用于高成本投放决策。

本研究没有对当前 10 项结构化特征直接使用 SMOTE。其原因是星期、是否标注发布地等变量具有离散语义，简单线性插值可能生成缺乏真实含义的合成样本；同时，过采样若在数据划分前进行，还会造成训练集与测试集之间的信息污染。若后续比较 SMOTE、SMOTEENN 或 EasyEnsemble，应只在每个训练折内部完成重采样，并保持验证集和测试集的原始类别分布。

11.2 阈值优化与概率校准

表10.1中的精确率、召回率和 F1 均基于 0.5 分类阈值，但 0.5 并不是所有业务场景的最优选择。梯度提升树在该阈值下的精确率达到 0.600，召回率却只有 0.169，表明模型给出的高分样本较可靠，但大量真实爆款仍位于阈值以下。相反，类别加权的线性模型召回率较高，却需要承担更高的误报成本。

因此，实际应用应先在独立验证集上确定阈值，再锁定阈值并在测试集报告一次最终结果。若目标是为运营人员生成数量有限的候选清单，可选择较高阈值或直接按预测概率取 Top-K，优先保证精确率；若目标是尽可能覆盖潜在爆款，可降低阈值并为漏判设置更高成本。进一步应用时，还应使用 Platt 缩放或保序回归检查概率校准，使“预测概率为 0.6”具有可解释的实际发生频率，而不仅是排序分数。

11.3 特征表达与多模态扩展

随机森林的重要性结果显示，粉丝量对数的重要性为 0.310，居所有特征首位；情感得分、正文长度和标题长度的重要性依次为 0.181、0.131 和 0.108。四项特征合计贡献约 73% 的重要性，说明发布者基础影响力和内容表达共同决定了现有模型的主要判别信号。标签数、星期和标点符号等特征提供了补充信息，但单独贡献相对有限。

这一结果也揭示了现有特征工程的边界。长度、符号计数和单一情感得分只能描述文本表层形式，无法识别主题、叙事结构、产品实体与图文一致性。后续可采用中文预训练语言模型编码标题和正文，使用 CLIP 或视觉主干网络提取封面及配图特征，再将文本、图像和结构化特征分别建模。数据量有限时可采用晚期融合，即对各模态子模型的概率进行加权或堆叠；拥有稳定配对的大规模图文数据后，再比较带跨模态注意力的中期融合。所有模态必须通过同一笔记的稳定标识关联，无法可靠匹配的图片或文本不得强行并入训练样本。

11.4 社交传播与时间外验证

热度不仅由笔记内容决定，还受到发布者历史表现、粉丝构成和平台阶段性流量的影响。若后续能够获得按时间排序的用户历史，可构造近 7 天、30 天和 90 天的历史互动统计，并确保每条样本只使用其发布时间之前的信息。若能够获得用户---笔记交互边，还可构建二部图并使用 GraphSAGE 等方法学习传播结构表示，但发布后的点赞、收藏和评论边不能用于发布前预测，否则会形成目标泄漏。

当前基准实验采用分层随机划分，适合在固定样本分布下比较算法。为检查这一划分是否高估模型稳定性，本文进一步使用全部有效日期样本进行一次时间外切分，并使用 GroupShuffleSplit 进行博主完全隔离的分组切分。梯度提升树在时间外测试上的 ROC-AUC 和 PR-AUC 分别为 0.739 和 0.457，在博主分组测试上分别为 0.736 和 0.444；分组测试的训练与测试博主重叠数为 0。两组结果与随机切分基准接近，说明当前结构化特征的排序信号并非只来自随机划分或同一博主复用。完整稳健性结果见第 18 章。



12. 模型评估、比较与结论

12.1 评估口径

分类评估以高热度笔记为正类。精确率表示被模型判为高热度的笔记中真实高热度笔记的比例，召回率表示全部真实高热度笔记中被模型识别出的比例，F1 为二者的调和平均。ROC-AUC 衡量随机抽取一条正样本和一条负样本时模型将正样本排在前面的概率；PR-AUC 则聚焦正类，更能反映类别不平衡场景下精确率与召回率的权衡。

测试集包含 12,000 条笔记，其中高热度笔记 2,401 条，正类比例为 20.01%。因此，随机排序的 PR-AUC 基线约为 0.200；五个模型的 PR-AUC 均在 0.405 以上，说明它们均提取到了有效预测信号。与此同时，任何单一阈值下的准确率都可能被 9,599 条负类样本主导，故本研究不以准确率决定最优模型。

12.2 混淆矩阵与错误结构

表 12.1: 不同模型在测试集上的混淆矩阵

模型	TN	FP	FN	TP
逻辑回归	6,020	3,579	842	1,559
线性 SVM	5,988	3,611	838	1,563
随机森林	8,801	798	1,668	733
梯度提升树	9,329	270	1,996	405
多层感知机	9,219	380	1,913	488

表12.1揭示了不同模型的错误偏好。逻辑回归与线性 SVM 识别出的真实爆款最多，真

阳性分别为 1,559 和 1,563，但其假阳性也超过 3,500 条。梯度提升树只有 270 个假阳性，是五个模型中误报最少的，同时漏掉 1,996 条真实爆款。随机森林处于两者之间，真阳性为 733，假阳性为 798。由此可见，不存在脱离业务成本而绝对最优的固定阈值分类器：线性模型偏向覆盖，树模型偏向谨慎。

12.3 综合比较与模型选择

从阈值无关的排序指标看，梯度提升树的 PR-AUC 为 0.440、ROC-AUC 为 0.736，均列第一，应作为结构化特征场景下的首选排序模型。相较正类比例 0.200 的随机基线，其 PR-AUC 提高约 0.240；相较逻辑回归，PR-AUC 提高 0.035，说明非线性关系与特征交互带来了稳定增益。随机森林和多层感知机的 PR-AUC 分别为 0.424 和 0.423，二者接近，但随机森林训练更快且更容易解释，可作为性能与可解释性之间的折中方案。

从默认阈值下的分类结果看，梯度提升树以 0.600 取得最高精确率，适合误报成本较高、候选名额有限的场景；线性 SVM 以 0.651 取得最高召回率，适合漏判成本较高的初筛场景；逻辑回归的 F1 为 0.414，在五个模型中最高，且系数方向便于解释，可作为透明度要求较高的基准决策模型。MLP 没有超过树模型，说明在当前 10 项表格型特征上增加网络复杂度并未转化为更好的泛化性能。

表 12.2: 分类模型的场景化选择建议

应用目标	推荐模型	选择依据
有限名额的精准推荐	梯度提升树	PR-AUC 与 ROC-AUC 最高，默认阈值下精确率最高，可进一步采用 Top-K 输出
潜在爆款的广覆盖初筛	线性 SVM 或逻辑回归	召回率约 0.65，能够找出更多真实爆款，但需接受较高误报率
兼顾性能与解释	随机森林	PR-AUC 达到 0.424，可通过特征重要性说明主要预测依据
概率化运营决策	校准后的梯度提升树	先在验证集完成阈值选择与概率校准，再按误报和漏报成本决策

12.4 稳健性、局限与本部分结论

本轮比较使用相同的 60,000 条分层样本、训练测试划分和 10 项无泄漏特征，模型间横向比较是公平的；数据审计、模型指标、分类报告和特征重要性均可由第 10 章 Notebook 复现。当前结论仍有三项限制：补充的时间外验证只有一个边界，尚不能替代多个滚动窗口；模型尚未纳入完整文本、图像和传播网络；F1、精确率和召回率依赖 0.5 阈值，不能代表调阈后的最佳业务效果。

综合而言，粉丝基础、情感得分和内容长度是现有模型的主要预测信号。梯度提升树排序能力最佳，线性模型覆盖率更高，随机森林则兼顾性能与解释性。本研究由此形成“梯度提升排序、验证集选阈值、场景化输出、时间外复核”的流程。至此，第 10 章完成模型构建，第 11 章完成改进设计，第 12 章完成统一评估与选择，分类模型部分形成闭环。

PartV: 小红书帖子热度预测模型

13 候选模型与基准选择 65

13.1 预测问题描述
13.2 线性回归模型
13.3 候选方法：支持向量回归（SVR）
13.4 本轮采用的树集成模型
13.5 后续候选：深度学习与多模态模型
13.6 其他未验证候选方法

14 扩展模型的数据前提与验证方案 69

14.1 模型架构设计

15 热度回归模型实证 71

15.1 任务定义与数据处理
15.2 模型与评估指标
15.3 基准结果与模型比较
15.4 可解释性、局限与应用建议



13. 候选模型与基准选择

13.1 预测问题描述

本研究把热度回归限定为一个发布前预测问题：只使用内容发布时即可获得的结构化字段，预测点赞、收藏和评论加权得到的连续互动量。该限定排除了发布后早期互动、平台曝光量等会造成目标泄漏或在当前数据中不可得的变量。连续输出可用于候选内容的相对排序，但不能被解释为对单篇笔记最终互动量的确定性承诺。

实际比较包括中位数常数基线，以及普通线性回归、Ridge 回归、随机森林、极端随机树和直方图梯度提升五个学习模型。它们覆盖了可解释的线性关系、带正则化的线性关系和非线性树集成，同时能够在统一的 60,000 条分层样本上完成可复现比较。SVR、XGBoost、LightGBM、LSTM、Transformer 和多模态模型在本轮没有产生数值实验；下文仅将这些方法作为候选方法或后续扩展讨论，不把其理论优势写成当前数据上的实证结论。

13.2 线性回归模型

线性回归模型是回归分析中最基础、最经典的模型。它假设因变量（如帖子点赞数或观看量）与一个或多个自变量（如字数、图片数、tag 数）之间存在线性关系。该模型的优点是形式简单、易于实现和解释，计算效率高，能够快速提供特征与热度之间的边际效应分析。在社交媒体分析领域，线性回归常被用作初步探索变量之间关系的工具，或作为更复杂模型的基准。例如，可以用来量化" 每增加一张图片平均能带来多少额外点赞" 或" 晚间发布相比午间发布的热度差异"。

然而，其最大的局限性在于线性假设，这使其难以捕捉社交媒体数据中普遍存在的非线性关系（如 tag 数量与热度之间可能存在的倒 U 型关系）。此外，线性回归对异常值（如偶然爆红的 viral content）和多重共线性（如粉丝数与历史平均点赞数高度相关）较为敏感，

这可能会影响其预测的准确性和稳健性。尽管如此，由于其简单性和可解释性，线性回归模型仍然是一个重要的基准，可以用来评估更复杂模型在处理非线性问题上的增益，并为特征重要性提供直观的理解。

13.2.1 经典线性模型

普通最小二乘法（OLS）线性回归作为最基础的学习型基准，用于检验 10 项结构化特征能否提供近似线性的预测信号。

13.2.2 正则化线性模型

本轮同时纳入 L2 正则化的 Ridge 回归，用于检查收缩系数后是否能够改善泛化；L1 正则化的 Lasso 未纳入最终数值比较。

13.3 候选方法：支持向量回归（SVR）

支持向量回归（Support Vector Regression, SVR）是支持向量机（SVM）在回归问题上的重要应用，它继承了 SVM 在处理小样本、非线性及高维模式识别问题中的诸多优势。SVR 的核心思想是寻找一个最优的回归函数（或称为超平面），使得所有训练样本点与该函数之间的偏差最小，同时保证模型的泛化能力。其最大的创新在于引入了"ε-不敏感损失函数"（ε-insensitive loss function）。该函数设定了一个宽度为 2ε 的" 容忍带"，只有当预测值与真实值之间的误差超出这个容忍带时，才会计算损失并进行惩罚。这种机制使得模型对容忍带内的小误差不敏感，从而提高了对噪声数据的鲁棒性，并使得模型解具有稀疏性，即只有少数" 支持向量" 对最终的回归函数有贡献。

在小红书热度预测中，SVR 理论上可用于拟合结构化特征与热度之间的非线性关系。不过，核方法在大样本上的训练成本较高，本轮统一实验没有运行 SVR，因此不能据此判断它在当前数据上是否优于线性或树模型。

SVR 模型有三个关键参数需要调优：

- 容忍带宽度 (ε)：ε 决定了对误差的容忍程度。ε 越小，模型对拟合精度的要求越高，可能导致模型复杂、过拟合；ε 越大，模型越简单，但可能欠拟合。在小红书数据中，由于热度分布通常呈现长尾特性，需要谨慎设置以避免对高热度异常值过度敏感。
- 惩罚系数 (C)：C 控制了对超出容忍带的样本的惩罚力度。C 越大，对误差的惩罚越重，模型倾向于将所有样本都拟合好，可能过拟合；C 越小，允许更多的误差，模型泛化能力可能更强。考虑到小红书帖子热度的极端方差，C 的选择需要平衡对 viral content 的拟合能力。
- 核函数 (Kernel Function)：核函数是 SVR 处理非线性问题的关键。通过核技巧，SVR 可以将原始数据映射到更高维的特征空间，从而在新的空间中寻找线性回归函数。常用的核函数包括线性核、多项式核和高斯径向基函数（RBF）核。RBF 核因其良好的性能和普适性，在处理文本、图像混合特征的社交媒体数据中被广泛使用。

如在后续研究中加入 SVR，应在与现有模型完全相同的数据切分和特征口径下调参，并同时报告运行成本与测试集指标。

13.4 本轮采用的树集成模型

集成学习通过组合多个基学习器降低单棵树的方差，或逐步修正残差以拟合非线性关系。随机森林是典型的 Bagging 方法 [8]，梯度提升则按迭代方式拟合前一轮残差。考虑到当前输入仅有 10 项表格型特征，本轮选择随机森林、极端随机树和直方图梯度提升树，避免把不同第三方框架的工程差异混入主要比较。

随机森林通过自助采样和随机特征子集训练多棵树；极端随机树进一步随机化候选切分点。两者都能表达非线性和交互，但特征重要性只表示预测贡献，不能直接解释为因果效应。直方图梯度提升先将连续特征分箱，再逐轮拟合残差，适合在较大表格数据集上控制训练成本。XGBoost 等框架具有成熟的正则化与高效实现 [9]，但本轮未使用，因而不参与结果排名。

13.5 后续候选：深度学习与多模态模型

循环神经网络、卷积神经网络和预训练语言模型能够从序列、图像或文本中学习表示，但采用这些模型的前提是获得与每条笔记稳定对应的原始模态数据。当前数据只有结构化字段和文本摘要，缺少严格对齐的图片张量与发布后时间序列，因此以下内容属于方法储备，不属于本轮实证。

长短期记忆网络（Long Short-Term Memory, LSTM）是一种特殊的 RNN，专门设计用于解决传统 RNN 在处理长序列时面临的梯度消失和梯度爆炸问题。LSTM 通过引入一个精巧的门控机制（包括输入门、遗忘门和输出门）来控制信息流，使其能够有选择地记忆和遗忘信息，从而有效地捕捉时间序列中的长期依赖关系。在小红书热度预测中，LSTM 可以用于建模用户互动的时间动态，例如，基于发布后 1 小时、2 小时、6 小时的点赞/收藏序列，预测 24 小时后的最终热度。这种早期热度序列往往包含了内容质量的重要信号。

卷积神经网络（Convolutional Neural Network, CNN）在图像识别领域取得了巨大成功，其强大的局部特征提取能力也被成功应用于文本分析（TextCNN）。在小红书场景下，TextCNN 可以通过不同大小的卷积核捕捉标题和正文中的局部语义特征（如关键词组合、情感表达模式），有效识别" 爆款标题" 的文本模式。对于图像数据，可以使用预训练的 CNN（如 ResNet, VGG）提取视觉特征，评估图片质量、美学得分和内容相关性。

预训练语言模型（BERT, RoBERTa）通过大规模语料预训练，能够深度理解小红书文本内容的语义和上下文信息。利用 BERT 对标题和正文进行编码，可以获得高质量的文本表征，捕捉隐含的情感倾向、话题类别和写作风格，这些都是影响热度的重要因素。

此外，可以构建多模态融合模型（Multi-modal Fusion），将文本特征（BERT）、视觉特征（CNN）和结构化特征（元数据）在特征层或决策层进行融合，全面捕捉影响热度的多维度因素。

13.5.1 时序深度学习模型：LSTM/GRU

若未来能够获得发布后前 N 小时的连续互动快照，可比较 LSTM/GRU 与简单增长曲线基线；这将属于“发布后早期预测”，必须与本文的“发布前预测”任务分开报告。

13.5.2 文本深度学习模型：BERT + TextCNN

完整标题和正文可用于比较 BERT 编码、TextCNN 和词袋基线。只有在固定数据切分上证明其测试集增益后，才能认为深层语义特征为结构化基准提供了额外信息。

13.6 其他未验证候选方法

13.6.1 宽度学习系统（Broad Learning System, BLS）

宽度学习是一种新兴的平坦神经网络架构，通过随机生成特征节点和增强节点，利用伪逆快速计算输出权重，具有训练速度极快、结构灵活的特点。在小红书实时热度预测场景中，BLS 可以作为快速基准模型，支持模型的在线更新和增量学习。

13.6.2 生存分析模型（Survival Analysis）

考虑到部分小红书帖子可能长期持续获得流量（" 长尾内容"），而另一些则快速衰减，可以引入生存分析中的 Cox 比例风险模型或 AFT（Accelerated Failure Time）模型，不仅预测总热度，还预测热度的持续时间和衰减速度，为评估内容的长期价值提供依据。



14. 扩展模型的数据前提与验证方案

本章记录多模态融合、用户行为动态建模和上下文感知等扩展方向。它们尚未在当前数据上实现，不能与下一章的结构化基准共享“已完成”状态。每一种扩展都需要先补齐输入数据，再在相同切分上与现有基准比较。

14.1 模型架构设计

模型扩展应首先服务于可检验的问题：新增模态是否在严格测试集上提供独立增益，增益是否能够跨时间与跨博主保持。只有回答这些问题后，预测分数才适合进入受控的决策支持流程。

可检验的候选方向包括：

- 多模态深度融合：现有的多模态方法通常采用简单的特征拼接或浅层融合。我们将探索更先进的融合机制，如基于注意力机制的多模态融合（Attention-based Fusion）、跨模态 Transformer（Cross-modal Transformer），让模型自动学习文本、图像、时间、空间特征之间的复杂交互关系。例如，模型可以学习到" 美食类内容在晚间配合高饱和度图片效果更佳" 这样的隐性规则。
- 图神经网络（GNN）应用：构建用户-内容-标签的异构图网络，利用图神经网络捕捉社交关系、内容相似性和标签共现关系。通过消息传递机制，模型可以借鉴相似内容的历史表现，或利用用户的社交影响力来修正热度预测，解决冷启动问题。
- 多任务学习框架：不同于单一预测观看量或点赞数，我们将构建多任务学习模型，同时预测多个热度指标（观看量、点赞数、收藏数、评论数、分享数）。通过共享表征层，模型可以学习到不同互动行为之间的内在关联（如" 高收藏内容通常评论较少但转化率较高"），提高整体预测精度。

- 时序卷积网络（TCN）与 Transformer：引入 Temporal Convolutional Network 和 Transformer 架构替代 LSTM，利用其并行计算优势和长距离依赖捕捉能力，更有效地建模热度传播的时间动态，特别是捕捉突发流量和病毒式传播模式。
- 因果推断集成：结合因果推断方法（如双重机器学习、倾向得分匹配），不仅预测相关性，还尝试识别因果关系，区分" 因为发布了某类内容所以热门" 和" 因为账号本身有影响力所以热门"，为内容策略提供更 robust 的建议。

策略融合方面，我们将探索如何将回归预测模型的输出直接转化为内容优化策略。例如：

- 实时发布决策支持：构建一个策略系统，当模型预测某篇草稿在特定时间、搭配特定标签发布能获得更高热度时，向创作者推荐最佳发布时机和标签组合。
- A/B 测试优化：模型可以帮助筛选待测试的标题或封面版本，但离线预测不能替代随机 A/B 测试；真实增量效果仍须通过受控实验估计。
- 动态流量分配：对于品牌方和 MCN 机构，预测模型可以用于评估不同 KOL 的内容投放效果，优化广告预算分配，识别潜在的高性价比投放对象。
- 内容冷启动策略：针对新账号或新内容，利用预测模型识别" 潜力内容"，建议平台给予初始流量扶持，提高优质内容的发现效率。

上述方案只有在数据完整性、时间外泛化和增量实验均通过验证后，才可视为对当前结构化基准的有效扩展。下一章先报告已经完成且可以复现的回归实验。



15. 热度回归模型实证

15.1 任务定义与数据处理

为将前述方案落实为可复现实验，本章将笔记热度定义为连续互动量

$$y = \text{点赞数} + \text{收藏数} + 4 \times \text{评论数}. \tag{15.1}$$

评论被赋予较高权重，是因为其参与成本和互动深度通常高于点赞与收藏。该定义与分类模型部分保持一致，但不再把第 80 百分位以上样本离散化为高热度类别，而是直接预测连续数值。

实验读取三个业务数据压缩包中的笔记详情表，共得到 323,598 条原始记录。按笔记链接去重；无有效链接时，按编号、标题和博主组合去重，并剔除互动指标缺失或为负的记录，最终保留 199,473 条有效笔记。热度中位数为 346，均值为 3,298.21，第 80 百分位为 2,134，第 95 百分位为 12,755，最大值达到 1,711,417。均值约为中位数的 9.5 倍，最大值又远高于第 95 百分位，表明目标分布具有显著右偏和长尾特征。

输入沿用分类模型部分的 10 项发布前特征：粉丝量对数、标题长度、正文长度、标签数、感叹号数、问号数、Emoji 数、情感得分、星期和是否标注发布地。点赞、收藏和评论没有作为输入，从而避免目标泄漏。为控制不同模型的计算成本，本文按对数热度的十分位分层抽取 60,000 条样本，再以 8:2 划分训练集和测试集，得到 48,000 条训练样本和 12,000 条测试样本。缺失值填补及标准化参数均只在训练集拟合。

15.2 模型与评估指标

由于直接拟合原始热度会使少数极端爆款支配平方损失，本章令所有有效模型学习 $\log(1+y)$，预测后使用 $\exp(\hat{y})-1$ 还原并将负预测截断为 0。比较模型包括中位数基线、普通线性回归、Ridge 回归、随机森林、极端随机树（Extra Trees）和直方图梯度提升树。

评估同时覆盖绝对误差、相对误差和排序能力。MAE 与 RMSE 在原始互动量尺度计算；RMSLE 衡量对数量级的预测误差，降低极端值的支配；R^2 衡量模型对原始热度方差的解释比例；Spearman 相关系数衡量预测排序与真实排序的一致性。运营筛选能力使用 Top 20% 召回率衡量，即预测热度排名前 20% 的笔记覆盖了多少真实热度排名前 20% 的笔记。鉴于长尾分布，本研究以 RMSLE 作为主要误差指标，以 Spearman 和 Top 20% 召回率作为重要辅助指标，而不依据单一 RMSE 选型。

15.3 基准结果与模型比较

表 15.1: 热度回归模型测试集结果

模型	MAE	RMSE	RMSLE	R^2	Spearman	Top 20% 召回
中位数基线	3,262.81	19,937.17	2.230	-0.023	–	0.194
线性回归	3,149.12	19,797.46	1.936	-0.009	0.463	0.407
Ridge	3,149.13	19,797.52	1.936	-0.009	0.463	0.407
随机森林	3,124.55	**19,666.20**	1.866	**0.004**	0.506	0.424
Extra Trees	3,125.54	19,698.07	1.862	0.001	0.509	**0.429**
梯度提升树	**3,119.22**	19,729.95	**1.849**	-0.002	**0.515**	**0.429**

表15.1显示，五个学习模型的 RMSLE 均优于中位数基线，说明发布前结构化特征包含稳定的热度信号。梯度提升树的 RMSLE 最低，为 1.849，相比中位数基线下降约 17.1%；其 Spearman 相关系数也最高，为 0.515，说明非线性模型对笔记相对热度具有中等强度的排序能力。该模型在严格取预测排名前 20% 时覆盖 42.9% 的真实高热笔记，显著高于无信息排序约 20% 的期望水平。Extra Trees 与梯度提升树的 Top 20% 召回率相同，RMSLE 略高；随机森林取得最低 RMSE 和唯一为正的 R^2，但其 RMSLE 和排序指标略逊于梯度提升树。

线性回归与 Ridge 的结果几乎相同，表明当前 10 项特征中的多重共线性并非线性模型的主要瓶颈；更关键的问题是特征与热度之间存在非线性关系和交互效应。树模型在 RMSLE、Spearman 和 Top 20% 召回率上均优于线性模型，支持这一判断。

15.4 可解释性、局限与应用建议

基于最佳梯度提升树的测试集排列重要性显示，粉丝量对数最重要，打乱该特征会使对数误差增加 2.620；星期、正文长度、情感得分和是否标注发布地的重要性均值分别为 0.154、0.136、0.136 和 0.105。标签数、标题长度、Emoji 数和感叹号数提供较弱的补充信息，问号数的重要性接近 0。该结果说明发布者已有影响力仍是热度预测的首要信号，但内容表达、发布时间和位置元数据共同提供了可利用的增量信息。排列重要性反映预测贡献而非因果效应，不能据此断言增加正文长度或选择某一星期发布必然提高热度。

需要审慎解释接近 0 的原始尺度 R^2。虽然最佳模型显著改善了 RMSLE 与排序能力，

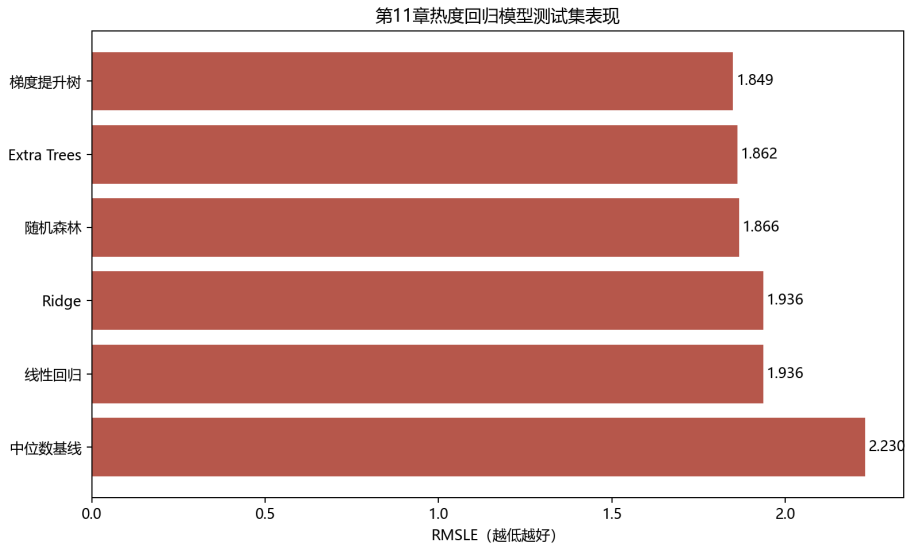


图 15.1: 不同热度回归模型的 RMSLE 比较

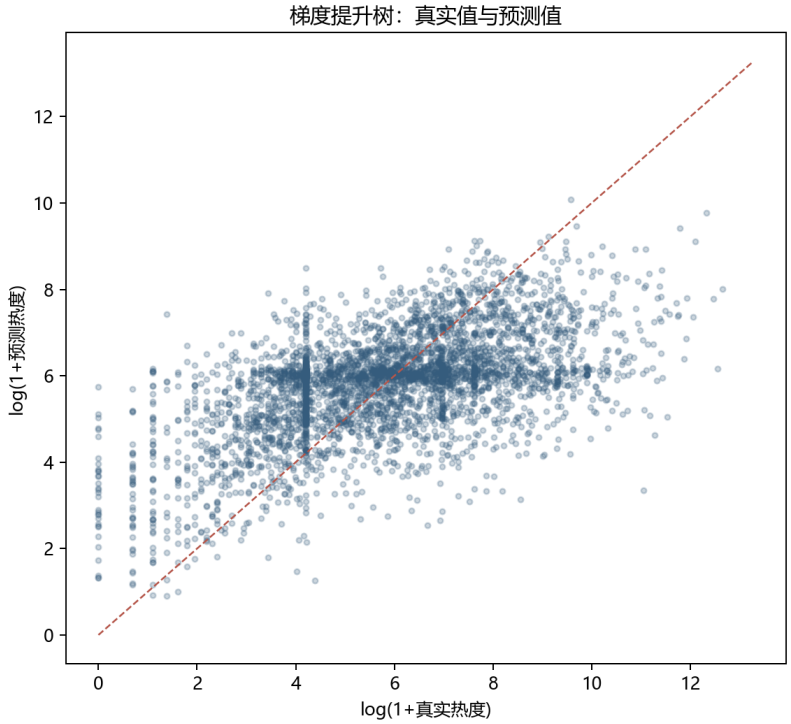


图 15.2: 梯度提升树在对数尺度上的真实热度与预测热度

但仍无法解释极端爆款造成的大部分原始方差。平台临时流量分配、突发热点、站外传播和早期互动速度没有包含在现有发布前特征中，而这些因素可能决定最极端的传播结果。因此，本模型适合用于发布前的相对热度排序、候选内容筛选和资源粗分配，不适合把单条笔记的点预测视为确定性承诺。

补充稳健性实验使用全部有效日期样本进行一次时间外切分，并按博主进行完全隔离的分组切分。梯度提升树在两种切分下的 RMSLE 分别为 1.744 和 1.827，Spearman 相关系数均约为 0.532，且与随机切分基准相当；原始尺度 R^2 仍接近 0。该结果增强了相对排序结论的可信度，但没有改变绝对量预测能力有限的判断。后续仍应采用多个滚动时间窗口复核稳定性；在获得稳定配对的原始图片、完整文本语义表示和发布者历史序列后，再比较 BERT、视觉编码器及多模态融合模型。综合本轮结果，推荐使用梯度提升树进行发布前排序，并在验证集按候选名额选择 Top-K；对极端爆款的绝对量预测则应输出区间或分位数，而不是单一点估计。

VI

Part VI: 统一实验总结

16 统一实验设置 77

16.1 数据口径与任务划分

16.2 评价原则与复现材料

17 分类与回归结果的统一比较 79

17.1 分类任务：排序、覆盖与误报的权衡

17.2 回归任务：相对排序优于绝对量预测

17.3 跨任务一致的特征信号

18 有效性边界与后续验证 81

18.1 本轮实际完成范围

18.2 时间外与博主分组验证

18.3 内部与外部有效性限制

18.4 下一轮验证顺序

16. 统一实验设置

16.1 数据口径与任务划分

本研究的实证部分使用相同的数据清洗规则和发布前特征完成分类与回归两项任务。三个业务数据压缩包共提供 323,598 条原始记录；按笔记链接去重，在链接缺失时按编号、标题和博主组合去重，并剔除互动指标缺失或为负的记录后，得到 199,473 条有效笔记。两项任务均从有效样本中分层抽取 60,000 条记录，并使用固定随机种子划分 48,000 条训练样本和 12,000 条测试样本。

统一热度指标定义为

$$y = \text{点赞数} + \text{收藏数} + 4 \times \text{评论数}. \tag{16.1}$$

分类任务将全体有效样本中热度达到第 80 百分位（2,134）的笔记记为高热度，正类比例为 20.01%；回归任务直接预测连续热度，并在训练时对目标使用 $\log(1+y)$ 变换，以减弱极端长尾样本对平方损失的支配。

输入统一为 10 项发布前可获得的结构化特征：粉丝量对数、标题长度、正文长度、标签数、感叹号数、问号数、Emoji 数、情感得分、星期和是否标注发布地。点赞、收藏、评论及其派生量均未进入输入特征，从而避免将目标本身泄漏给模型。缺失值填补和标准化参数只在训练集上拟合。

16.2 评价原则与复现材料

分类任务以 PR-AUC 为主要排序指标，并同时报告 ROC-AUC、精确率、召回率和 F1。回归任务以 RMSLE 为主要误差指标，并辅以 MAE、RMSE、R^2、Spearman 相关系数和 Top 20% 召回率。选择这些指标的原因是，分类正类只占约 20%，而连续热度具有明显右偏和长尾；在这两种情况下，仅依据准确率或原始尺度 RMSE 都可能给出片面的结论。

第 10 章 Notebook 记录了分类模型的数据审计、测试集指标、分类报告和随机森林特征重要性；热度回归 Notebook 记录了对应的数据审计、模型指标、排列重要性以及最佳模型逐条预测。实验表格均由这些机器可读输出整理，不使用没有代码和结果文件支持的多模态、消融或统计显著性数值。



17. 分类与回归结果的统一比较

17.1 分类任务：排序、覆盖与误报的权衡

分类实验表明，梯度提升树的 PR-AUC 和 ROC-AUC 分别为 0.440 和 0.736，均为五个模型中的最高值，适合作为候选笔记排序模型。随机森林与多层感知机的 PR-AUC 分别为 0.424 和 0.423，说明在当前 10 项表格型特征上，增加神经网络复杂度没有带来优于树模型的泛化效果。

固定 0.5 阈值下，不同模型呈现明显的业务取舍。梯度提升树的精确率最高，为 0.600，但召回率只有 0.169；线性 SVM 的召回率最高，为 0.651，但精确率为 0.302。逻辑回归取得最高 F1（0.414）。因此，有限名额的精准推荐更适合使用梯度提升树或 Top-K 排序，广覆盖初筛更适合使用类别加权的线性模型。表10.1和表12.1给出了完整指标与混淆矩阵。

17.2 回归任务：相对排序优于绝对量预测

回归实验中，梯度提升树取得最低 RMSLE（1.849）和最高 Spearman 相关系数（0.515），其 Top 20% 召回率为 0.429；Extra Trees 取得相同的 Top 20% 召回率，RMSLE 略高，为 1.862。随机森林取得最低 RMSE 和唯一为正的 R^2，但 R^2 也只有 0.004。完整结果见表15.1。

这些结果说明，结构化发布前特征能够有效改善热度数量级判断和相对排序，却无法解释极端爆款造成的大部分原始方差。模型的合理用途是候选内容排序和资源粗分配，而不是对单篇笔记给出确定性的互动量承诺。若业务必须给出绝对量，应进一步采用分位数回归或预测区间，并报告区间覆盖率。

17.3 跨任务一致的特征信号

分类随机森林的重要性和回归梯度提升树的排列重要性都将粉丝量对数列为首要特征。正文长度、标题长度、情感得分、星期和位置标记在两项任务中提供了不同程度的补充信息。这种跨任务一致性说明，发布者既有影响力是当前数据中最稳定的预测信号，内容表达与发布时间则贡献增量信息。

需要强调的是，特征重要性衡量预测贡献而非因果效应。粉丝量较高与热度较高同时出现，不等于单纯增加粉丝数就会以相同比例提高某一篇笔记的互动；正文长度、情感和星期等变量也可能与账号类型、内容主题及平台流量机制共同变化。因此，本研究的结果适合支持风险可控的候选排序，不应被解释为确定性的运营因果规则。



18. 有效性边界与后续验证

18.1 本轮实际完成范围

本轮实证已经完成结构化特征上的五个分类模型和五个学习型回归模型，并提供可执行 Notebook 与机器可读结果。CNN、RNN/LSTM、BERT、图网络、多模态融合、多任务学习和消融实验没有纳入数值比较。现有数据缺少与每条笔记稳定对应的原始图片张量、严格按时间排列的发布者历史序列和用户---笔记传播边；在这些条件不满足时构造伪图像、伪序列或伪传播图，会引入缺乏业务含义的结构并削弱结论可信度。

因此，本报告将深度文本、视觉和传播模型保留为后续研究方案，而不宣称其已经取得性能提升。只有在补齐输入数据、固定训练与测试口径并保存完整实验输出后，才能将这些模型加入与当前基准的公平比较。

18.2 时间外与博主分组验证

为检验随机切分的乐观偏差，本文补充两种划分。时间外切分将 199,075 条具有有效发布日期的样本按时间排序，以接近前 80% 的数据训练、其余数据测试，并确保同一个自然日不会跨越两个集合；训练期截至 2024 年 7 月 22 日，测试期从 2024 年 7 月 23 日延续至 2024 年 10 月 14 日。博主分组切分使用 199,467 条具有有效博主名称的样本，按博主整体分配至训练或测试集合，测试集中 24,568 名博主均未出现在训练集。

表18.1显示，两种严格切分下的 ROC-AUC 和 PR-AUC 均与随机切分基准接近。默认阈值下召回率仍然偏低，进一步说明排序分数、Top-K 输出和验证集阈值选择比机械使用 0.5 阈值更适合实际应用。

表18.2进一步表明，两个严格测试集上的 Spearman 相关系数均超过 0.53，RMSLE 没有劣于随机切分基准；但原始尺度 R^2 仍接近 0。由此可以较有把握地认为模型具有跨时间

表 18.1: 梯度提升分类模型的稳健性验证

切分方式	测试样本	正类比例	ROC-AUC	PR-AUC	Recall
时间外切分	40,412	0.233	0.739	0.457	0.201
按博主分组	39,850	0.200	0.736	0.444	0.180

表 18.2: 梯度提升回归模型的稳健性验证

切分方式	测试样本	RMSLE	R^2	Spearman	Top 20% 召回
时间外切分	40,412	1.744	-0.013	0.532	0.409
按博主分组	39,850	1.827	0.002	0.532	0.433

和跨博主的相对排序信号，同时仍不能准确解释极端互动量。

18.3 内部与外部有效性限制

补充验证降低了随机切分和博主复用导致的内部有效性疑虑，但当前时间外实验仍只是单一时间边界，尚未覆盖平台规则变化、季节效应和多个滚动窗口；按博主分组也不能排除同一机构控制多个账号等不可观测关联。因此，这些结果增强了稳健性证据，却仍不是上线后的无偏性能保证。

数据还缺少平台曝光量、推荐流量、站外传播、热点生命周期和发布后早期互动速度。它们可能决定极端爆款，却无法从当前 10 项发布前特征中恢复。样本主要来自美妆和家电领域，结论能否迁移到旅行、教育或本地生活等领域也仍需独立验证。

18.4 下一轮验证顺序

后续工作应将当前单次时间切分扩展为多个滚动窗口，并在独立验证集完成阈值选择和概率校准，再锁定流程并只在对应测试窗口评估一次。完成这些基础验证后，才应依次加入文本语义、图片和发布者历史特征。每次扩展都应与相同数据切分下的结构化基准比较，并通过消融实验确认新增信息的独立贡献。

在当前证据范围内，推荐的应用流程是“梯度提升排序、验证集选择阈值或 Top-K、按业务成本输出候选、定期进行时间外复核”。这一流程与现有数据能力相匹配，也为未来更复杂的多模态模型提供了可复现基线。

VII

Part VII: 结论与展望

19 研究结论 85
19.1 主要发现
19.2 实践含义

20 研究局限与未来工作 87
20.1 研究局限
20.2 未来工作
20.3 总结



19. 研究结论

19.1 主要发现

本研究围绕小红书笔记热度的影响因素与发布前预测展开分析，形成了从数据清洗、探索性分析、特征构造到分类和回归建模的完整流程。三个业务数据压缩包共包含 323,598 条原始记录，经统一去重和有效性检查后保留 199,473 条笔记。研究使用“点赞数 + 收藏数 +4× 评论数”衡量互动热度，并以 10 项不包含发布后互动的结构化特征完成两类预测任务。

探索性分析与模型结果共同表明，发布者粉丝基础是最稳定的热度信号；内容长度、情感表达、标签、发布时间和位置元数据提供了较弱但可利用的增量信息。部分变量与热度之间存在非线性关系，因此树模型整体上比线性模型具有更好的排序能力。不过，这些关系来自观察数据，只能解释为统计关联和预测信号，不能直接推断为因果效应。

分类任务中，梯度提升树取得最高 PR-AUC（0.440）和 ROC-AUC（0.736），适合对潜在高热度笔记排序；线性 SVM 取得最高召回率（0.651），适合低成本的广覆盖初筛；逻辑回归取得最高默认阈值 F1（0.414），可作为易解释基准。回归任务中，梯度提升树取得最低 RMSLE（1.849）、最高 Spearman 相关系数（0.515）和 0.429 的 Top 20% 召回率。接近 0 的原始尺度 R^2 同时说明，当前模型能够改善相对排序，却难以准确预测极端爆款的绝对互动量。

19.2 实践含义

在现有证据范围内，模型更适合充当内容决策的辅助排序工具，而不是自动化承诺工具。对于候选名额有限的运营场景，可使用梯度提升树按预测分数输出 Top-K；对于不希望漏掉潜在爆款的初筛场景，可使用类别加权的线性模型，并由人工或第二阶段模型处理较

多的假阳性。任何阈值都应在独立验证集上根据误报与漏报成本确定，不能机械采用 0.5。

特征重要性可帮助识别值得进一步分析的方向，但不应被转写为“增加正文长度必然提高热度”等确定性建议。更稳妥的做法是将模型发现用于提出运营假设，再通过随机实验、准实验或严格的时间外回测验证其效果。



20. 研究局限与未来工作

20.1 研究局限

第一，本文虽已完成一次时间外切分和一次博主完全隔离的分组切分，但尚未使用多个滚动时间窗口检验平台规则与季节变化。第二，输入主要是文本表层和账号结构化特征，没有稳定配对的图片、完整文本语义、曝光量、传播网络与早期互动序列。第三，样本集中于美妆和家电领域，跨领域泛化能力尚未验证。第四，互动热度是研究构造指标，评论权重取 4 具有业务解释，但仍需通过敏感性分析检验不同权重下结论是否稳定。

此外，极端爆款受到平台临时流量、突发热点和站外传播影响，这些信息在当前数据中不可观测。因而，模型对数量级和排序的改善不能消除社交媒体传播本身的高度不确定性。

20.2 未来工作

近期工作应把现有单次时间外验证扩展为多个滚动窗口，并继续完成阈值优化、概率校准和跨领域性能比较。对于回归任务，可进一步比较分位数回归、Tweedie 损失或两阶段模型，为长尾热度提供区间预测。

在数据条件允许后，可使用中文预训练语言模型提取标题与正文语义，使用视觉编码器提取封面和配图特征，并在稳定笔记标识下进行晚期融合。若能够获得严格按时间排序的发布者历史和用户---笔记交互边，可进一步研究时序模型与图网络。所有新增模型都应在相同的数据切分和无泄漏约束下与当前结构化基准比较，并保留可执行 Notebook、环境说明和机器可读结果。

20.3 总结

本研究结果表明，有限的发布前结构化特征已经能够为小红书笔记热度提供优于随机基线的排序信息，但对极端传播结果的解释能力仍然有限。相比追求未经验证的复杂模型，更可靠的路径是先建立可复现基准、明确使用边界，再通过时间外验证和新增模态逐步扩展。由此形成的研究框架既能够支持当前的内容筛选任务，也为后续多模态和动态传播研究保留了清晰接口。

参考文献

[1] Xiaohongshu Open Platform, “Why choose xiaohongshu,” https://ad-market.xiaohongshu.com/, 2026, official platform metrics; accessed 2026-10-02. 11

[2] J. Berger and K. L. Milkman, “What makes online content viral?” *Journal of Marketing Research*, vol. 49, no. 2, pp. 192–205, 2012. 11, 12

[3] L. de Vries, S. Gensler, and P. S. H. Leeflang, “Popularity of brand posts on brand fan pages: An investigation of the effects of social media marketing,” *Journal of Interactive Marketing*, vol. 26, no. 2, pp. 83–91, 2012. 11, 12

[4] I. Pletikosa Cvijikj and F. Michahelles, “Online engagement factors on Facebook brand pages,” *Social Network Analysis and Mining*, vol. 3, no. 4, pp. 843–861, 2013. 11, 12

[5] E. Bakshy, J. M. Hofman, W. A. Mason, and D. J. Watts, “Everyone’s an influencer: Quantifying influence on Twitter,” in *Proceedings of the Fourth ACM International Conference on Web Search and Data Mining*. Association for Computing Machinery, 2011, pp. 65–74. 11, 12

[6] A. Khosla, A. Das Sarma, and R. Hamid, “What makes an image popular?” in *Proceedings of the 23rd International Conference on World Wide Web*. Association for Computing Machinery, 2014, pp. 867–876. 12

[7] T. Baltrušaitis, C. Ahuja, and L.-P. Morency, “Multimodal machine learning: A survey and taxonomy,” *IEEE Transactions on Pattern Analysis and Machine Intelligence*, vol. 41, no. 2, pp. 423–443, 2019. 12, 13

[8] L. Breiman, “Random forests,” *Machine Learning*, vol. 45, no. 1, pp. 5–32, 2001. 13, 67

[9] T. Chen and C. Guestrin, “XGBoost: A scalable tree boosting system,” in *Proceedings of the 22nd ACM SIGKDD International Conference on Knowledge Discovery and Data Mining*. Association for Computing Machinery, 2016, pp. 785–794. 13, 67

[10] S. Hochreiter and J. Schmidhuber, “Long short-term memory,” *Neural Computation*, vol. 9, no. 8, pp. 1735–1780, 1997. 13

[11] K. He, X. Zhang, S. Ren, and J. Sun, “Deep residual learning for image recognition,” in *2016 IEEE Conference on Computer Vision and Pattern Recognition*. IEEE, 2016, pp. 770–778. 13

[12] Z. Wu, S. Pan, F. Chen, G. Long, C. Zhang, and P. S. Yu, “A comprehensive survey on graph neural networks,” *IEEE Transactions on Neural Networks and Learning Systems*, vol. 32, no. 1, pp. 4–24, 2021. 13

[13] G. Szabó and B. A. Huberman, “Predicting the popularity of online content,” *Communications of the ACM*, vol. 53, no. 8, pp. 80–88, 2010. 13

[14] R. Kohavi, R. Longbotham, D. Sommerfield, and R. M. Henne, “Controlled experiments on the web: Survey and practical guide,” *Data Mining and Knowledge Discovery*, vol. 18, no. 1, pp. 140–181, 2009. 13

[15] L. Li, W. Chu, J. Langford, and R. E. Schapire, “A contextual-bandit approach to personalized news article recommendation,” in *Proceedings of the 19th International Conference on World Wide Web*. Association for Computing Machinery, 2010, pp. 661–670. 14

[16] S. Wager and S. Athey, “Estimation and inference of heterogeneous treatment effects using random forests,” *Journal of the American Statistical Association*, vol. 113, no. 523, pp. 1228–1242, 2018. 14