小红书帖子热度研究报告

数据分析与预测模型实证研究

研究主题：小红书笔记热度影响因素分析与发布前预测

研究范围：数据清洗、探索性分析、分类模型、回归模型与可解释性分析

复现说明：数据、Notebook、机器可读实验输出与报告源码均按项目目录归档。

Contents

I Part I: 研究背景与文献综述

1 研究背景与文献综述 11

1.1 研究背景与意义 11

1.2 国内外研究现状 12

1.2.1 社交媒体内容传播与影响力研究综述 12

1.2.2 多模态社交媒体数据分析方法 12

1.3 内容热度预测与广告效果优化方法 13

II Part II: 小红书数据获取与数据处理

2 数据获取与来源 17

2.1 数据来源 17

2.1.1 主要数据源：小红书平台 17

2.1.2 数据领域划分方式 18

2.1.3 辅助数据源说明 20

2.2 数据采集方法 20

2.2.1 采集工具与框架 21

2.2.2 采集流程设计 23

2.2.3 反爬策略与伦理考量 23

2.3 数据描述与特征工程 24
2.3.1 时间特征构建 . . . 24
2.3.2 互动行为特征 . . . 24
2.3.3 发布地点特征 . . . 25
2.3.4 标签特征 . . . 25
2.4 数据预处理与清洗 25
2.4.1 异常与冗余数据清理 . . . 25
2.4.2 缺失值处理策略 . . . 25
2.4.3 特征编码与一致性控制 . . . 25

III Part III: 小红书笔记多维度数据分析与探索

3 笔记内容质量分析 . . . 29
3.1 文本内容深度与可读性分析 29
3.1.1 变量构建与样本处理 . . . 29
3.1.2 文本长度与互动关系 . . . 29
3.1.3 文本情感与互动关系 . . . 30
3.1.4 互动分布特征 . . . 31
3.1.5 非线性趋势识别 . . . 32
3.1.6 回归结果与稳健性检验 . . . 32
3.1.7 分组分析 . . . 32
3.1.8 情感分组结果 . . . 33
3.2 主题相关性与信息价值分析 33
3.2.1 变量构建与共线性修正 . . . 33
3.2.2 信息价值回归结果与检验 . . . 34
3.2.3 信息密度的“干货溢价”效应 . . . 34
3.2.4 预期偏差与“悬念留白”机制 . . . 35
3.2.5 信息分布的可视化特征 . . . 35

4 笔记形式与视觉呈现分析 . . . 37
4.1 多媒体内容分析 37
4.2 排版与格式分析 37

5 发布者影响力与社交网络分析 . . . 39
5.1 发布者基础影响力分析 39
5.2 发布者内容垂直度与粉丝画像（模拟）分析 40

6 发布时机与上下文分析 41
6.1 时间节律：基于周周期的注意力波动分析 41
6.2 制度性节点冲击：节假日与调休制度的异象 42
6.3 空间格局：地域数字文化的非对称扩张 43

7 标签策略与话题热度分析 45
7.1 标签使用策略分析 45
7.2 话题借势与热点响应分析 46

8 多维度相关性分析 47
8.1 特征间相关性分析 47
8.2 特征与目标变量相关性分析 48
8.3 非线性关系探索 50

9 特征选择与重要性评估 53
9.1 基于统计检验的初步筛选 53
9.2 基于机器学习模型的特征重要性评估 53

IV Part IV: 基于机器学习的笔记热度分类预测模型

10 基准分类模型 57
10.1 预测问题描述 57
10.2 逻辑回归 57
10.3 支持向量机 58
10.4 集成学习模型 58
10.4.1 随机森林 58
10.4.2 梯度提升决策树 58
10.5 深度学习模型 59
10.5.1 多层感知机 59
10.5.2 卷积神经网络 59
10.5.3 循环神经网络 59
10.6 实证设置与基准结果 59

11 针对小红书数据特点的模型改进 61
11.1 类别不平衡与代价敏感学习 61
11.2 阈值优化与概率校准 62

11.3 特征表达与多模态扩展 62
11.4 社交传播与时间外验证 62

12 模型评估、比较与结论 63
12.1 评估口径 63
12.2 混淆矩阵与错误结构 63
12.3 综合比较与模型选择 64
12.4 稳健性、局限与本部分结论 64

V PartV: 小红书帖子热度预测模型

13 基准模型 67
13.1 预测问题描述 67
13.2 线性回归模型 68
13.2.1 经典线性模型 68
13.2.2 正则化线性模型 68
13.3 支持向量回归（SVR） 68
13.4 集成学习模型（Random Forest, XGBoost, LightGBM） 69
13.4.1 树集成模型一：Random Forest 70
13.4.2 树集成模型二：XGBoost/LightGBM 70
13.5 深度学习模型（LSTM, TextCNN, BERT） 70
13.5.1 时序深度学习模型：LSTM/GRU 71
13.5.2 文本深度学习模型：BERT + TextCNN 71
13.6 其他模型 71
13.6.1 宽度学习系统（Broad Learning System, BLS） 71
13.6.2 生存分析模型（Survival Analysis） 71

14 改进模型设计方案 73
14.1 模型架构设计 73

15 热度回归模型实证 75
15.1 任务定义与数据处理 75
15.2 模型与评估指标 75
15.3 基准结果与模型比较 76
15.4 可解释性、局限与应用建议 76

VI Part VI: 统一实验总结

16 统一实验设置 81
16.1 数据口径与任务划分 81
16.2 评价原则与复现材料 81

17 分类与回归结果的统一比较 83
17.1 分类任务：排序、覆盖与误报的权衡 83
17.2 回归任务：相对排序优于绝对量预测 83
17.3 跨任务一致的特征信号 84

18 有效性边界与后续验证 85
18.1 本轮实际完成范围 85
18.2 内部与外部有效性限制 85
18.3 下一轮验证顺序 86

VII Part VII: 结论与展望

19 研究结论 89
19.1 主要发现 89
19.2 实践含义 89

20 研究局限与未来工作 91
20.1 研究局限 91
20.2 未来工作 91
20.3 总结 92

Part I: 研究背景与文献综述

1 研究背景与文献综述 11
1.1 研究背景与意义
1.2 国内外研究现状
1.3 内容热度预测与广告效果优化方法



1. 研究背景与文献综述

1.1 研究背景与意义

随着移动互联网的深度普及和社交媒体平台的蓬勃发展，内容创作与分享已成为数字经济时代信息传播与消费决策的核心环节。小红书（RED）作为中国领先的生活方式分享社区和消费决策入口，已从早期的海外购物攻略平台，演变为集图文、短视频、直播等多种形式于一体的综合性内容生态。截至 2023 年底，小红书月活跃用户数已突破 **3 亿 **，其中 **70%** 为 90 后年轻用户，社区内日均笔记发布量高达 ** 数百万篇 **，形成了一个庞大、活跃且极具商业价值的内容市场。在此背景下，品牌方、商家及个人创作者如何在海量信息中脱颖而出，通过优化内容策略以实现更高的曝光度、互动量与转化效果，已成为一个至关重要且富有挑战性的现实课题。

然而，小红书平台的内容分发机制相对复杂且不透明，一篇笔记能否成为“爆款”，往往受到内容质量、呈现形式、发布时机、标签策略、用户互动（如初始点赞、收藏、转发）以及平台算法推荐等多重因素的共同影响。例如，一条看似普通的日常分享笔记，可能因契合了某个热点话题、拥有吸引眼球的封面图、或在特定时间段发布，而在短时间内获得指数级传播，实现“从 0 到 1”的突破；反之，精心策划的商业推广内容若未能准确把握平台调性与用户偏好，则可能陷入“自娱自乐”的窘境。这种不确定性不仅增加了内容创作者与营销者的试错成本，也使得广告投放的精准性与投资回报率（ROI）难以稳定评估。

本研究的意义在于，基于小红书公开的笔记数据，系统地量化分析影响笔记热度的关键因素（如内容特征、视觉元素、时间地点、互动指标、话题标签等），并构建科学的数据分析模型，旨在揭示内容热度生成的内在逻辑与规律。通过实证研究，我们期望为内容创作者、品牌营销人员及广告代理商提供一套具有可操作性的内容优化策略框架，帮助其在内容策划、形式设计、发布规划及互动运营等环节做出更科学、更有效的决策，从而在竞

争激烈的“种草”生态中提升内容的吸引力、传播力与商业转化力，最终实现广告效果的最大化。此外，本研究亦有助于深化对社交媒体内容传播机制的理解，为平台算法的优化与社区生态的健康发展提供来自数据侧的洞察。

1.2 国内外研究现状

1.2.1 社交媒体内容传播与影响力研究综述

社交媒体内容传播与影响力的研究已成为传播学、市场营销学及数据科学交叉领域的热点。其核心在于探究哪些因素驱动了内容的广泛传播（如转发、点赞、评论）以及用户参与（Engagement）。根据研究视角的差异，现有文献大致可分为三类。首先，基于内容特征的研究，关注文本情感、主题类别、语言风格、标题吸引力、信息实用性等对传播效果的影响。例如，研究发现，包含积极情绪或激起好奇心的标题往往能获得更高的点击率；而提供实用价值（如教程、攻略）的“干货”内容则更容易引发用户的收藏行为。其次，基于视觉与形式特征的研究，强调图片质量、视频时长、封面设计、排版美观度等多媒体元素的关键作用。例如，有研究表明，高质量的原创图片、统一和谐的视觉风格能显著提升用户的停留时间和互动意愿。再者，基于上下文与网络结构的研究，则聚焦于发布时间、发布者影响力（KOL/KOC）、社交网络关系、话题热度（Hashtag）以及平台算法推荐机制等外部环境因素。例如，识别用户活跃的高峰时段进行发布，或巧妙借势热点话题，已被证明是提升初始曝光量的有效策略。

近年来，随着数据获取与分析技术的进步，相关研究方法也在不断演进。传统的问卷调查与案例分析法正逐渐与大规模数据挖掘、自然语言处理（NLP）和计算机视觉（CV）技术相结合。例如，研究者利用情感分析模型量化笔记文本的情感倾向，利用图像识别技术分析封面图的元素构成（如人脸、产品、场景），进而建立其与互动数据的关联模型。同时，机器学习方法，特别是预测模型（如回归模型、分类模型）和因果推断方法（如自然实验、双重差分法），被越来越多地应用于量化单个或多个因素对内容传播效果的边际影响，并试图从相关性中识别出因果关系，为策略制定提供更坚实的证据。

1.2.2 多模态社交媒体数据分析方法

传统统计与计量方法

在社交媒体数据分析的早期阶段，传统统计与计量经济学方法扮演了基础角色。这些方法主要用于检验特定因素与内容表现（如点赞数、转发数）之间是否存在显著的相关关系。多元线性回归（Multiple Linear Regression）是最常用的模型之一，它将内容热度（因变量）表示为一系列可量化特征（自变量，如文本长度、图片数量、发布小时等）的线性组合，通过估计系数来评估各因素的贡献度。为了处理计数数据（如点赞数）的离散性和过度分散问题，泊松回归（Poisson Regression）或负二项回归（Negative Binomial Regression）也常被采用。

然而，社交媒体数据通常具有复杂的特征：因变量（如热度指标）分布高度偏斜（存在大量零值和少数极端的“爆款”）；自变量之间可能存在多重共线性（例如，高质量内容可能同时具备优质图文和合适的发布时间）；并且存在大量的潜在混淆变量。为了解决

这些问题，研究者引入了更复杂的模型。例如，分位数回归（Quantile Regression）可用于研究不同热度水平下（如普通笔记 vs. 爆款笔记）影响因素的不同作用；而面板数据模型（Panel Data Model）则能利用同一创作者或同一主题的多次发布数据，控制个体或主题的固定效应，从而更准确地识别特定因素的作用。尽管这些方法在控制变量和估计参数方面非常严谨，但它们通常假设变量间的关系是线性的或可预定义形式的，对于捕捉文本、图像等高维复杂特征内部的非线性模式和交互作用能力有限。

机器学习与深度学习方法

机器学习和深度学习技术的发展，为分析和预测社交媒体内容热度提供了更强大、更灵活的工具。这些方法能够自动从原始数据（如原始文本、图像像素）中学习有效的特征表示，并建模复杂的非线性关系。

在特征工程方面，自然语言处理技术如词袋模型（Bag-of-Words）、TF-IDF 以及词嵌入（Word Embedding，如 Word2Vec, GloVe）可以将非结构化的文本转化为结构化特征，用于后续的回归或分类任务。对于图像，除了手动提取的颜色、纹理、物体检测等特征外，卷积神经网络（CNN）预训练模型（如 ResNet, VGG）可以提取深层、抽象的视觉特征向量。

在预测建模方面，集成学习方法如随机森林（Random Forest）和梯度提升决策树（XGBoost, LightGBM）因其出色的性能和可解释性（通过特征重要性排序）而被广泛应用。这些模型能够处理高维特征，自动进行特征选择，并捕捉特征间的复杂交互作用，常用于构建内容热度的回归预测或分类（如预测笔记是否会成为热门）模型。

更进一步，深度学习模型特别适合处理端到端（End-to-End）的多模态学习任务。例如，可以构建融合文本（通过 LSTM 或 Transformer 编码器）和图像（通过 CNN 编码器）特征的神经网络模型，共同预测内容的互动量。图神经网络（GNN）则可用于建模用户-内容交互网络或话题传播网络，以纳入社交关系信息进行更精准的预测。例如，有研究尝试利用用户历史行为序列，通过循环神经网络（RNN）来个性化预测其对某条内容的感兴趣程度。这些先进方法不仅能提升预测的准确性，还能帮助研究者发现传统方法难以识别的深层模式和影响因素组合。

1.3 内容热度预测与广告效果优化方法

传统预测与优化模型

在内容热度预测的传统模型中，除了上述的统计回归模型，时间序列预测方法（如 ARIMA 模型）有时也被用于分析某个账号或话题的热度随时间变化的趋势，但这种方法更适用于宏观趋势分析，而非对单篇内容的微观预测。在广告效果优化方面，传统的 A/B 测试（A/B Testing）是实践中的黄金标准。通过将目标受众随机分为两组，分别展示不同版本的内容（如不同标题、不同封面图），然后比较两组在关键指标（如点击率、转化率）上的差异，可以科学地评估单一变量的影响。然而，A/B 测试通常一次只能测试少数几个变量，且需要足够的流量和较长的测试周期，对于需要快速迭代、多因素同时优化的场景效率较低。

响应面方法（Response Surface Methodology, RSM）等实验设计方法可以用于探索多个

因素（如标题长度、图片风格、发布时间）及其交互作用对结果指标的最优组合。但这类方法通常假设响应面是连续的且可用低阶多项式近似，在面对社交媒体内容这种离散、高维且存在大量噪声的优化问题时，其应用受到一定限制。

机器学习驱动的内容策略优化

机器学习方法为实现智能化、自动化的内容策略优化提供了新的路径。一方面，预测模型本身可以作为优化工具：通过构建一个能够相对准确预测内容热度的模型（即“代理模型”或“元模型”），创作者或营销者可以在内容发布前，模拟调整不同的内容属性（如尝试不同的标题关键词、选择不同的发布时间段），利用模型预测哪种组合可能获得更好的效果，从而指导决策。这本质上是一种基于模型的“假设分析”（What-if Analysis）。

另一方面，强化学习（Reinforcement Learning）为在动态环境中持续优化内容策略提供了框架。智能体（如一个自动发布系统）可以通过与环境的交互（发布内容 -> 观察用户反馈 -> 获得奖励），学习在不同情境下（如不同话题、不同受众时段）应采取的最优内容策略（如选择什么类型的内容、以何种形式呈现）。此外，因果森林（Causal Forest）等基于机器学习的因果推断方法，可以从观测数据中估计不同内容干预（如添加特定标签、使用特定滤镜）对个体笔记或特定用户群体的异质性处理效应，从而帮助实现更精细化的个性化内容优化。

最终，结合多模态数据分析、热度预测模型与因果推断/优化算法，本研究旨在构建一个系统性的分析框架，以科学解码小红书内容热度的生成密码，为提升广告与营销效果提供数据驱动的解决方案。

Part II: 小红书数据获取与数据处理

2 数据获取与来源 17

2.1 数据来源

2.2 数据采集方法

2.3 数据描述与特征工程

2.4 数据预处理与清洗



2. 数据获取与来源

2.1 数据来源

小红书内容传播效果的研究高度依赖于高质量、大规模的真实用户笔记数据。为系统分析影响笔记互动表现（如点赞、评论、收藏等）的关键因素，本研究以小红书平台公开发布的用户笔记为主要研究对象，通过自动化数据采集方式构建研究所需的数据集。在数据采集过程中，严格遵循相关法律法规及平台使用规范，仅采集用户公开可见的信息，并对涉及用户身份的数据进行脱敏处理，确保数据仅用于学术研究目的。

2.1.1 主要数据源：小红书平台

本研究的主要数据来源为小红书平台的公开笔记信息，数据采集覆盖家电与美妆两个典型内容垂直领域。通过对不同领域笔记内容及互动数据的对比分析，探究内容形式、文本特征及用户影响力等因素对笔记传播效果的影响。

数据采集时间范围为 2023 年 1 月至 2024 年 8 月，共获取约 1,338,527 条有效笔记数据，具有较大的样本规模和较强的统计分析价值。

采集的核心数据字段主要包括以下几类：

- 笔记元数据：包括笔记唯一标识（ID）、笔记标题、正文内容、话题标签（关键词）、笔记发布时间及发布地点。
- 互动数据：包括笔记的点赞数、评论数和收藏数，用于衡量笔记的传播效果与用户参与度。
- 内容形式特征：包括笔记是否包含图片、是否包含视频及其链接信息，用于分析多媒体内容对传播效果的影响。
- 用户信息：包括博主名称及其粉丝数量，用于刻画发布者影响力水平，并作为后续分析中的控制变量。

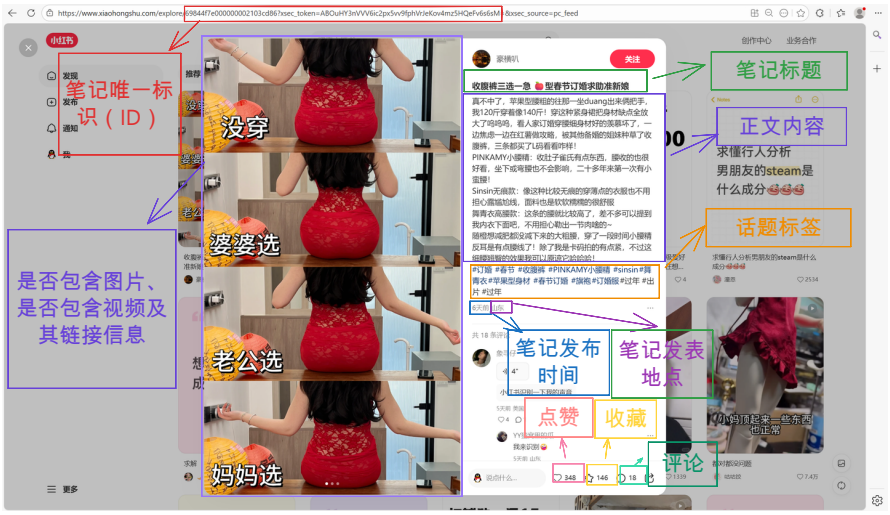


Figure 2.1: 小红书笔记页面与采集字段示意

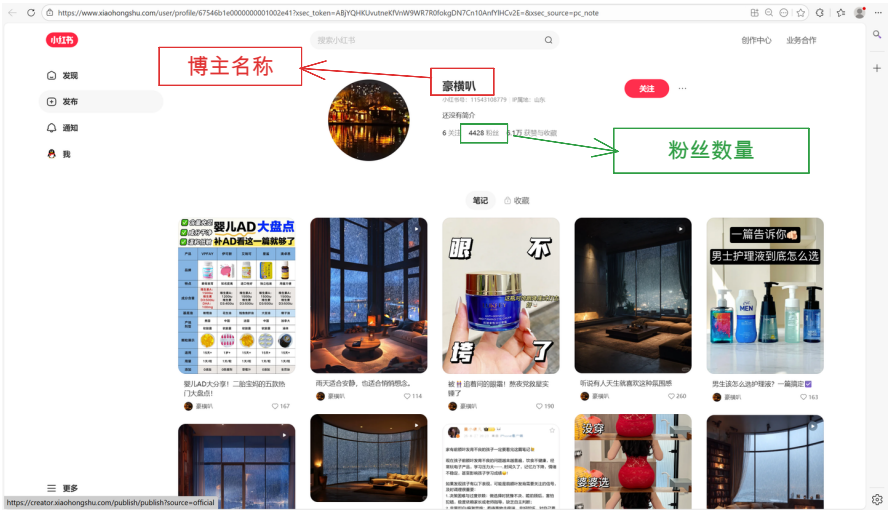


Figure 2.2: 用户页面采集字段示意

2.1.2 数据领域划分方式

为保证不同内容领域样本的准确性与可区分性，本研究在数据采集阶段即对内容领域进行前置区分，采用不同访问入口 URL 分别获取家电与美妆领域的笔记数据。

其中，家电领域的数据通过平台搜索入口进行采集，基于以“家电”为核心关键词构建的搜索结果页面获取笔记列表；美妆领域的数据则通过平台官方内容频道入口进行采集，直接访问美妆频道对应的内容流页面获取笔记列表。由于不同入口页面在平台内容组织逻辑上已完成领域划分，因此能够在源头上减少跨领域内容混入的情况。

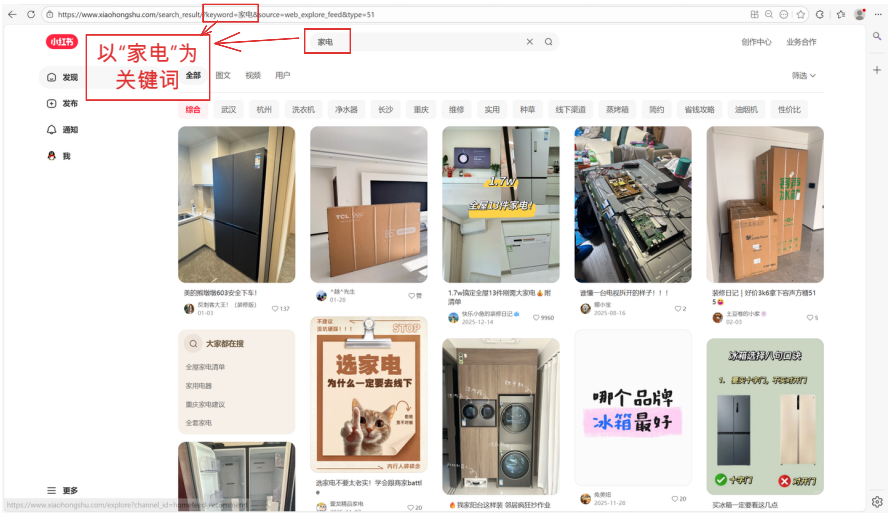


Figure 2.3: 以“家电”为核心关键词构建的搜索结果页面

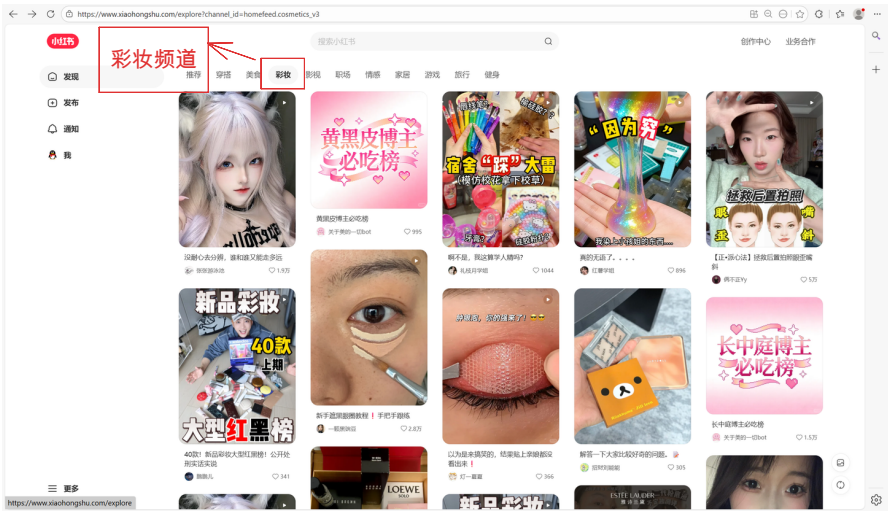


Figure 2.4: 美妆频道对应的内容流页面

在具体采集过程中，分别从上述不同入口页面解析并提取笔记唯一标识（ID），再基于笔记 ID 进一步访问笔记详情页获取完整内容信息。通过这种“入口区分—ID 提取—详情采集”的两阶段方式，实现了家电与美妆两个内容领域样本的独立采集与明确区分。

不同领域入口 URL 设置示例:

```
# 本代码仅为过程抽象示例，非实际运行代码。

# 不同领域入口URL设置
ENTRY_URLS = {
    "家电": (
        "https://www.xiaohongshu.com/search_result/?"
```

```
        "keyword=家电&source=web_explore_feed&type=51"
    ),
    "美妆": (
        "https://www.xiaohongshu.com/explore?"
        "channel_id=homefeed.cosmetics_v3"
    )
}
def collect_ids_by_field(field_name):
    """
    根据领域名称选择不同入口URL
    """
    url = ENTRY_URLS[field_name]
    print(f"当前采集领域: {field_name}")
    print(f"使用入口: {url}")

    response = session.get(url, headers=get_headers(), cookies=cookies)
    soup = BeautifulSoup(response.text, "html.parser")

    # 后续统一执行ID提取逻辑
    # ...

# 调用示例
collect_ids_by_field("家电")
collect_ids_by_field("美妆")
```

2.1.3 辅助数据源说明

本研究未引入任何辅助数据源，如微博热搜、百度指数或第三方社交媒体监测平台的数据。所有分析均基于所采集的小红书平台笔记数据展开。通过构建大规模、高维度的原始笔记数据集，直接从平台内部数据中挖掘影响内容传播效果的关键因素，以避免外部数据噪声对分析结果的干扰。

2.2 数据采集方法

研究采用基于 Python 的自动化网页数据采集方法，对平台公开页面进行结构化解析。在采集过程中，通过合理控制请求频率与访问行为，尽量模拟真实用户浏览过程，以保证数据采集的稳定性与连续性。-抓取”的流水线作业，提升了系统的健壮性和可维护性。

2.2.1 采集工具与框架

数据采集主要基于 Python 语言实现，使用 requests 库完成网页请求，利用 BeautifulSoup 对 HTML 页面进行解析与信息提取。通过维护会话状态、设置随机 User-Agent 及请求延时，有效降低高频访问带来的风险，提高采集过程的稳定性。

整体爬虫程序采用模块化设计，分为笔记 ID 采集模块与笔记详情信息采集模块，便于后续维护与扩展。

- 第一阶段：ID 收集爬虫：该模块负责从平台信息流中持续发现新的笔记 ID。它模拟访问指定的频道发现页（如美妆、家电频道），解析页面源码，提取笔记详情页链接并剥离出唯一的笔记 ID。
- 第二阶段：详情页采集爬虫：该模块读取第一阶段生成的 ID 列表，批量构建详情页 URL 并发起请求。通过解析详情页的 <meta> 标签和特定 DOM 元素，精确提取 2.1.1 节中定义的各类信息。

小红书笔记 ID 采集流程示例：

```
import time
import random
import requests
from bs4 import BeautifulSoup

def get_note_ids_from_page(url):
    headers = {
        "User-Agent": "Mozilla/5.0"
    }
    response = requests.get(url, headers=headers)
    soup = BeautifulSoup(response.text, "html.parser")

    note_ids = []
    for link in soup.find_all("a", href=True):
        if "/explore/" in link["href"]:
            note_id = link["href"].split("/explore/")[-1]
            note_ids.append(note_id)

    time.sleep(random.uniform(2, 5)) # 随机延时
    return note_ids
```

在获取笔记唯一标识后，进一步访问笔记详情页面，对笔记的文本内容、互动数据及发布时间等关键信息进行解析。其基本实现流程如代码示例所示：

```
import requests
```

```
from bs4 import BeautifulSoup
import time
import random

def get_note_detail(note_id):
    url = f"https://www.xiaohongshu.com/explore/{note_id}"
    headers = {
        "User-Agent": "Mozilla/5.0"
    }

    response = requests.get(url, headers=headers)
    soup = BeautifulSoup(response.text, "html.parser")

    # 提取笔记标题
    try:
        title = soup.select_one('meta[name="og:title"]')['content']
    except:
        title = ""

    # 提取正文描述
    try:
        description =
            soup.select_one('meta[name="description"]')['content']
    except:
        description = ""

    # 提取互动数据
    try:
        like_count =
            soup.select_one('meta[name="og:xhs:note_like"]')['content']
        comment_count =
            soup.select_one('meta[name="og:xhs:note_comment"]')['content']
        collect_count =
            soup.select_one('meta[name="og:xhs:note_collect"]')['content']
    except:
        like_count, comment_count, collect_count = 0, 0, 0

    # 提取发布时间
```

```
    try:
        publish_time = soup.select_one('span.date').text.strip()
    except:
        publish_time = ""

    time.sleep(random.uniform(2, 4)) # 控制访问频率

    return {
        "note_id": note_id,
        "title": title,
        "description": description,
        "like": like_count,
        "comment": comment_count,
        "collect": collect_count,
        "publish_time": publish_time
    }
```

2.2.2 采集流程设计

本研究的数据采集流程主要包括以下几个步骤：

1. **确定采集范围**：明确研究领域为家电与美妆两个内容类别，数据采集时间范围限定为 2023 年 1 月至 2024 年 8 月。
2. **笔记 ID 获取**：分别通过搜索页面与频道页面获取笔记列表，从页面中解析并提取笔记唯一标识（ID），并对已采集 ID 进行去重处理。
3. **笔记详情采集**：基于已获取的笔记 ID，进一步访问笔记详情页面，采集完整的文本内容、互动数据、多媒体信息及博主相关信息。
4. **数据存储**：将结构化数据统一存储为 CSV 文件，便于后续统计分析；同时将笔记正文、标签词、视频链接等文本信息以及图片资源分别保存，用于辅助特征提取和描述性分析。

数据采集过程为连续多日运行完成，通过分轮采集与断点续爬机制，保证在长时间运行条件下的数据完整性与稳定性。

2.2.3 反爬策略与伦理考量

为降低对平台服务器的访问压力并遵守网络爬虫伦理，本研究在数据采集过程中采取了以下措施：

- 设置随机请求延时，避免高频访问；
- 控制单轮采集规模，防止异常请求行为；
- 仅采集平台公开展示的数据内容；

- 所有数据仅用于学术研究，分析结果以聚合统计形式呈现，不涉及任何个人隐私信息的公开。

本研究所采集的全部数据均为小红书平台上的公开信息。在数据使用上，我们郑重承诺：所有数据仅用于本项学术研究的统计分析，绝不会用于任何商业目的，也不会以任何形式公开披露能识别到具体用户或个人身份的原始信息。论文中的所有结论均基于聚合后的统计结果呈现。

2.3 数据描述与特征工程

原始采集的小红书笔记数据以文本和半结构化字段为主，包含大量非标准化表达形式，无法直接用于统计分析与建模。因此，本研究在数据清洗的基础上，围绕时间信息、互动行为、发布地点与标签等核心要素，构建了一套结构化特征体系，将原始字段转化为可量化、可编码的分析变量。

2.3.1 时间特征构建

小红书平台中的发布时间以多种自然语言形式呈现，如“3 天前”“昨天 20:15”“06-20”“编辑于今天”等。针对该特点，本文对发布时间字段进行统一解析与推断，主要步骤包括：

- 识别相对时间表达（如“x 天前”“昨天”“今天”），并基于数据采集日期反推出实际发布日期；
- 对仅包含“月-日”或“x 月 x 日”的时间表达，结合采集时间补全年份信息；
- 对已为标准日期格式（如 YYYY-MM-DD）的记录直接保留。

经过处理后，所有笔记的发布日期被统一转换为标准日期格式（YYYY-MM-DD），并在此基础上进一步派生出以下时间特征：

- **发布日期**：推断后的笔记实际发布时间；
- **星期特征**：根据发布日期计算星期几，并编码为数值型变量，用于刻画发布时点的周期性特征。

2.3.2 互动行为特征

互动行为是衡量笔记热度的核心信息来源，包括点赞数、评论数、收藏数以及发布者粉丝数。然而，这些字段在原始数据中通常以非标准数值形式出现，如“1.2 万”“3 万+”“10+”等。

为保证数据的可计算性，本文对上述字段进行统一数值化处理：

- 将带有“万”“万 +”等单位的文本数值转换为对应的整数数量级；
- 对带“+”的数值，在保留数量级信息的基础上进行近似修正；
- 最终生成相对准确的点赞数、评论数、收藏数及粉丝数数值特征。

该处理过程在一定程度上缓解了平台展示规则带来的信息模糊问题，使互动数据能够直接参与后续统计分析与建模。

2.3.3 发布地点特征

发布地点信息来源于笔记发布时间字段中附带的文本描述。本文通过正则匹配与字符串解析方法，从相关字段中抽取用户填写的发布地点信息，并构建地点特征。

在此基础上，采用字典映射方式对地点文本进行编码处理：

- 对已识别的发布地点建立全局唯一编号映射表；
- 对同时包含多个地点的情况，保留多值编码结果；
- 对未填写或无法识别发布地点的笔记，设置统一的缺失标记。

此外，为便于模型区分地点信息的完整性，额外构建“是否填写发布地点”的辅助二元特征。

2.3.4 标签特征

笔记中的话题标签反映了内容的主题属性。本文对笔记中包含的标签词进行统计与整理，并采用与发布地点相同的字典化编码策略：

- 统计全体数据中出现过的标签词集合；
- 构建标签词到数值 ID 的映射关系；
- 对缺失标签或无标签笔记设置统一缺失编码；
- 构建“是否填写标签”的辅助特征。

通过上述处理，原始文本标签被转化为可用于建模的离散类别特征。

2.4 数据预处理与清洗

原始采集的数据在结构和内容层面均存在噪声与不一致问题。为保证数据质量，本文在特征工程之前实施了系统的数据预处理与清洗流程。

2.4.1 异常与冗余数据清理

在数据整理过程中，主要执行以下清洗操作：

- 删除在合并或追加过程中产生的重复表头行；
- 剔除关键字段（如粉丝数）中包含明显异常字符串的记录；
- 对无法解析发布时间或缺失核心标识信息的样本予以剔除。

2.4.2 缺失值处理策略

考虑到社交平台数据中缺失现象普遍存在，本文未采用简单均值或众数填补，而是通过显式标注缺失状态的方式进行处理：

- 对发布地点、标签等非关键特征，使用特定编码值表示缺失；
- 同时构建“是否填写该信息”的辅助特征，保留缺失本身所蕴含的信息；
- 对关键字段（如笔记 ID、互动数据）严重缺失的样本直接剔除。

2.4.3 特征编码与一致性控制

为保证多文件、多批次数据处理结果的一致性，代码采用增量式字典编码策略：

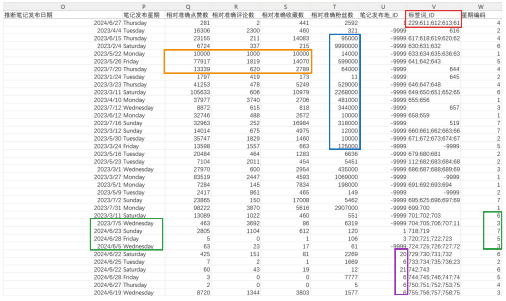
- 地点与标签编码字典在处理过程中持续更新并全局共享；
- 相同文本特征在不同数据文件中始终对应相同的数值编码；
- 对未匹配到的异常类别设置统一的异常标识值。

该策略有效避免了因分批处理导致的特征含义不一致问题，为后续建模提供了稳定的数据基础。



清洗前的原始数据

(a) 同色框对应：红=标签词，蓝=粉丝量，绿=发布时间，紫=发布地点，橙=点赞数、评论数、收藏数



清洗后的结构化数据

(b) 同色框对应：红=标签编码，蓝=相对准确粉丝数，绿=推断发布日期、推翻星期几和对应星期编码，紫=发布地点编码=相对准确点赞数、相对准确评论数、相对准确收藏数

Figure 2.5: 小红书笔记数据清洗前后对比

Part III: 小红书笔记多维度数据分析与探索

3 笔记内容质量分析 29

3.1 文本内容深度与可读性分析

3.2 主题相关性与信息价值分析

4 笔记形式与视觉呈现分析 37

4.1 多媒体内容分析

4.2 排版与格式分析

5 发布者影响力与社交网络分析 39

5.1 发布者基础影响力分析

5.2 发布者内容垂直度与粉丝画像（模拟）分析

6 发布时机与上下文分析 41

6.1 时间节律：基于周周期的注意力波动分析

6.2 制度性节点冲击：节假日与调休制度的异象

6.3 空间格局：地域数字文化的非对称扩张

7 标签策略与话题热度分析 45

7.1 标签使用策略分析

7.2 话题借势与热点响应分析

8 多维度相关性分析 47

8.1 特征间相关性分析

8.2 特征与目标变量相关性分析

8.3 非线性关系探索

9 特征选择与重要性评估 53

9.1 基于统计检验的初步筛选

9.2 基于机器学习模型的特征重要性评估



3. 笔记内容质量分析

3.1 文本内容深度与可读性分析

本研究从文本长度、可读性与情感三个维度考察小红书笔记内容质量与互动表现之间的关系。由于实际数据处理中，可读性指标仅能对部分样本稳定返回结果，本文采用“全量基础清洗 + 抽样计算特征 + 回归稳健性检验”的方式开展分析。

3.1.1 变量构建与样本处理

首先，本文将原始 CSV 数据合并后进行基础清洗。剔除点赞、评论、收藏缺失的样本后，原始样本量为 323,598 条，清洗后保留 297,031 条。为降低极端账号对结果的干扰，本文进一步构造互动率指标，并删除粉丝数异常高但互动率过低的疑似买粉样本，最终样本量仍保持为 297,031 条。

在核心变量构建上，本文将互动表现定义为：

$$\text{engagement} = \text{likes} + \text{favs} + 4 \times \text{comments}$$

并对其取对数得到以缓解长尾分布对回归估计的影响。文本长度方面，本文计算了标题长度、正文长度以及全文长度，其中全文长度作为主分析变量进入回归模型。情感变量则由情感预测值构造得到，进一步计算情绪极端程度

$$\text{emotion_extreme} = \text{emotion_strength} - 0.5$$

3.1.2 文本长度与互动关系

为了考察文本长度是否影响用户互动，本文首先对全文长度与互动水平进行了可视化分析。结合后续回归结果，长度的一次项系数为负、二次项系数为正，说明文本长度与互

动之间存在一定的 U 型关系。在当前样本区间内，较短文本整体上更容易获得较高互动，但当长度继续增加到一定程度后，互动水平可能再次回升。

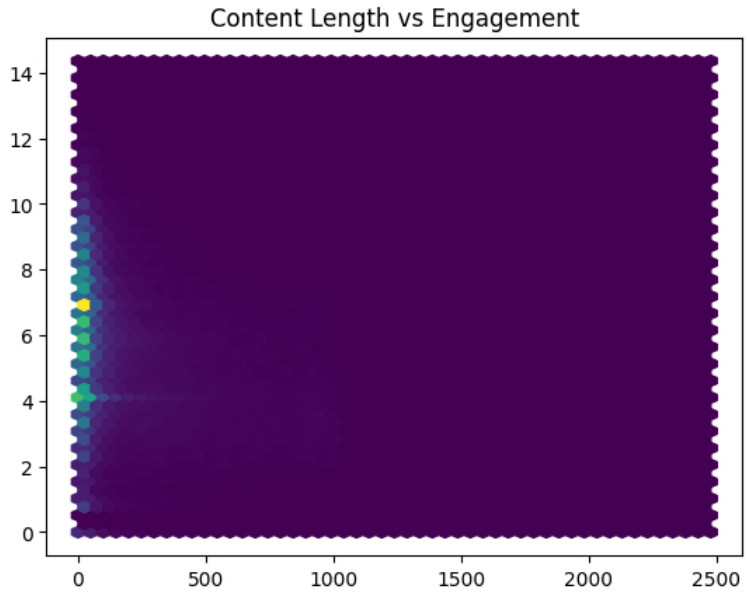


Figure 3.1: 文本长度与互动关系

3.1.3 文本情感与互动关系

在情感维度上，本文进一步分析了情感强度与互动表现之间的关系。回归结果表明，情感变量与互动水平呈现负相关趋势。情感强度和情绪极端程度在主模型与稳健性模型中均表现为显著负相关，说明在本样本中，越偏离中性、越强烈的情绪表达，平均互动反而更低。

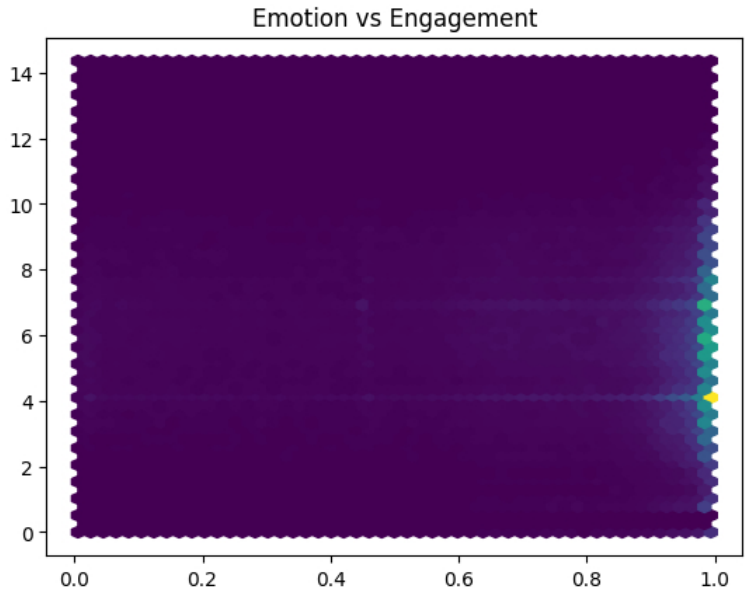


Figure 3.2: 文本情感与互动关系

3.1.4 互动分布特征

从整体分布来看，笔记互动量呈现明显的长尾特征。大多数样本集中在较低互动区间，只有少量内容获得了极高互动。这也解释了为何本文对互动变量采用对数变换后再进行建模，以提高回归估计的稳定性并减弱极端值的影响。

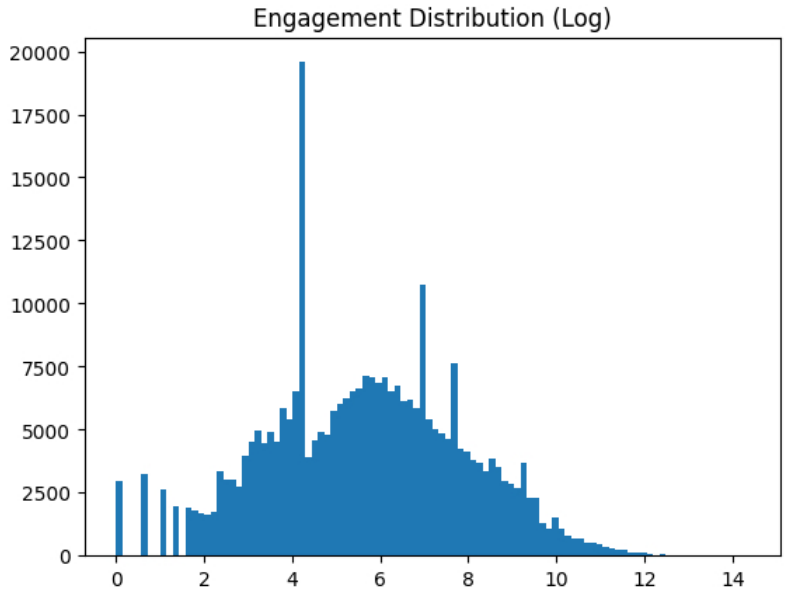


Figure 3.3: 互动特征分布

3.1.5 非线性趋势识别

为了进一步识别长度变量与互动之间的非线性结构，本文对抽样样本进行了 LOWESS 平滑拟合。结果显示，文本长度与互动之间存在较明显的弯曲趋势，这说明简单线性模型不足以完整描述二者关系。因此，在后续 OLS 回归中，本文加入了长度平方项，以刻画可能存在的非线性效应。

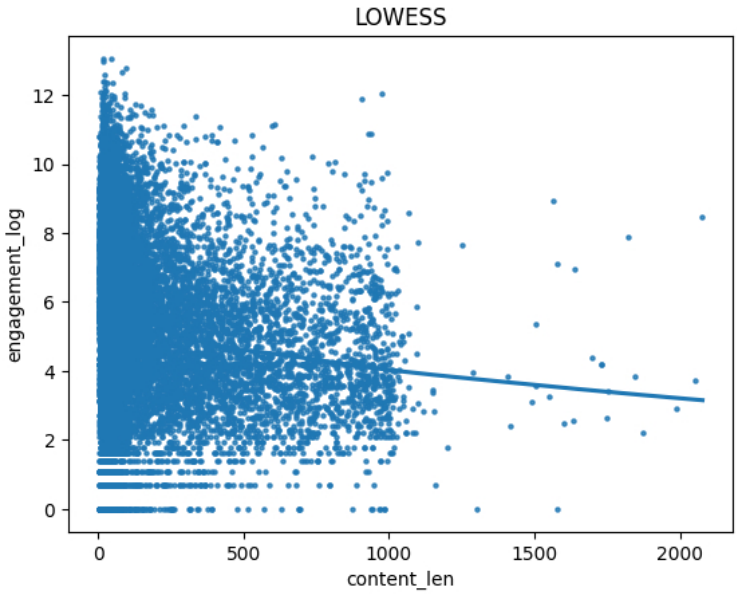


Figure 3.4: 非线性趋势识别

3.1.6 回归结果与稳健性检验

在主回归模型中，本文以 *engagement_log* 为因变量，以文本长度、长度平方项、情感强度、情绪极端程度和可读性为自变量进行 OLS 估计。结果显示，模型整体显著，但解释力有限，R^2 约为 0.050。这说明文本特征对互动具有统计意义上的解释力，但笔记热度仍受到账号属性、发布时间、封面质量、主题类别等其他因素影响。

具体而言，文本长度一次项系数显著为负，而二次项系数显著为正，说明长度效应具有非线性特征；情感强度与情绪极端程度的系数均显著为负，表明在本样本中，情绪越强或越极端，平均互动反而越低；可读性变量在主模型中边际显著，但在稳健性模型中不再显著，说明其影响较弱，且对样本极端值较为敏感。

进一步地，本文剔除互动前 1

3.1.7 分组分析

为更直观地观察长度效应，本文进一步将文本长度按分位数分组，比较不同长度区间的平均互动水平。结果表明，文本长度与平均互动之间存在明显的分组差异，整体趋势与回归结果一致，即长度并非简单线性越长越好，而是存在相对更优的区间。

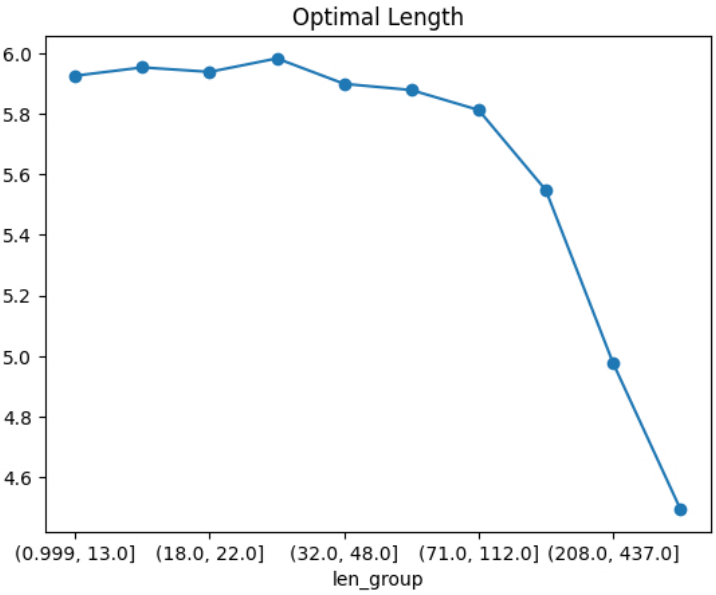


Figure 3.5: 分组分析

3.1.8 情感分组结果

最后，本文对情感强度与情绪极端程度进行了分组比较。结果表明，情感强度较低、情绪更接近中性的样本平均互动更高；而情绪极端程度越高，平均互动水平总体越低。这一结果与回归分析保持一致，进一步说明在小红书笔记场景中，过强或过于极端的情绪表达并不一定带来更高互动。

综合来看，文本内容特征对笔记热度具有显著影响，其中长度呈现非线性关系，情感强度与情绪极端程度总体上与互动负相关，可读性影响相对较弱且不够稳健。该结果说明，小红书用户对内容的响应不仅取决于文本长度本身，也与内容表达方式、情绪呈现方式及其是否符合平台阅读习惯密切相关。

3.2 主题相关性与信息价值分析

在社交媒体中，除了基础的情感与篇幅特征外，内容传递的实际信息量以及“标题-正文”间的一致性，也是决定用户深度互动的关键因素。本节基于 TF-IDF 算法提取文本核心关键词，从“信息密度”与“标题匹配度”两个维度，深入探讨小红书笔记的信息价值分布对互动表现的影响。

3.2.1 变量构建与共线性修正

为量化笔记的信息分布情况，本文首先利用 TF-IDF 算法提取单篇笔记中的高权重核心词汇。“信息密度（info_density）”定义为正文高权重词汇数占局部总有效词数的比重；“标题匹配度（title_match）”则定义为标题关键词与正文关键词的交集词数占标题总词数的比例，主要用于衡量笔记是直接“白描”还是存在一定的内容悬念差。

在将上述变量引入回归模型前，考虑到前期引入的文本长度平方项（$content_len^2$）会与一次项产生较强的自然数学共线性（未标准化模型的条件数曾高达 2.04×10^6），本文利用 Z-score 对所有连续型自变量先行进行标准化处理，再由标准化后的长度构造平方项。处理后，各变量的方差膨胀因子（VIF）介于 1.11 至 7.74 之间，模型总体条件数（Cond. No.）降至 8.52。该结果说明数值尺度导致的病态程度明显缓解，但个别变量仍存在中等程度的共线性，解释单个系数时仍需保持谨慎。

3.2.2 信息价值回归结果与检验

本文将标准化后的各特征变量纳入 OLS 回归模型,因变量为对数互动量 *engagement_log*，而非除以粉丝数后的互动率。回归估计结果如表 3.1 所示。整体模型高度显著（F 统计量 = 259.7，Prob(F) < 0.001）。

Table 3.1: 信息价值与互动表现的多元线性回归结果

变量	标准化系数 (β)	标准误 (Std.Err)	t 值	P>|t|
截距项 (Intercept)	5.4472	0.021	255.55	<0.001 ***
内容长度 (*content_len*)	-0.4994	0.043	-11.71	<0.001 ***
内容长度平方 ($content_len^2$)	0.0711	0.015	4.80	<0.001 ***
情感强度 (*emotion_strength*)	-0.1100	0.018	-5.97	<0.001 ***
极端情感 (*emotion_extreme*)	-0.0969	0.019	-5.18	<0.001 ***
信息密度 (*info_density*)	0.1055	0.025	4.20	<0.001 ***
标题匹配度 (*title_match*)	-0.1822	0.016	-11.23	<0.001 ***
样本量 = 20,000	$R^2 = 0.072$	总体条件数 (Cond. No.) = 8.52		

注：*** 代表 1% 的显著性水平。

由于引入了标准化处理，相较于前述的基础回归模型，本模型中的各项系数代表了不同特征变量在同一量纲下对互动率的相对作用强度。前述关于长度“U 型折返”以及极端情绪负面作用的结论在加入新特征后依旧十分稳健，并且本部分揭示了信息维度两个额外的核心机制。

3.2.3 信息密度的“干货溢价”效应

回归结果表明，信息密度与互动表现呈显著正相关（$\beta = 0.1055, p < 0.001$）。在控制模型中其他文本变量后，高权重词汇占比较高的笔记通常具有更高的平均互动量。这一结果与“信息更集中、更便于检索的内容可能更符合用户决策需求”的解释一致。不过，本文的信息密度来自 TF–IDF 阈值构造，且模型尚未控制全部账号与主题差异，因此该结果应理解为相关性证据，而非信息密度对互动的确定性因果效应。

3.2.4 预期偏差与“悬念留白”机制

模型同时揭示了一个值得关注的反直觉现象：标题匹配度与互动表现呈显著负相关（$\beta = -0.1822, p < 0.001$），且其标准化系数绝对值在模型中仅次于文本长度。这意味着，在当前样本和词汇重合度定义下，标题关键词被正文直接重复得越多，笔记的平均互动量反而越低。

这一现象可能与信息缺口或标题的悬念表达有关：过分直白的重复可能降低读者继续探索的意愿，而适度的信息差可能保留阅读动机。不过，当前指标衡量的是分词后的词汇重合，而不是严格的语义一致性；标题较短、正文缺失或不同主题的语言习惯也可能影响该指标。因此，“悬念留白”只能作为一种可能解释，尚不能由本模型直接验证。

3.2.5 信息分布的可视化特征

为进一步佐证回归模型揭示的两大规律，本文对信息密度、标题匹配度与互动强度的关系进行了二维六边形密度成像拟合（Hexbin Plot）。如图 3.6 所示，左侧图中高密度分布带向右侧高互动区的蔓延直观体现了“干货溢价”的底盘支撑效能；而右侧图则清晰地反映了标题匹配度过高时，样本互动数据出现的集中性坍缩，为本节总结的“悬念留白”机制提供了几何维度的实质性支撑。

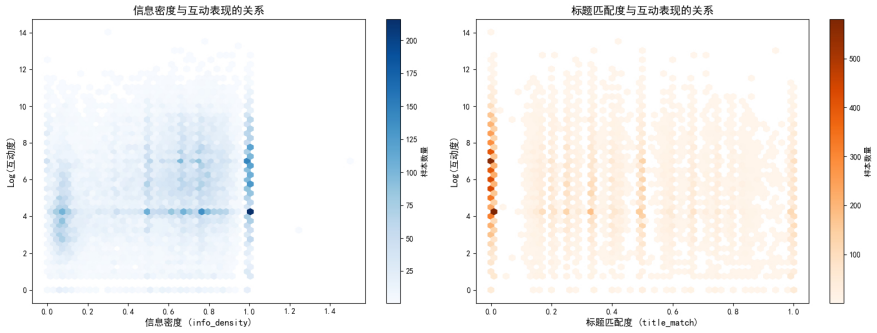


Figure 3.6: 信息密度与标题匹配度对互动的二维密度影响分析



4. 笔记形式与视觉呈现分析

4.1 多媒体内容分析

小红书是一个强视觉化的平台，图片和视频的质量直接影响用户的点击和停留意愿。本研究将对笔记的多媒体内容进行量化分析。

首先，我们将分析图片的基本特征。对于包含图片的笔记，我们将计算其图片数量，并研究图片数量与互动量的关系。通常，一定数量的高质量图片能更好地展示内容，但过多图片可能导致加载缓慢，反而影响体验。我们还将通过图像处理技术提取封面图或首图的关键视觉特征，如：

- **色彩特征：**主色调、色彩丰富度（饱和度、对比度）。明亮、色彩和谐的图片可能更具吸引力。
- **构图特征：**是否包含人脸、人脸占比、是否遵循三分法等构图原则。
- **清晰度与美学质量：**使用图像清晰度算法（如拉普拉斯方差）和预训练的深度学习美学评估模型对图片质量进行评分。

我们将通过相关性分析和分组实验（如对比高热度笔记和低热度笔记的图片特征均值）来验证哪些视觉特征与笔记热度显著相关。

其次，对于视频笔记，我们将分析视频时长、封面帧、是否有字幕、背景音乐等特征。视频时长存在一个“甜点区间”，过短可能表达不清，过长则完播率低。我们将通过数据分析寻找不同内容类别下最优的视频时长范围。

4.2 排版与格式分析

在小红书这类强视觉驱动的社交媒体平台上，笔记的排版与格式直接影响用户的阅读体验和信息获取效率。良好的排版不仅能够降低用户的认知负荷，还能通过视觉引导突出

关键信息，从而延长停留时间并激发互动行为。尽管排版特征往往被视为“微内容”，但其对传播效果的潜在贡献不可忽视。本研究旨在系统量化排版与格式特征对笔记热度的影响，为内容创作者提供可操作的优化建议。

- **文本分段**：正文是否合理分段（通过换行符或分隔符数量衡量），长段落是否使用小标题或序号。
- **重点突出**：检测正文中是否包含加粗标签（<b>、）、特殊符号或表情符号（Unicode Emoji）来强调关键信息。
- **清单使用**：检测正文是否包含列表结构，或平台特有的列表格式开头的行，是否使用“1. 2. 3.”或“•”等列表形式，使内容条理清晰。特征通过 Python 的正则表达式库 re 和 emoji 库进行提取。

这些格式特征虽然看似细微，但可能通过影响阅读流畅度和信息获取效率，间接影响用户的互动意愿。我们将通过构建二元特征（如“是否使用表情符号”）并比较其在不同热度组中的分布，来评估其影响。

5. 发布者影响力与社交网络分析

5.1 发布者基础影响力分析

发布者自身的社交资产是笔记获得初始流量的基石。粉丝数量决定了笔记发布时的基础曝光池大小，而历史表现和认证状态则反映了发布者的内容生产能力和用户信任度。本部分旨在量化发布者基础特征对笔记热度的贡献，并识别高粉丝粘性的“优质创作者”特征。

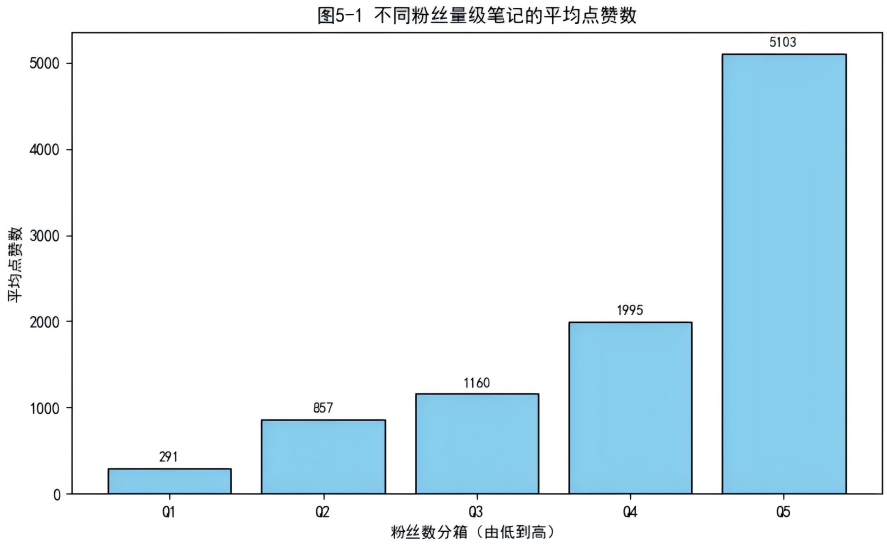


Figure 5.1: 不同粉丝量级笔记的平均点赞数

- **粉丝数量（取对数）**：从用户信息页采集粉丝数，由于分布呈长尾，对其进行自然对数变换（log(粉丝数 +1)）以缓解异方差性。计算粉丝数对数与笔记点赞数对数的皮

尔逊相关系数，并通过散点图和平滑拟合（LOESS）观察线性关系强度。

- **历史表现：**计算每个发布者在采集窗口前 30 天内发布的笔记平均点赞数、评论数、收藏数，作为“近期内容质量”的代理变量。若发布者为新用户，则用整体样本均值填充。定义互动率 = 点赞数 / (粉丝数 +1)，计算每个笔记的互动率，并分析其分布。将发布者按互动率分组，比较不同组别笔记的平均互动量，以识别“高质量”发布者（粉丝数不高但互动率高）。
- **认证状态：**比较认证用户（企业号、专业号、达人）与非认证用户在平均互动量上的差异。认证通常意味着更高的可信度和专业性，可能带来额外的流量权重。以对数化后的点赞数为因变量，将粉丝数对数、历史平均表现对数、认证状态等作为自变量，构建多元线性回归模型。同时，加入粉丝数与内容特征的交互项，探究不同粉丝量级下内容要素的异质性作用。

5.2 发布者内容垂直度与粉丝画像（模拟）分析

由于难以直接获取粉丝画像，我们可以通过分析发布者历史笔记的主题分布来推断其内容垂直度。一个高度垂直的发布者（如只发美妆内容）可能拥有更精准、忠诚的粉丝群体，其笔记的互动率和转化率可能更高。我们将计算发布者历史笔记主题分布的熵值，熵值越低代表垂直度越高，并分析垂直度与平均互动率的关系。



6. 发布时机与上下文分析

在社交媒体生态中，内容的传播效能不仅取决于文本与视觉质量，还受到发布时境（Temporal Context）与地域文化（Spatial Context）的深刻影响。本章在利用规则引擎剔除了 15,972 条“高粉丝低互动”的疑似买粉样本后，基于 29.6 万条有效数据，从星期节律、中国特色法定节假日以及地域数字经济三个维度，深度剖析小红书笔记传播的时空动力学机制。

6.1 时间节律：基于周周期的注意力波动分析

受限于现代社会工作与学习的周期性规律，用户的线上注意力呈现出明显的周内波动机制。利用单因素方差分析（ANOVA），检验结果表明“星期几效应对数互动量”的主效应极显著（$F = 946.56$, $p < 0.001$，$\eta^2 = 0.018$）。

数据呈现出两个值得关注的极值节点：第一，**周一是内容互动的最高峰（平均 log 互动量达 5.95）**。这一反常识现象可用组织行为学中的“心理补偿机制（Psychological Compensation）”来解释——在结束周末回归工作或学业的首日，用户倾向于利用流式媒体进行碎片化的“赛博摸鱼”以缓解职段压力。其二，**周五是互动的绝对低谷（平均 log 互动量仅为 5.01）**。Tukey HSD 事后检验进一步表明，周五与其他任何工作日的均值差异（Mean Diff 均在 -0.5 以上）均极其显著（$p_{adj} < 0.01$）。这揭示了媒介使用的替代效应（Substitution Effect）：在周末临近前，受众注意力从“线上内容消费”发生了向“线下实体社交”的物理转移。

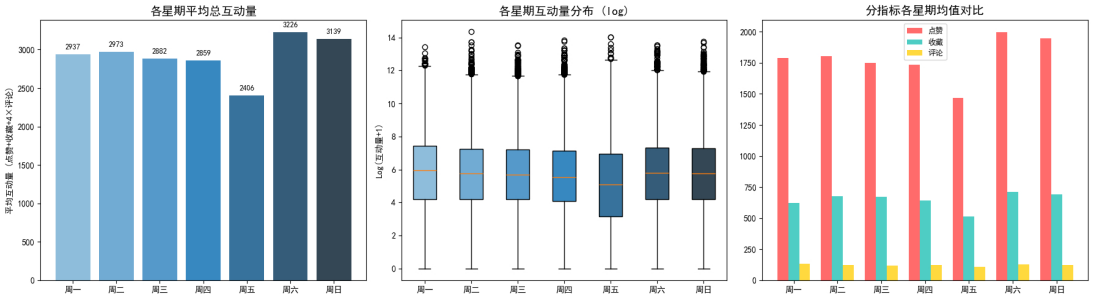


Figure 6.1: 小红书笔记互动的周周期波动及分指标分布

6.2 制度性节点冲击：节假日与调休制度的异象

除常规节律外，国家法定节假日引起的社会作息变动对平台流量池具有强烈的宏观冲击。为了精准刻画这一效应，本文将 2023-2024 年的数据严格划分为：普通工作日、普通周末、节假日以及中国特有的“调休工作日”。

四组样本的 ANOVA 检验显示出极显著的结构差异（$F = 305.53$, $p < 10^{-190}$）。其中最引人注目的实证发现是：**调休工作日的互动峰值反常地超越了所有日期类型，平均总互动跃升至 4744（对数互动 6.28），甚至高于真正的法定节假日（4202）。**

一方面，节假日（Welch $t = 18.75$, $p < 0.001$ 显著高于非节假日）作为大块闲暇时间，确实是深度长决策内容（如旅游攻略、家电选购）消费的集中区。但另一方面，调休工作日的极高数据表征了“强迫性劳动时间”与“注意力涣散”的错位：处于心理疲劳与调休补偿心态下的用户，其移动端浏览频率剧增。在该节点发布的内容，极易借由宏观“摸鱼流量池”脱颖而出。

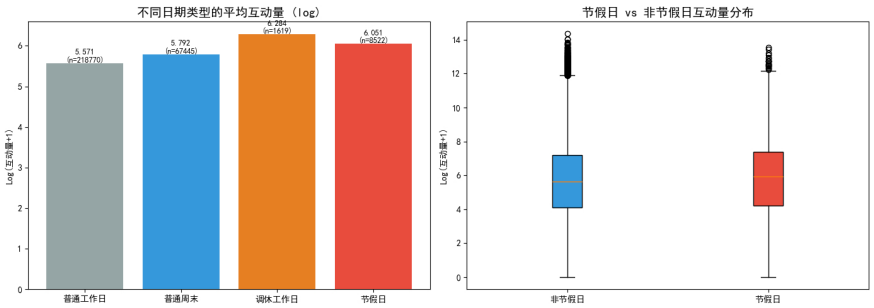


Figure 6.2: 不同日期类型（含调休特征）对互动表现的异质性冲击

6.3 空间格局：地域数字文化的非对称扩张

从数字地理学的视角切入，社交媒体的数据特征往往能够折射出区域经济水平与消费文化的图景。在剔除无效地理标记后，本文梳理了样本分布排名前列的省份（市），并观察到了“规模优势”与“传播效率高地”并非完全重合的现象。

从总量集聚来看，**广东省以 25,624 条记录确立了断档第一的大盘领跑属性**（超第二名几乎一倍）。这印证了珠三角庞大的电商与图文代运营产业链造就的内容生产渗透率。然而，从互动转化效率来看，其平均对数互动（5.23）却处于腰部水平，体现了过度商业化与内卷带来的流量互相稀释困境。

另一方面，**江浙沪与四川盆地构筑了“高生产质感 + 高互动黏性”的传播堡垒**。浙江（5.97）、四川（5.88）与上海（5.87）在拥有巨大基数的同时，维持了全局最高梯队的绝对互动均值。这在宏观上对应了此类核心地带用户对其输出的“精致生活方式（Lifestyle）”以及活跃“松弛社交文化（Chill Culture）”的向外辐射与强认同。

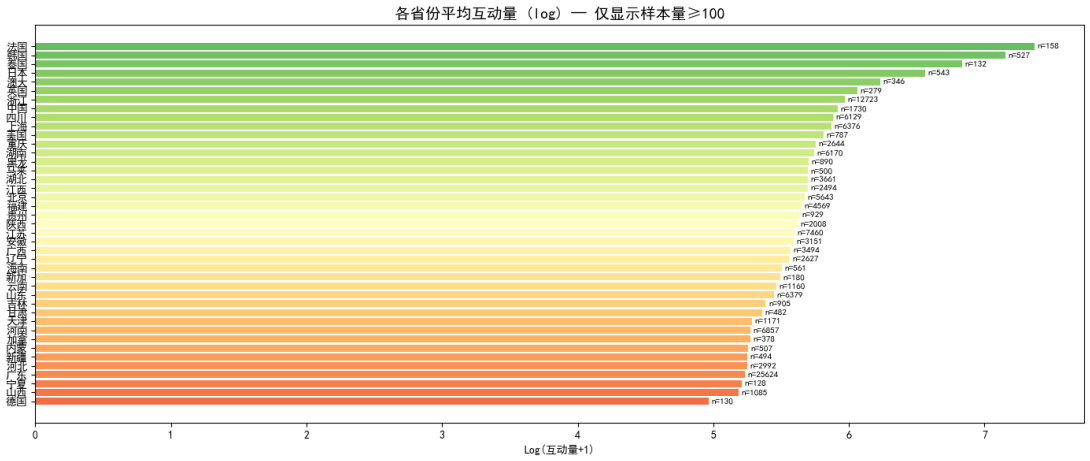


Figure 6.3: 小红书内容互动效能的地域热度解构

7. 标签策略与话题热度分析

7.1 标签使用策略分析

话题标签是小红书内容分类、搜索曝光和推荐分发的重要工具。合理使用标签能够将笔记精准推送给目标受众，同时借助热门标签获取泛流量。本部分旨在系统研究标签数量、类型组合及标签热度对笔记传播效果的影响，为创作者提供科学的标签策略指导。

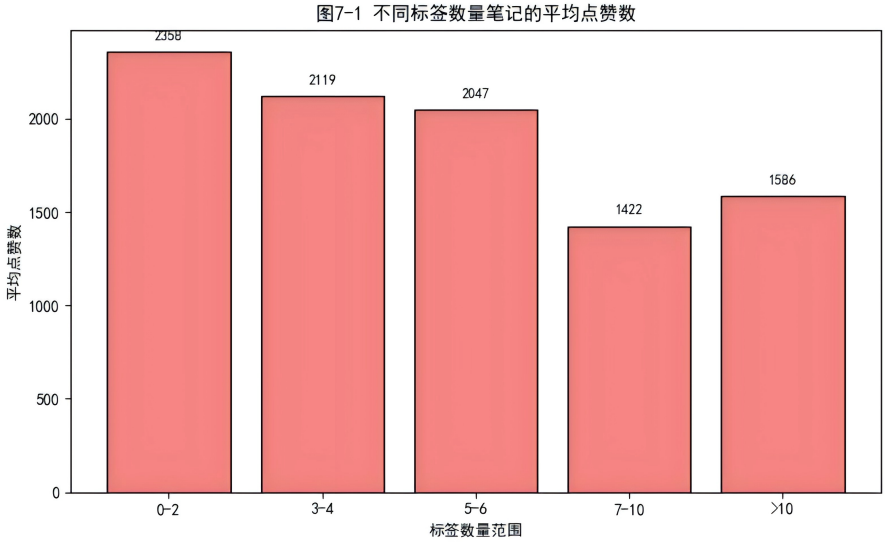


Figure 7.1: 不同标签数量笔记的平均点赞数

- **标签数量：**统计笔记使用的话题标签数量，分析其与热度的关系。过多标签可能被视为 spam，过少则可能降低曝光机会。统计每篇笔记包含的标签个数，构建连续特征。绘制标签数量的分布直方图，并统计不同标签数量区间下笔记的平均互动量，寻找

最优标签数量区间。

- **标签类型组合**：通过预定义的标签词库（基于数据中高频标签的聚类）将标签划分为以下类型：通用热门标签、垂直细分标签、地点标签、品牌标签等等。对每篇笔记，统计各类标签的数量。分析高热度笔记的标签组合策略，例如是否同时使用了“大流量泛标签”和“精准垂类标签”。使用关联规则挖掘或决策树模型，分析高热度笔记中标签类型的共现模式，识别典型的“黄金标签组合”。
- **标签热度**：计算每个标签在数据采集期间出现的总频次，作为其“基础热度”。分析笔记所带标签的平均热度或最高热度是否与笔记自身热度相关。将笔记按标签平均热度分位数分组，比较各组互动量的差异，并通过回归模型评估在控制粉丝数等因素后标签热度的边际贡献。

7.2 话题借势与热点响应分析

社交媒体内容传播具有显著的时效性，紧跟热点事件是获得爆发式流量的常见策略。然而，盲目“蹭热点”可能导致内容与账号定位不符，甚至引发用户反感。本部分旨在量化热点响应对笔记热度的实际增益，并探索最佳介入时机，为内容营销的时效性决策提供数据支撑。

- 效果对比：采用倾向得分匹配（PSM）或逆概率加权（IPW）等方法，为每篇“蹭热点”笔记匹配一组特征相似的非热点笔记，比较两组在发布后 72 小时内的平均互动量差异，从而得到热点响应的净效应。
- 时机效应分析：将热点笔记按介入阶段分组，使用方差分析比较各组互动量的均值，并通过回归模型控制其他因素，估计不同阶段的边际收益。同时，引入热点类型（节日型、事件型、娱乐型）与阶段的交互项，探究异质性。
- 生命周期建模：对每个热点事件，追踪其相关笔记的互动量随时间衰减曲线，使用生存分析或时序模型拟合热点的影响力衰减速度，为预测热点剩余价值提供依据。

对于高度相关的特征对（如相关系数绝对值大于 0.8），在后续建模中可能需要考虑只保留其中一个或进行降维处理。



8. 多维度相关性分析

8.1 特征间相关性分析

为避免原始文件、筛选文件及中间结果重复计入，本章仅读取文件名中包含“笔记详细信息”的数据，并优先按照笔记链接去重；链接缺失时，采用编号、标题和博主名称的组合去重。完成互动指标清洗后，共得到 182,103 条可用笔记，其中 168,323 条具有有效粉丝数。由于现有数据不包含可靠的图片数量、认证状态和发布小时，本章不对这些变量进行推断，而使用实际可获得的粉丝数、文本长度、标签数、标点与表情符号、情感得分、标题正文重合度、星期和地点完整性等特征。

考虑到互动量和粉丝数均呈明显长尾分布，本文分别构造

$$y = \log(1 + \text{engagement}), \qquad x_{fans} = \log(1 + \text{fans}),$$

并同时计算 Pearson 相关系数与 Spearman 秩相关系数。前者用于识别线性关系，后者对极端值更稳健，可用于判断变量之间是否存在稳定的单调关系。图8.1给出了特征间 Pearson 相关系数矩阵。

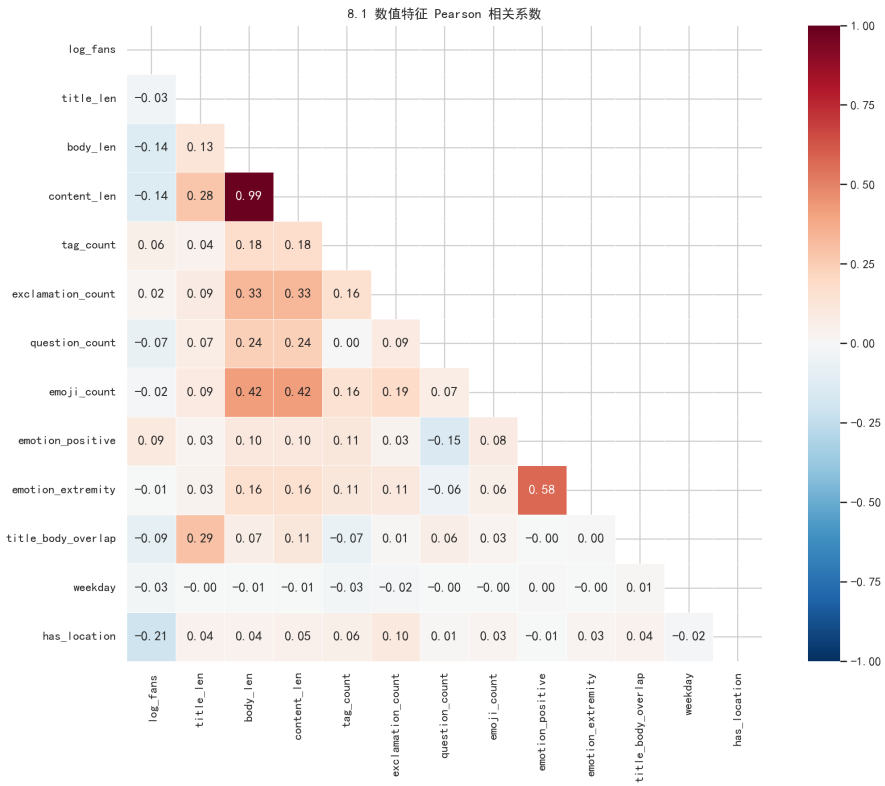


Figure 8.1: 数值特征间的 Pearson 相关系数矩阵

结果显示，正文长度与全文长度的相关系数达到 $r = 0.988$，是唯一满足 $|r| \geq 0.8$ 的特征对。这一高度相关主要源于全文长度由标题和正文共同构成，属于变量定义带来的机械相关。在后续多变量模型中不宜同时保留正文长度与全文长度，本文建议保留含义更完整的全文长度。其余变量之间未出现绝对相关系数超过 0.8 的组合，说明除长度变量外，当前特征集合不存在严重的两两线性共线性。需要强调的是，两两相关较低并不能完全排除多变量共线性，后续回归仍应结合 VIF 进行诊断。

8.2 特征与目标变量相关性分析

本文首先以对数互动量为连续型目标，分别计算各特征的 Pearson 和 Spearman 相关系数，并采用 Benjamini–Hochberg 方法对多重检验的 p 值进行 FDR 校正。图8.2按照 Spearman 相关系数绝对值展示变量排序。

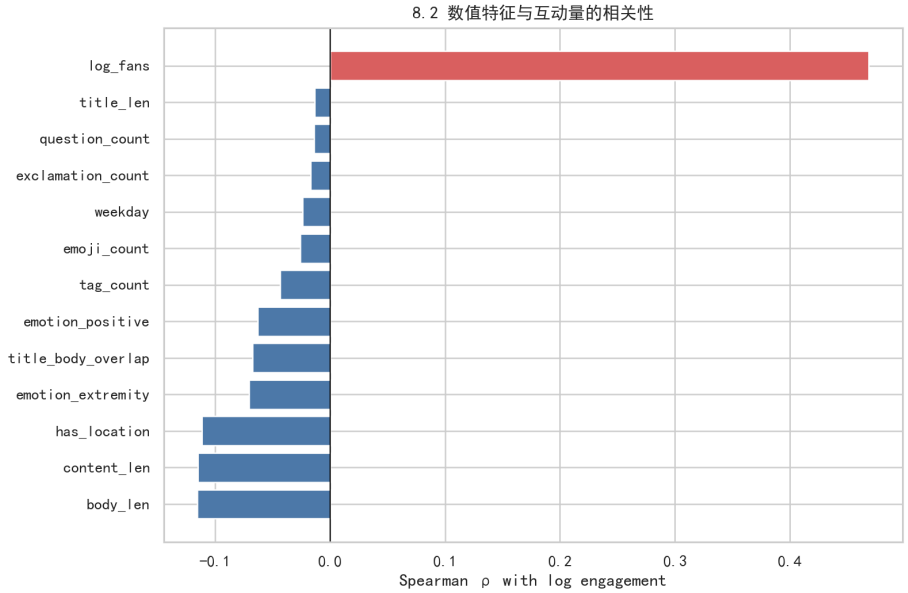


Figure 8.2: 数值特征与对数互动量的 Spearman 相关系数排序

粉丝数对数与对数互动量的相关性最强，Pearson 相关系数为 0.489，Spearman 相关系数为 0.469，均在 FDR 校正后显著。这表明发布者既有受众规模仍是笔记互动表现最重要的单一关联因素，但相关系数未达到高度相关水平，笔记热度并不能仅由粉丝基数解释。正文长度和全文长度与互动量呈弱负相关，Spearman 系数分别为 −0.116 和 −0.115；是否具有有效发布地点的系数为 −0.111。情绪极端程度、标题正文重合度和正向情感概率的 Spearman 系数分别为 −0.070、−0.068 和 −0.063，方向与第 3 章的回归结果基本一致，但效应强度较小。标签数量、表情符号、星期、感叹号和问号等变量的绝对相关系数均小于 0.05，统计显著性主要受大样本量影响，不宜解释为具有较强的实际作用。

为进一步比较高热度内容，本文将总互动量位于样本前 10% 的笔记定义为“爆款”，并对连续特征实施点二列相关、Welch 独立样本 t 检验和 Mann–Whitney U 检验，同时报告 Cohen's d。粉丝数对数的组间差异最明显：普通组均值为 7.613，爆款组均值为 9.589，$d = 0.696$，属于中等偏大的效应。相比之下，爆款组正文长度和全文长度更短，对应效应量分别为 −0.213 和 −0.211；标签数量、情绪极端程度与表情数量的效应量绝对值约为 0.12 至 0.14，其余变量的效应量更小。问号数量和星期编码在 FDR 校正后均未表现出稳定的爆款组差异。

星期编码本身不适合作为严格连续变量解释，因此本文另行进行分组描述。如图8.3所示，周六和周日的爆款比例分别为 10.91% 和 10.86%，周一为 10.42%，周五最低，为 8.54%。该结果说明星期差异主要体现为类别间波动，而非随编码增加或减少的线性趋势。

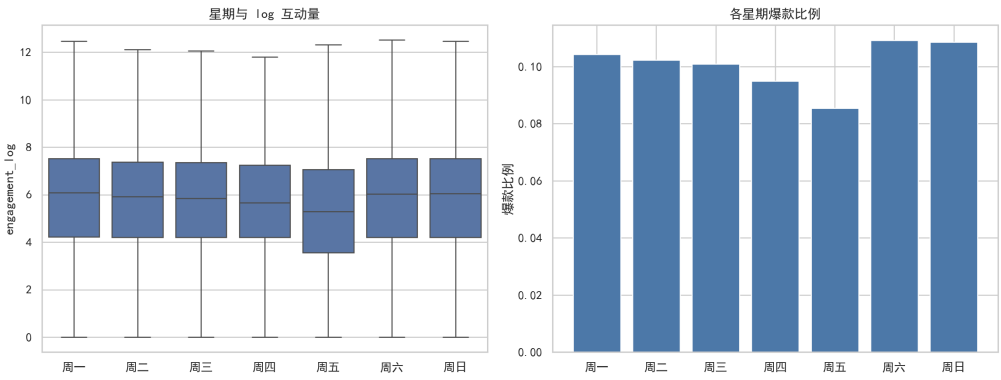


Figure 8.3: 不同星期的互动量分布与爆款比例

总体而言，粉丝规模是与互动量及爆款状态关联最稳定的特征；文本长度表现出弱负相关；情感、标签及格式变量虽然在大样本下多达到统计显著，但实际效应普遍较弱。因此，后续预测模型不应仅根据 p 值筛选变量，而应综合考虑效应量、非线性结构与变量的理论意义。

8.3 非线性关系探索

线性相关系数可能掩盖阈值、平台期或转折关系。为此，本文对粉丝数对数、全文长度、标签数量、正向情感概率、情绪极端程度和标题正文重合度进行 LOWESS 局部加权平滑，并将全部有效样本划分为 20 个分位数组计算组内平均互动。为减少极端值对曲线边界的影响，作图时剔除各自变量上下 0.5% 的观测；散点和 LOWESS 最多随机抽取 20,000 条记录，而分位数组均值仍使用全部有效数据。

图8.4展示了粉丝规模与文本长度的主要非线性形态。粉丝数对数与互动量总体呈明显正向关系，但曲线并非全程保持相同斜率，说明粉丝增长带来的互动增量存在阶段差异。全文长度曲线则表现出较明显的弯曲：短文本区间互动水平相对较高，随着长度增加先下降，随后在部分较长文本区间趋于平缓或出现局部回升。这与第 3.1 节在 OLS 中加入长度平方项后得到的非线性结论相互印证。

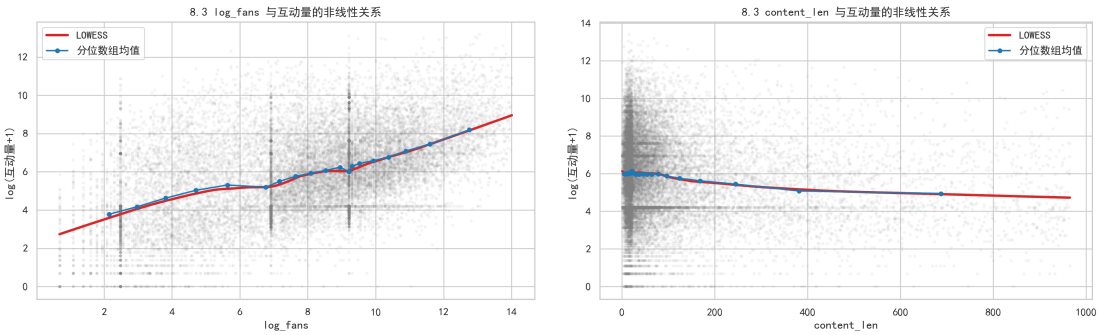


Figure 8.4: 粉丝规模与全文长度的 LOWESS 非线性关系

情绪极端程度的 LOWESS 结果见图8.5。总体趋势显示，越偏离中性区间，平均对数

互动量越低，但局部区间存在波动。这说明情感效应不宜简单表述为严格线性下降，更适合在后续模型中使用二次项、限制性立方样条或树模型检验。标签数量、正向情感概率和标题正文重合度也呈现不同程度的局部弯曲，但其总体变化幅度明显小于粉丝规模和文本长度。

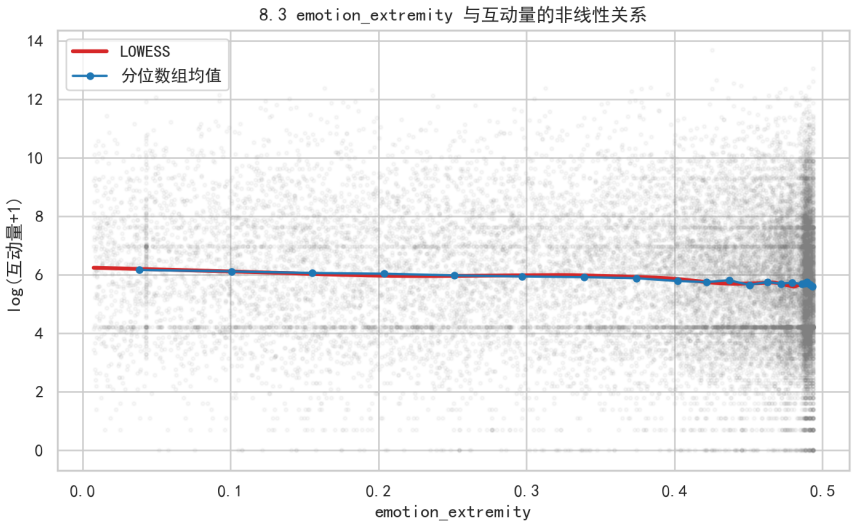


Figure 8.5: 情绪极端程度与互动量的 LOWESS 关系

需要指出，LOWESS 属于探索性可视化方法，曲线形态不能直接证明因果关系。账号粉丝基础、内容类别、采集时间以及平台推荐机制都可能同时影响文本特征和互动结果。因此，本节的非线性发现主要用于为后续模型设定提供依据，而不将曲线转折点直接解释为普遍适用的内容运营最优值。



9. 特征选择与重要性评估

9.1 基于统计检验的初步筛选

在构建复杂的机器学习模型之前，通过统计检验对大量原始特征进行初步筛选, 可以剔除与目标变量无关或相关性极弱的特征，降低维度、减少噪声，并提高后续建模的效率与可解释性。本部分将根据任务类型（回归或分类）采用不同的统计检验方法。

- **针对回归任务（预测互动量）**：数值型特征：对每个数值特征 x，计算其与目标变量 y（通常取对数化后的点赞数）的皮尔逊相关系数 r 及显著性 p 值。若 $p < 0.05$，则认为该特征与目标存在显著线性相关，予以保留；否则剔除。由于皮尔逊相关对线性关系敏感，对于可能呈非线性关系的特征（如标签数量），可同时计算斯皮尔曼秩相关系数作为补充。分类型特征：对于类别型特征，使用单因素方差分析（ANOVA）检验不同类别下目标变量均值是否存在显著差异。若 F 检验的 $p < 0.05$ ，则保留该特征；否则剔除。对于类别数较多的特征，可先合并低频类别后再进行检验。
- **针对分类任务（预测是否爆款）**：数值型特征：将样本按爆款标签分为两组，首先进行正态性检验（Shapiro- Wilk 或 Kolmogorov-Smirnov）。若两组数据均近似正态分布，则使用独立样本 t 检验比较均值差异；若任一组的分布非正态，则使用 Mann-Whitney U 检验比较中位数差异。保留 $p < 0.05$ 的特征。分类型特征：构建特征与爆款标签的列联表，进行卡方独立性检验。若 $p < 0.05$，则拒绝原假设（特征与爆款独立），保留该特征。对于有序分类特征（如星期几），可同时进行趋势卡方检验。

9.2 基于机器学习模型的特征重要性评估

统计检验主要捕捉特征与目标之间的线性或单调关系，而机器学习模型能够自动学习复杂的非线性模式及特征间的交互作用。通过多种模型的内部机制，我们可以获得更全面、

更稳健的特征重要性排序，为最终构建可解释的预测模型和提出优化策略提供依据。

- **树模型的重要性：**随机森林（Random Forest）：训练回归或分类随机森林模型，获取基于基尼不纯度减少（或均方误差减少）的特征重要性评分。该评分衡量了每个特征在树节点分裂时减少不纯度的累计贡献。通过交叉验证选择树的数量和最大深度等超参数；梯度提升树：训练 XGBoost 或 LightGBM 模型，获取基于分裂增益（gain）的特征重要性，即每个特征在每次分裂时带来的平均损失减少量。该指标比基于分裂次数的权重更能反映特征的预测能力。
- **正则化线性模型：** Lasso 回归（L1 正则化）：对特征进行标准化后，训练 Lasso 回归模型。Lasso 通过 L1 惩罚项将部分特征的系数压缩为零，从而实现嵌入式特征选择。保留系数非零的特征，其绝对值大小反映了特征对预测的贡献程度。由于 Lasso 对线性关系敏感，可与树模型的结果互补。
- **模型不可知解释方法：** SHAP 值：基于博弈论中的 Shapley 值，为每个样本的每个特征分配一个贡献值，表示该特征对预测结果的边际贡献。计算所有样本的 SHAP 值绝对值平均值，得到全局特征重要性排序。SHAP 值不仅能反映重要性，还能通过依赖图展示特征与预测值的关方向及非线性模式。对于 XGBoost 或随机森林模型，可使用 TreeExplainer 高效计算 SHAP 值。

将上述三种方法得到的重要性评分进行归一化处理，并采用加权平均或排名平均的方法获得综合重要性得分。设定阈值，筛选出核心特征集。同时，观察不同方法的一致性：若某个特征在多种方法中均排名靠前，则其重要性更为可信。

Part IV: 基于机器学习的笔记热度分类预测模型

10 基准分类模型 57

10.1 预测问题描述
10.2 逻辑回归
10.3 支持向量机
10.4 集成学习模型
10.5 深度学习模型
10.6 实证设置与基准结果

11 针对小红书数据特点的模型改进 61

11.1 类别不平衡与代价敏感学习
11.2 阈值优化与概率校准
11.3 特征表达与多模态扩展
11.4 社交传播与时间外验证

12 模型评估、比较与结论 63

12.1 评估口径
12.2 混淆矩阵与错误结构
12.3 综合比较与模型选择
12.4 稳健性、局限与本部分结论



10. 基准分类模型

10.1 预测问题描述

在小红书内容传播效果研究中，一个核心任务是根据笔记的多维度特征（如内容、形式、发布者、时间、标签等）预测其是否具有高互动潜力。我们将此任务定义为二分类问题：给定一篇笔记的特征向量，模型需要预测其属于“高热度”（如互动量位于前 20% 的爆款）还是“普通热度”类别。这比直接预测连续互动量更稳健，能有效处理极端值并服务于实际的二元决策（如是否加大推广）。通过构建和比较多种经典分类模型，我们可以识别出对预测贡献最大的特征，并理解各因素与热度之间的复杂关系，为内容优化提供可解释的洞见。

10.2 逻辑回归

逻辑回归（Logistic Regression）是解决二分类问题最基础的线性模型，以其简单、高效和高可解释性著称。尽管其假设特征与对数几率间存在线性关系，限制了其捕捉复杂非线性模式的能力，但作为基准模型，它能快速提供特征重要性的初步排序（通过系数大小和方向），帮助我们理解各因素对成为爆款的边际贡献。在处理小红书笔记分类时，逻辑回归可首先用于验证特征工程的合理性，并为后续复杂模型提供性能比较的基准。

- **模型原理**：通过 Sigmoid 函数将特征的线性组合映射到 (0,1) 区间，输出样本属于正类（高热度）的概率。决策边界为线性超平面。
- **优势**：计算速度快，模型参数（系数）直接可解释，能直观看出各特征对结果的正/负向影响及相对强度。
- **局限**：无法自动捕捉特征间复杂的交互作用和非线性关系，对数据线性可分性要求较高。

10.3 支持向量机

支持向量机（Support Vector Machine, SVM）通过寻找最大化分类间隔的最优超平面来实现分类，在处理高维、非线性问题上表现优异。对于小红书笔记数据，其高维特征（如文本向量、多标签）和潜在的非线性关系（如图片数量与热度的倒 U 型关系）使 SVM 成为一个强有力的基准模型。

- **核技巧**：通过引入高斯径向基函数（RBF）等核函数，SVM 能将原始特征空间映射到更高维度，从而在变换后的空间中找到一个线性分界超平面，有效处理原始空间中的非线性模式。
- **优势**：在高维空间中表现良好，泛化能力强，尤其适用于样本量不是特别巨大的情况。通过调整正则化参数 C 和核函数参数，可以灵活控制模型复杂度。
- **应用**：在小红书笔记分类中，SVM 可以学习到内容质量、发布者影响力、发布时间等特征之间复杂的相互作用，以区分爆款与普通笔记。

10.4 集成学习模型

集成学习通过结合多个基学习器的预测结果，获得比单一模型更稳定、更准确的强学习器，非常适合处理小红书笔记分类中特征多样、模式复杂的问题。

10.4.1 随机森林

随机森林（Random Forest）通过自助采样（Bootstrap）构建多棵决策树，并综合所有树的投票结果进行分类。其引入的随机特征选择有效降低了模型的方差，防止过拟合。

- **优势**：能处理高维数据，对缺失值不敏感，无需复杂的数据预处理。模型可提供特征重要性评分，有助于我们识别影响热度的关键因素（如封面图质量、特定话题标签）。
- **应用**：在小红书场景下，随机森林可以同时评估文本、视觉、上下文等数百个特征，并给出重要性排序，例如可能发现“发布时段”和“标题情感”的交互作用对热度预测至关重要。

10.4.2 梯度提升决策树

梯度提升决策树（Gradient Boosting Decision Trees, GBDT）及其高效实现（如 XGBoost, LightGBM）以串行方式迭代训练决策树，每一棵新树都致力于纠正前一棵树的残差。

- **优势**：预测精度通常高于随机森林，能自动处理特征的非线性关系和交互作用，且通过正则化控制模型复杂度。XGBoost 和 LightGBM 在计算效率和内存使用上进行了大量优化，适合处理大规模数据集。
- **应用**：对于拥有海量笔记数据的小红书研究，LightGBM 能快速训练并高效处理类别型特征（如发布城市、星期几）。其输出的特征重要性（基于分裂增益或覆盖度）能深度揭示各因素对笔记热度的贡献，例如可能精确量化“使用特定热门标签”对互动量的提升幅度。

10.5 深度学习模型

深度学习模型能自动从原始或初级特征中学习高级表示，特别适合处理小红书笔记中的非结构化数据（如文本、图像）。

10.5.1 多层感知机

多层感知机（Multilayer Perceptron, MLP）是最基本的深度学习模型，由全连接层和非线性激活函数堆叠而成。它可以作为深度学习方法的入门基准，用于验证经过特征工程的结构化数据是否包含足够预测信息。

- **优势**：能够学习特征间的复杂非线性组合，相比逻辑回归具有更强的表示能力。
- **应用**：可将经过预处理和特征工程的所有数值和类别特征（经过编码后）输入 MLP，作为与其他更复杂深度学习模型对比的基线。

10.5.2 卷积神经网络

卷积神经网络（Convolutional Neural Network, CNN）在图像处理领域取得巨大成功，但其局部感知和参数共享的思想也可应用于一维序列数据。

- **应用**：对于文本数据，可将词嵌入序列视为一维“图像”，使用一维 CNN 来提取短语级别的局部语义特征。对于图像特征，可以直接使用预训练的 CNN（如 ResNet）提取的深度特征向量作为输入的一部分。CNN 能有效捕捉如“标题中的特定关键词组合”或“封面图中同时出现人脸和产品”等局部模式对热度的信号。

10.5.3 循环神经网络

循环神经网络（Recurrent Neural Network, RNN）及其变体长短期记忆网络（LSTM）专门为序列数据设计，能捕捉时间或顺序上的依赖关系。

- **应用**：在小红书笔记分类中，LSTM 可用于建模文本的序列信息（如正文的语义流），或建模用户历史行为序列（如发布者过去笔记的互动趋势）以捕捉其内容质量的时序演变。然而，对于单篇笔记的静态特征分类，LSTM 的优势可能不如 CNN 或 MLP 明显，除非考虑时间上下文（如当前热点话题）。

10.6 实证设置与基准结果

为将上述模型由方案说明落实为可复现实验，本文读取工作区三个业务数据压缩包中的笔记详情表，合并后共得到 323,598 条原始记录。按笔记链接（无链接时按编号、标题和博主）去重并剔除互动指标缺失或为负的记录后，保留 199,473 条有效笔记。互动量定义为“点赞数 + 收藏数 +4× 评论数”，达到全样本第 80 百分位（2,134）的笔记记为高热度，正类比例为 20.01%。建模输入仅使用发布前或内容本身可获得的 10 项特征，包括粉丝量对数、标题和正文长度、标签数、感叹号数、问号数、Emoji 数、情感得分、星期和是否标注发布地；点赞、收藏和评论没有作为输入，以避免目标泄漏。

考虑计算成本，从有效数据中按类别分层抽取 60,000 条用于比较，再按 8:2 分层随机划分训练集与测试集。数值缺失以训练集的中位数填补；逻辑回归、线性 SVM 和 MLP

同时进行标准化。逻辑回归与 SVM 使用类别权重平衡，随机森林使用 300 棵树，梯度提升采用直方图梯度提升分类器，MLP 包含 64 和 32 个神经元的两个隐藏层并使用早停。表10.1报告固定测试集结果。鉴于正类仅占约 20%，模型选择以 PR-AUC 为主，ROC-AUC、F1、精确率和召回率为辅。

Table 10.1: 第 10 章基准分类模型测试集结果

模型	ROC-AUC	PR-AUC	F1	精确率	召回率
逻辑回归	0.700	0.405	0.414	0.303	0.649
线性 SVM	0.700	0.406	0.413	0.302	0.651
随机森林	0.725	0.424	0.373	0.479	0.305
梯度提升树	**0.736**	**0.440**	0.263	**0.600**	0.169
多层感知机	0.718	0.423	0.299	0.562	0.203

梯度提升树的排序能力最佳（PR-AUC=0.440，ROC-AUC=0.736），说明结构化特征与热度之间存在明显的非线性关系；随机森林和 MLP 次之。逻辑回归与线性 SVM 的 PR-AUC 接近，但在类别加权后召回率均约为 0.65，更适合“尽量不漏掉潜在爆款”的初筛场景。梯度提升树默认阈值下精确率最高而召回率较低，若用于候选内容筛选，应在验证集上按业务成本降低分类阈值，而不能只依据默认 0.5 阈值下的 F1 作结论。

本轮完成了 10.1 至 10.5.1 的可运行实证。10.5.2 的 CNN 与 10.5.3 的 RNN/LSTM 未给出数值结果：现有压缩包没有与每条笔记稳定对应的原始图片张量或发布者连续历史序列，直接把静态汇总特征重塑为“图像”或伪序列会制造不具业务含义的结构。虽然正文文本可形成词序列，但在没有独立时间外测试和文本模型调参预算的条件下，其结果不能与本节结构化基准作公平比较。因此本研究保留 CNN 与 RNN 的模型设计说明，待补齐图片、严格的用户历史序列和时间切分后再实施，避免报告不可复现或误导性的深度模型成绩。



11. 针对小红书数据特点的模型改进

第 10 章的实证结果表明，仅使用发布前可获得的结构化特征，模型已经能够形成高于随机排序的有效判别能力，但类别不平衡、特征表达有限和决策阈值固定仍然制约实际效果。本章据此给出与现有数据相匹配的改进方案，并明确哪些方法已经在基准实验中落实、哪些方法需要新增数据后才能实施。

11.1 类别不平衡与代价敏感学习

本研究将互动量位于前 20% 的笔记定义为高热度样本，因此正负样本比例约为 1:4。若仅追求总体准确率，把所有笔记判为普通类即可获得约 80% 的准确率，却完全失去识别爆款的能力。因此，实验没有把准确率作为核心指标，而是以 PR-AUC 衡量少数类的排序质量，并同时报告精确率、召回率与 F1。

在模型训练阶段，逻辑回归和线性 SVM 采用与类别频率成反比的类别权重。该设置使两种线性模型在测试集上的召回率分别达到 0.649 和 0.651，显著高于其他模型默认阈值下的召回率，说明代价敏感学习能够减少潜在爆款的漏判。不过，召回率的提高伴随着较多假阳性：逻辑回归和线性 SVM 分别产生 3,579 和 3,611 个假阳性样本。因此，这两类模型更适合低成本初筛，而不宜直接用于高成本投放决策。

本研究没有对当前 10 项结构化特征直接使用 SMOTE。其原因是星期、是否标注发布地等变量具有离散语义，简单线性插值可能生成缺乏真实含义的合成样本；同时，过采样若在数据划分前进行，还会造成训练集与测试集之间的信息污染。若后续比较 SMOTE、SMOTEENN 或 EasyEnsemble，应只在每个训练折内部完成重采样，并保持验证集和测试集的原始类别分布。

11.2 阈值优化与概率校准

表10.1中的精确率、召回率和 F1 均基于 0.5 分类阈值，但 0.5 并不是所有业务场景的最优选择。梯度提升树在该阈值下的精确率达到 0.600，召回率却只有 0.169，表明模型给出的高分样本较可靠，但大量真实爆款仍位于阈值以下。相反，类别加权的线性模型召回率较高，却需要承担更高的误报成本。

因此，实际应用应先在独立验证集上确定阈值，再锁定阈值并在测试集报告一次最终结果。若目标是为运营人员生成数量有限的候选清单，可选择较高阈值或直接按预测概率取 Top-K，优先保证精确率；若目标是尽可能覆盖潜在爆款，可降低阈值并为漏判设置更高成本。进一步应用时，还应使用 Platt 缩放或保序回归检查概率校准，使“预测概率为 0.6”具有可解释的实际发生频率，而不仅是排序分数。

11.3 特征表达与多模态扩展

随机森林的重要性结果显示，粉丝量对数的重要性为 0.310，居所有特征首位；情感得分、正文长度和标题长度的重要性依次为 0.181、0.131 和 0.108。四项特征合计贡献约 73% 的重要性，说明发布者基础影响力和内容表达共同决定了现有模型的主要判别信号。标签数、星期和标点符号等特征提供了补充信息，但单独贡献相对有限。

这一结果也揭示了现有特征工程的边界。长度、符号计数和单一情感得分只能描述文本表层形式，无法识别主题、叙事结构、产品实体与图文一致性。后续可采用中文预训练语言模型编码标题和正文，使用 CLIP 或视觉主干网络提取封面及配图特征，再将文本、图像和结构化特征分别建模。数据量有限时可采用晚期融合，即对各模态子模型的概率进行加权或堆叠；拥有稳定配对的大规模图文数据后，再比较带跨模态注意力的中期融合。所有模态必须通过同一笔记的稳定标识关联，无法可靠匹配的图片或文本不得强行并入训练样本。

11.4 社交传播与时间外验证

热度不仅由笔记内容决定，还受到发布者历史表现、粉丝构成和平台阶段性流量的影响。若后续能够获得按时间排序的用户历史，可构造近 7 天、30 天和 90 天的历史互动统计，并确保每条样本只使用其发布时间之前的信息。若能够获得用户---笔记交互边，还可构建二部图并使用 GraphSAGE 等方法学习传播结构表示，但发布后的点赞、收藏和评论边不能用于发布前预测，否则会形成目标泄漏。

当前基准实验采用分层随机划分，适合在固定样本分布下比较算法，但可能高估模型面对未来内容时的稳定性。部署前应补充按发布时间的训练集、验证集和测试集划分，并按博主分组检查同一发布者是否跨集合出现。只有当模型在时间外测试中仍保持稳定的 PR-AUC 和召回率，才能说明其学习到的规律具有跨时期泛化能力。



12. 模型评估、比较与结论

12.1 评估口径

分类评估以高热度笔记为正类。精确率表示被模型判为高热度的笔记中真实高热度笔记的比例，召回率表示全部真实高热度笔记中被模型识别出的比例，F1 为二者的调和平均。ROC-AUC 衡量随机抽取一条正样本和一条负样本时模型将正样本排在前面的概率；PR-AUC 则聚焦正类，更能反映类别不平衡场景下精确率与召回率的权衡。

测试集包含 12,000 条笔记，其中高热度笔记 2,401 条，正类比例为 20.01%。因此，随机排序的 PR-AUC 基线约为 0.200；五个模型的 PR-AUC 均在 0.405 以上，说明它们均提取到了有效预测信号。与此同时，任何单一阈值下的准确率都可能被 9,599 条负类样本主导，故本研究不以准确率决定最优模型。

12.2 混淆矩阵与错误结构

Table 12.1: 不同模型在测试集上的混淆矩阵

模型	TN	FP	FN	TP
逻辑回归	6,020	3,579	842	1,559
线性 SVM	5,988	3,611	838	1,563
随机森林	8,801	798	1,668	733
梯度提升树	9,329	270	1,996	405
多层感知机	9,219	380	1,913	488

表12.1揭示了不同模型的错误偏好。逻辑回归与线性 SVM 识别出的真实爆款最多，真

阳性分别为 1,559 和 1,563，但其假阳性也超过 3,500 条。梯度提升树只有 270 个假阳性，是五个模型中误报最少的，同时漏掉 1,996 条真实爆款。随机森林处于两者之间，真阳性为 733，假阳性为 798。由此可见，不存在脱离业务成本而绝对最优的固定阈值分类器：线性模型偏向覆盖，树模型偏向谨慎。

12.3 综合比较与模型选择

从阈值无关的排序指标看，梯度提升树的 PR-AUC 为 0.440、ROC-AUC 为 0.736，均列第一，应作为结构化特征场景下的首选排序模型。相较正类比例 0.200 的随机基线，其 PR-AUC 提高约 0.240；相较逻辑回归，PR-AUC 提高 0.035，说明非线性关系与特征交互带来了稳定增益。随机森林和多层感知机的 PR-AUC 分别为 0.424 和 0.423，二者接近，但随机森林训练更快且更容易解释，可作为性能与可解释性之间的折中方案。

从默认阈值下的分类结果看，梯度提升树以 0.600 取得最高精确率，适合误报成本较高、候选名额有限的场景；线性 SVM 以 0.651 取得最高召回率，适合漏判成本较高的初筛场景；逻辑回归的 F1 为 0.414，在五个模型中最高，且系数方向便于解释，可作为透明度要求较高的基准决策模型。MLP 没有超过树模型，说明在当前 10 项表格型特征上增加网络复杂度并未转化为更好的泛化性能。

Table 12.2: 分类模型的场景化选择建议

应用目标	推荐模型	选择依据
有限名额的精准推荐	梯度提升树	PR-AUC 与 ROC-AUC 最高，默认阈值下精确率最高，可进一步采用 Top-K 输出
潜在爆款的广覆盖初筛	线性 SVM 或逻辑回归	召回率约 0.65，能够找出更多真实爆款，但需接受较高误报率
兼顾性能与解释	随机森林	PR-AUC 达到 0.424，可通过特征重要性说明主要预测依据
概率化运营决策	校准后的梯度提升树	先在验证集完成阈值选择与概率校准，再按误报和漏报成本决策

12.4 稳健性、局限与本部分结论

本轮比较使用相同的 60,000 条分层样本、训练测试划分和 10 项无泄漏特征，模型间横向比较是公平的；数据审计、模型指标、分类报告和特征重要性均可由第 10 章 Notebook 复现。当前结论仍有三项限制：随机划分不能替代时间外验证；模型尚未纳入完整文本、图像和传播网络；F1、精确率和召回率依赖 0.5 阈值，不能代表调阈后的最佳业务效果。

综合而言，粉丝基础、情感得分和内容长度是现有模型的主要预测信号。梯度提升树排序能力最佳，线性模型覆盖率更高，随机森林则兼顾性能与解释性。本研究由此形成“梯度提升排序、验证集选阈值、场景化输出、时间外复核”的流程。至此，第 10 章完成模型构建，第 11 章完成改进设计，第 12 章完成统一评估与选择，分类模型部分形成闭环。

PartV: 小红书帖子热度预测模型

13 基准模型 67

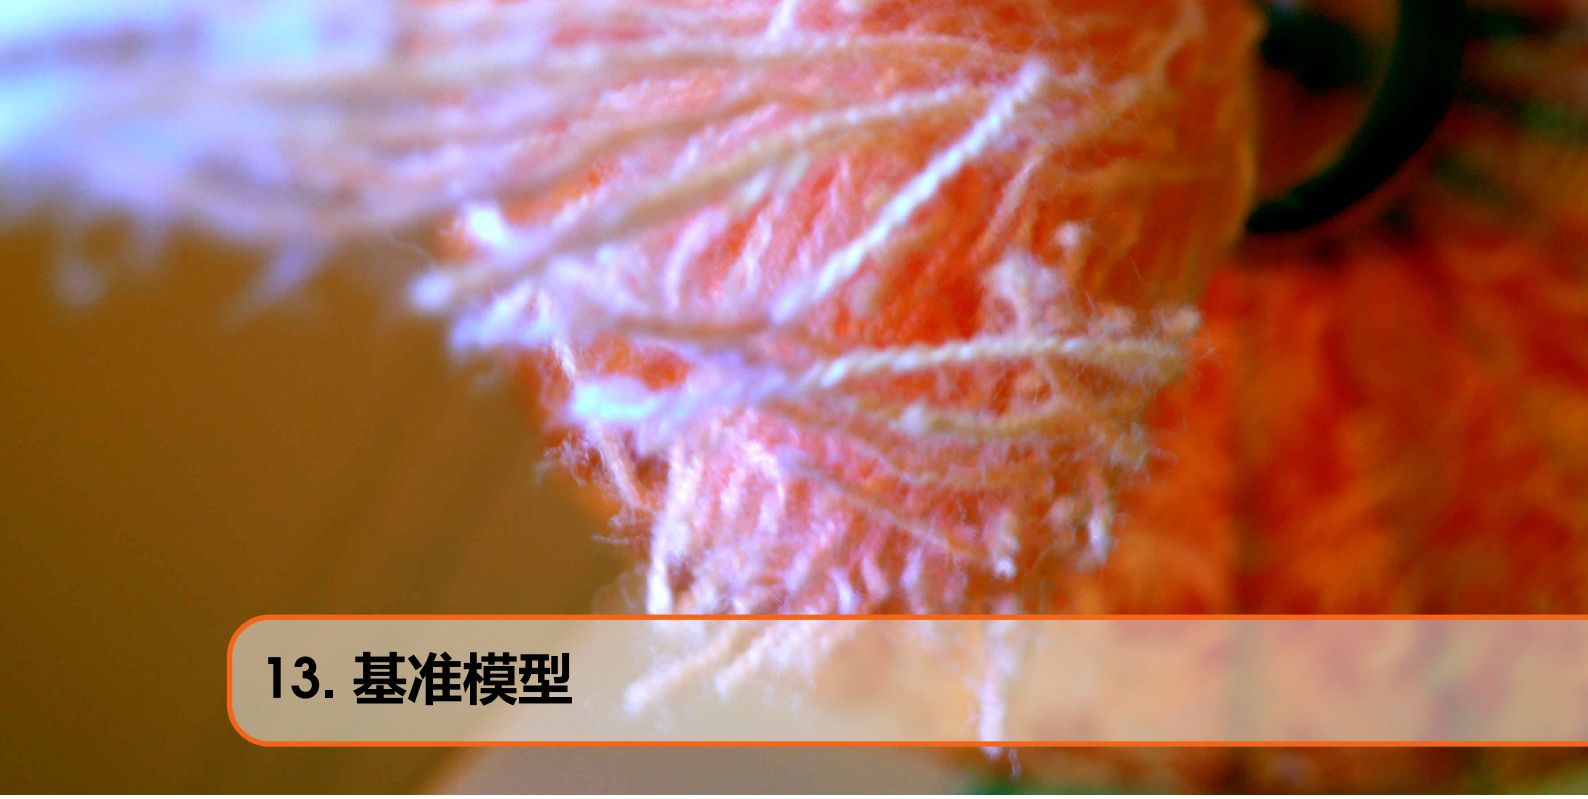
13.1 预测问题描述
13.2 线性回归模型
13.3 支持向量回归（SVR）
13.4 集成学习模型（Random Forest, XGBoost, LightGBM）
13.5 深度学习模型（LSTM, TextCNN, BERT）
13.6 其他模型

14 改进模型设计方案 73

14.1 模型架构设计

15 热度回归模型实证 75

15.1 任务定义与数据处理
15.2 模型与评估指标
15.3 基准结果与模型比较
15.4 可解释性、局限与应用建议



13. 基准模型

13.1 预测问题描述

小红书帖子热度预测的核心目标是预测帖子在未来某个时间点的观看量、点赞数、收藏数等互动指标，这是一个典型的回归预测问题。与简单的热门/非热门二分类预测不同，回归预测旨在提供连续的数值输出，这对于内容创作者优化发布策略、品牌方评估广告投放效果以及平台优化推荐算法具有更直接的指导意义。在社交媒体营销的实际应用中，热度预测的应用场景非常广泛。例如，在内容发布前，可以根据历史数据特征预测潜在热度，辅助创作者优化标题、标签和发布时间；在发布后短时间内，可以基于早期互动数据预测最终热度，为实时流量分配和推荐加权提供依据。

本研究的建模思路是，首先构建一个包含多维特征的输入向量，这些特征可以包括内容文本特征（标题情感、关键词密度、文本长度）、视觉特征（图片数量、图片质量评分、是否包含人脸/产品）、时间特征（发布时段、星期几、是否为节假日）、空间特征（发布地点热度、地理标签）、社交特征（粉丝数、历史发帖频率、账号垂直度）以及标签特征（tag 数量、tag 热度、tag 与内容相关性）等。然后，选择合适的回归模型来学习这些特征与帖子热度指标之间的复杂非线性关系。我们将重点考察支持向量回归（SVR）、梯度提升树（GBDT）和深度学习模型（如 LSTM、Transformer）在这一任务中的表现。SVR 通过其独特的 ε-不敏感损失函数，能够在拟合精度和模型泛化能力之间取得良好的平衡，对社交媒体数据中的噪声和异常值具有较强的鲁棒性。而 LSTM 和 Transformer 则擅长捕捉时间序列数据中的长期依赖关系，能够从用户互动序列中学习到潜在的传播动态模式。通过对这些模型的构建、训练和评估，我们期望能够开发出预测精度高、稳健性强的小红书帖子热度预测模型，为后续的内容优化策略和精准营销提供坚实的基础。

为了全面评估所提出模型的性能，我们将构建一系列具有代表性的基准模型，涵盖从

传统统计方法到现代机器学习和深度学习模型。这些基准模型将作为比较的基准，以衡量我们改进模型的有效性。

结合不同学习算法预测，建立一套多维度预测系统。

机器学习：KNN, SVR, Linear Regression, Ridge, Lasso, Elastic Net, Decision Tree, Extra Trees

深度学习：LSTM, GRU, BPNN, CNN, TextCNN, BERT, RoBERTa

集成学习：AdaBoost, GBDT, Bagging, Extra Trees, XGBoost, LightGBM, CatBoost, Random Forest

宽度学习：Broad Learning System (BLS)

13.2 线性回归模型

线性回归模型是回归分析中最基础、最经典的模型。它假设因变量（如帖子点赞数或观看量）与一个或多个自变量（如字数、图片数、tag 数）之间存在线性关系。该模型的优点是形式简单、易于实现和解释，计算效率高，能够快速提供特征与热度之间的边际效应分析。在社交媒体分析领域，线性回归常被用作初步探索变量之间关系的工具，或作为更复杂模型的基准。例如，可以用来量化" 每增加一张图片平均能带来多少额外点赞" 或" 晚间发布相比午间发布的热度差异"。

然而，其最大的局限性在于线性假设，这使其难以捕捉社交媒体数据中普遍存在的非线性关系（如 tag 数量与热度之间可能存在的倒 U 型关系）。此外，线性回归对异常值（如偶然爆红的 viral content）和多重共线性（如粉丝数与历史平均点赞数高度相关）较为敏感，这可能会影响其预测的准确性和稳健性。尽管如此，由于其简单性和可解释性，线性回归模型仍然是一个重要的基准，可以用来评估更复杂模型在处理非线性问题上的增益，并为特征重要性提供直观的理解。

13.2.1 经典线性模型

普通最小二乘法（OLS）线性回归将作为最基础的基准模型，用于建立特征与热度指标之间的线性映射关系。

13.2.2 正则化线性模型

引入 L1 正则化（Lasso）和 L2 正则化（Ridge）的线性模型，用于处理特征多重共线性问题并进行特征选择，防止在多维社交媒体特征场景下过拟合。

13.3 支持向量回归（SVR）

支持向量回归（Support Vector Regression, SVR）是支持向量机（SVM）在回归问题上的重要应用，它继承了 SVM 在处理小样本、非线性及高维模式识别问题中的诸多优势。SVR 的核心思想是寻找一个最优的回归函数（或称为超平面），使得所有训练样本点与该函数之间的偏差最小，同时保证模型的泛化能力。其最大的创新在于引入了"ε-不敏感损失

函数"（ε-insensitive loss function）。该函数设定了一个宽度为 2ε 的" 容忍带"，只有当预测值与真实值之间的误差超出这个容忍带时，才会计算损失并进行惩罚。这种机制使得模型对容忍带内的小误差不敏感，从而提高了对噪声数据的鲁棒性，并使得模型解具有稀疏性，即只有少数" 支持向量" 对最终的回归函数有贡献。

在小红书热度预测中，这种特性尤为重要，因为社交媒体数据往往包含大量噪声（如随机流量波动、机器人账号干扰）。SVR 能够有效地捕捉内容特征（如情感极性、视觉美学）与热度指标之间复杂的非线性关系，克服了简单线性模型的局限性。

SVR 模型有三个关键参数需要调优：

- 容忍带宽度 (ε)：ε 决定了对误差的容忍程度。ε 越小，模型对拟合精度的要求越高，可能导致模型复杂、过拟合；ε 越大，模型越简单，但可能欠拟合。在小红书数据中，由于热度分布通常呈现长尾特性，需要谨慎设置以避免对高热度异常值过度敏感。
- 惩罚系数 (C)：C 控制了对超出容忍带的样本的惩罚力度。C 越大，对误差的惩罚越重，模型倾向于将所有样本都拟合好，可能过拟合；C 越小，允许更多的误差，模型泛化能力可能更强。考虑到小红书帖子热度的极端方差，C 的选择需要平衡对 viral content 的拟合能力。
- 核函数 (Kernel Function)：核函数是 SVR 处理非线性问题的关键。通过核技巧，SVR 可以将原始数据映射到更高维的特征空间，从而在新的空间中寻找线性回归函数。常用的核函数包括线性核、多项式核和高斯径向基函数（RBF）核。RBF 核因其良好的性能和普适性，在处理文本、图像混合特征的社交媒体数据中被广泛使用。

实证研究表明，通过合理的参数调优和特征工程，SVR 在预测社交媒体内容参与度方面能够取得优于传统线性模型的效果，特别是在中等规模数据集上表现稳定。

13.4 集成学习模型（Random Forest, XGBoost, LightGBM）

集成学习（Ensemble Learning）是一种通过构建并结合多个学习器来完成预测任务的机器学习方法。其核心思想是" 三个臭皮匠，顶个诸葛亮"，通过集成多个弱学习器的预测结果，可以获得一个比任何单个学习器都更强大、更稳健的强学习器。在小红书热度预测领域，集成学习模型因其出色的性能、对高维特征的鲁棒性以及可解释性而备受青睐。

随机森林（Random Forest）是一种基于 Bagging（Bootstrap Aggregating）思想的集成学习算法。它通过自助采样法（Bootstrap）从原始训练集中生成多个不同的子训练集，并在每个子训练集上独立地训练一棵决策树。在构建决策树的过程中，随机森林还引入了特征的随机选择，即每次分裂节点时，只从所有特征中随机选取一个子集来寻找最优分裂特征。这种双重随机性使得随机森林中的每棵树都具有差异性，从而降低了模型的方差，提高了泛化能力。随机森林对异常值和噪声不敏感，能够处理高维数据（如大量的 tag 特征、文本 TF-IDF 特征），并且可以评估特征的重要性，因此在理解哪些因素（如图片 vs 文本 vs 时间）对热度影响最大方面表现出色。

XGBoost（eXtreme Gradient Boosting）是一种基于 Boosting 思想的集成学习算法。与 Bagging 并行训练多个弱学习器不同，Boosting 采用串行的方式，每一轮迭代都根据前一轮模型的预测结果来调整样本权重，使得新的模型能够更关注于之前被错误预测的样本（如

那些" 本该热门却表现平平" 或" 意外爆红" 的帖子）。XGBoost 是梯度提升决策树（Gradient Boosting Decision Tree, GBDT）的一种高效实现，它在 GBDT 的基础上进行了多项优化，包括使用二阶泰勒展开来近似损失函数、引入正则化项来控制模型复杂度、以及采用并行计算来加速训练过程。XGBoost 以其卓越的预测性能、高效性和灵活性，在各种机器学习竞赛中屡获殊荣，也被广泛应用于社交媒体热度预测和广告效果评估中。

LightGBM（Light Gradient Boosting Machine）是另一种高效的梯度提升框架，采用基于直方图的决策树算法和叶子优先（Leaf-wise）的树生长策略，相比 XGBoost 在训练速度和内存效率上有显著优势，特别适合处理小红书这类大规模、高维度的社交媒体数据集。

13.4.1 树集成模型一：Random Forest

利用随机森林模型进行特征重要性分析，识别对观看量和点赞数影响最大的内容特征，为内容创作者提供可操作的优化建议。

13.4.2 树集成模型二：XGBoost/LightGBM

利用 XGBoost 和 LightGBM 构建高精度预测模型，通过网格搜索和贝叶斯优化进行超参数调优，捕捉特征间的复杂交互效应（如" 高颜值图片 + 晚间发布 + 情感化标题" 的组合效应）。

13.5 深度学习模型（LSTM, TextCNN, BERT）

深度学习模型，特别是循环神经网络（RNN）及其变体、卷积神经网络（CNN）以及预训练语言模型，在处理小红书多模态数据（文本 + 图像 + 时序）方面展现出强大的能力，因为它们能够自动从原始数据中学习复杂的模式和层次化的特征表示。

长短期记忆网络（Long Short-Term Memory, LSTM）是一种特殊的 RNN，专门设计用于解决传统 RNN 在处理长序列时面临的梯度消失和梯度爆炸问题。LSTM 通过引入一个精巧的门控机制（包括输入门、遗忘门和输出门）来控制信息流，使其能够有选择地记忆和遗忘信息，从而有效地捕捉时间序列中的长期依赖关系。在小红书热度预测中，LSTM 可以用于建模用户互动的时间动态，例如，基于发布后 1 小时、2 小时、6 小时的点赞/收藏序列，预测 24 小时后的最终热度。这种早期热度序列往往包含了内容质量的重要信号。

卷积神经网络（Convolutional Neural Network, CNN）在图像识别领域取得了巨大成功，其强大的局部特征提取能力也被成功应用于文本分析（TextCNN）。在小红书场景下，TextCNN 可以通过不同大小的卷积核捕捉标题和正文中的局部语义特征（如关键词组合、情感表达模式），有效识别" 爆款标题" 的文本模式。对于图像数据，可以使用预训练的 CNN（如 ResNet, VGG）提取视觉特征，评估图片质量、美学得分和内容相关性。

预训练语言模型（BERT, RoBERTa）通过大规模语料预训练，能够深度理解小红书文本内容的语义和上下文信息。利用 BERT 对标题和正文进行编码，可以获得高质量的文本表征，捕捉隐含的情感倾向、话题类别和写作风格，这些都是影响热度的重要因素。

此外，可以构建多模态融合模型（Multi-modal Fusion），将文本特征（BERT）、视觉特征（CNN）和结构化特征（元数据）在特征层或决策层进行融合，全面捕捉影响热度的多

维度因素。

13.5.1 时序深度学习模型：LSTM/GRU

构建基于早期互动序列（发布后前 N 小时的点赞、评论、分享数）的 LSTM 模型，实现热度的早期预测和趋势外推。

13.5.2 文本深度学习模型：BERT + TextCNN

利用 BERT 提取深层语义特征，结合 TextCNN 捕捉局部关键词模式，构建高精度的文本内容质量评估和热度预测模型。

13.6 其他模型

13.6.1 宽度学习系统（Broad Learning System, BLS）

宽度学习是一种新兴的平坦神经网络架构，通过随机生成特征节点和增强节点，利用伪逆快速计算输出权重，具有训练速度极快、结构灵活的特点。在小红书实时热度预测场景中，BLS 可以作为快速基准模型，支持模型的在线更新和增量学习。

13.6.2 生存分析模型（Survival Analysis）

考虑到部分小红书帖子可能长期持续获得流量（" 长尾内容"），而另一些则快速衰减，可以引入生存分析中的 Cox 比例风险模型或 AFT（Accelerated Failure Time）模型，不仅预测总热度，还预测热度的持续时间和衰减速度，为评估内容的长期价值提供依据。



14. 改进模型设计方案

在基准模型的基础上，我们将设计并实现一个或多个改进模型，以期在预测精度上取得突破。改进方向将主要集中在多模态数据融合、用户行为动态建模和上下文感知优化上。

14.1 模型架构设计

在基准模型的基础上，本研究将致力于提出改进模型，并探索如何将预测模型与内容创作策略进行有效融合，以期开发出具有更高传播效果的智能化内容优化系统。

改进模型方面，我们将从以下几个方向进行探索：

- 多模态深度融合：现有的多模态方法通常采用简单的特征拼接或浅层融合。我们将探索更先进的融合机制，如基于注意力机制的多模态融合（Attention-based Fusion）、跨模态 Transformer（Cross-modal Transformer），让模型自动学习文本、图像、时间、空间特征之间的复杂交互关系。例如，模型可以学习到" 美食类内容在晚间配合高饱和度图片效果更佳" 这样的隐性规则。
- 图神经网络（GNN）应用：构建用户-内容-标签的异构图网络，利用图神经网络捕捉社交关系、内容相似性和标签共现关系。通过消息传递机制，模型可以借鉴相似内容的历史表现，或利用用户的社交影响力来修正热度预测，解决冷启动问题。
- 多任务学习框架：不同于单一预测观看量或点赞数，我们将构建多任务学习模型，同时预测多个热度指标（观看量、点赞数、收藏数、评论数、分享数）。通过共享表征层，模型可以学习到不同互动行为之间的内在关联（如" 高收藏内容通常评论较少但转化率较高"），提高整体预测精度。
- 时序卷积网络（TCN）与 Transformer：引入 Temporal Convolutional Network 和 Transformer 架构替代 LSTM，利用其并行计算优势和长距离依赖捕捉能力，更有效地建模

热度传播的时间动态，特别是捕捉突发流量和病毒式传播模式。

- 因果推断集成：结合因果推断方法（如双重机器学习、倾向得分匹配），不仅预测相关性，还尝试识别因果关系，区分" 因为发布了某类内容所以热门" 和" 因为账号本身有影响力所以热门"，为内容策略提供更 robust 的建议。

策略融合方面，我们将探索如何将回归预测模型的输出直接转化为内容优化策略。例如：

- 实时发布决策支持：构建一个策略系统，当模型预测某篇草稿在特定时间、搭配特定标签发布能获得更高热度时，向创作者推荐最佳发布时机和标签组合。
- A/B 测试优化：利用预测模型进行虚拟 A/B 测试，在内容发布前预测不同标题、封面图版本的表现，辅助创作者选择最优方案。
- 动态流量分配：对于品牌方和 MCN 机构，预测模型可以用于评估不同 KOL 的内容投放效果，优化广告预算分配，识别潜在的高性价比投放对象。
- 内容冷启动策略：针对新账号或新内容，利用预测模型识别" 潜力内容"，建议平台给予初始流量扶持，提高优质内容的发现效率。

通过这种深度融合，我们期望能够开发出比传统内容运营更智能、更数据驱动的小红书营销优化系统，实现从" 经验驱动" 到" 算法驱动" 的转变。



15. 热度回归模型实证

15.1 任务定义与数据处理

为将前述方案落实为可复现实验，本章将笔记热度定义为连续互动量

$$y = \text{点赞数} + \text{收藏数} + 4 \times \text{评论数}. \tag{15.1}$$

评论被赋予较高权重，是因为其参与成本和互动深度通常高于点赞与收藏。该定义与分类模型部分保持一致，但不再把第 80 百分位以上样本离散化为高热度类别，而是直接预测连续数值。

实验读取三个业务数据压缩包中的笔记详情表，共得到 323,598 条原始记录。按笔记链接去重；无有效链接时，按编号、标题和博主组合去重，并剔除互动指标缺失或为负的记录，最终保留 199,473 条有效笔记。热度中位数为 346，均值为 3,298.21，第 80 百分位为 2,134，第 95 百分位为 12,755，最大值达到 1,711,417。均值约为中位数的 9.5 倍，最大值又远高于第 95 百分位，表明目标分布具有显著右偏和长尾特征。

输入沿用分类模型部分的 10 项发布前特征：粉丝量对数、标题长度、正文长度、标签数、感叹号数、问号数、Emoji 数、情感得分、星期和是否标注发布地。点赞、收藏和评论没有作为输入，从而避免目标泄漏。为控制不同模型的计算成本，本文按对数热度的十分位分层抽取 60,000 条样本，再以 8:2 划分训练集和测试集，得到 48,000 条训练样本和 12,000 条测试样本。缺失值填补及标准化参数均只在训练集拟合。

15.2 模型与评估指标

由于直接拟合原始热度会使少数极端爆款支配平方损失，本章令所有有效模型学习 $\log(1+y)$，预测后使用 $\exp(\hat{y})-1$ 还原并将负预测截断为 0。比较模型包括中位数基线、普通线性回归、Ridge 回归、随机森林、极端随机树（Extra Trees）和直方图梯度提升树。

评估同时覆盖绝对误差、相对误差和排序能力。MAE 与 RMSE 在原始互动量尺度计算；RMSLE 衡量对数量级的预测误差，降低极端值的支配；R^2 衡量模型对原始热度方差的解释比例；Spearman 相关系数衡量预测排序与真实排序的一致性。运营筛选能力使用 Top 20% 召回率衡量，即预测热度排名前 20% 的笔记覆盖了多少真实热度排名前 20% 的笔记。鉴于长尾分布，本研究以 RMSLE 作为主要误差指标，以 Spearman 和 Top 20% 召回率作为重要辅助指标，而不依据单一 RMSE 选型。

15.3 基准结果与模型比较

Table 15.1: 热度回归模型测试集结果

模型	MAE	RMSE	RMSLE	R^2	Spearman	Top 20% 召回
中位数基线	3,262.81	19,937.17	2.230	-0.023	–	0.194
线性回归	3,149.12	19,797.46	1.936	-0.009	0.463	0.407
Ridge	3,149.13	19,797.52	1.936	-0.009	0.463	0.407
随机森林	3,124.55	**19,666.20**	1.866	**0.004**	0.506	0.424
Extra Trees	3,125.54	19,698.07	1.862	0.001	0.509	**0.429**
梯度提升树	**3,119.22**	19,729.95	**1.849**	-0.002	**0.515**	**0.429**

表15.1显示，五个学习模型的 RMSLE 均优于中位数基线，说明发布前结构化特征包含稳定的热度信号。梯度提升树的 RMSLE 最低，为 1.849，相比中位数基线下降约 17.1%；其 Spearman 相关系数也最高，为 0.515，说明非线性模型对笔记相对热度具有中等强度的排序能力。该模型在严格取预测排名前 20% 时覆盖 42.9% 的真实高热笔记，显著高于无信息排序约 20% 的期望水平。Extra Trees 与梯度提升树的 Top 20% 召回率相同，RMSLE 略高；随机森林取得最低 RMSE 和唯一为正的 R^2，但其 RMSLE 和排序指标略逊于梯度提升树。

线性回归与 Ridge 的结果几乎相同，表明当前 10 项特征中的多重共线性并非线性模型的主要瓶颈；更关键的问题是特征与热度之间存在非线性关系和交互效应。树模型在 RMSLE、Spearman 和 Top 20% 召回率上均优于线性模型，支持这一判断。

15.4 可解释性、局限与应用建议

基于最佳梯度提升树的测试集排列重要性显示，粉丝量对数最重要，打乱该特征会使对数误差增加 2.620；星期、正文长度、情感得分和是否标注发布地的重要性均值分别为 0.154、0.136、0.136 和 0.105。标签数、标题长度、Emoji 数和感叹号数提供较弱的补充信息，问号数的重要性接近 0。该结果说明发布者已有影响力仍是热度预测的首要信号，但内容表达、发布时间和位置元数据共同提供了可利用的增量信息。排列重要性反映预测贡献而非因果效应，不能据此断言增加正文长度或选择某一星期发布必然提高热度。

需要审慎解释接近 0 的原始尺度 R^2。虽然最佳模型显著改善了 RMSLE 与排序能力，

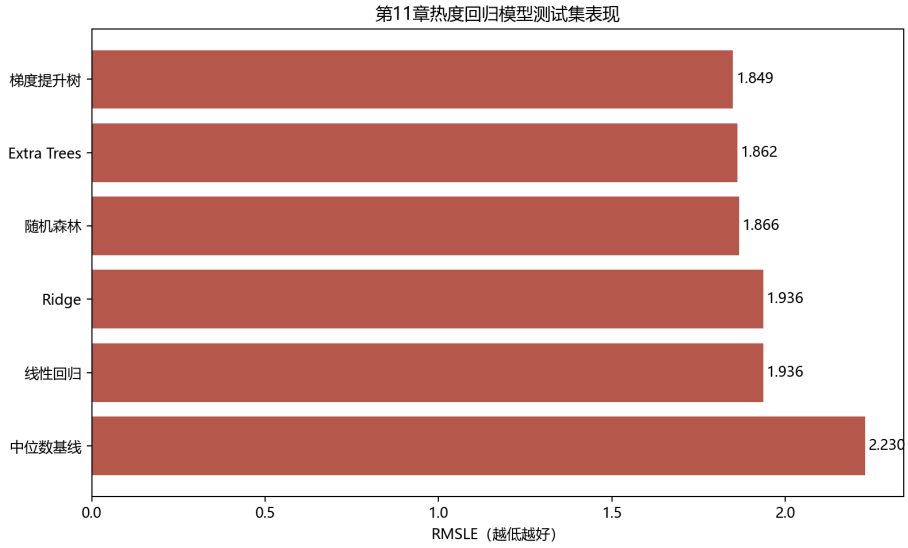


Figure 15.1: 不同热度回归模型的 RMSLE 比较

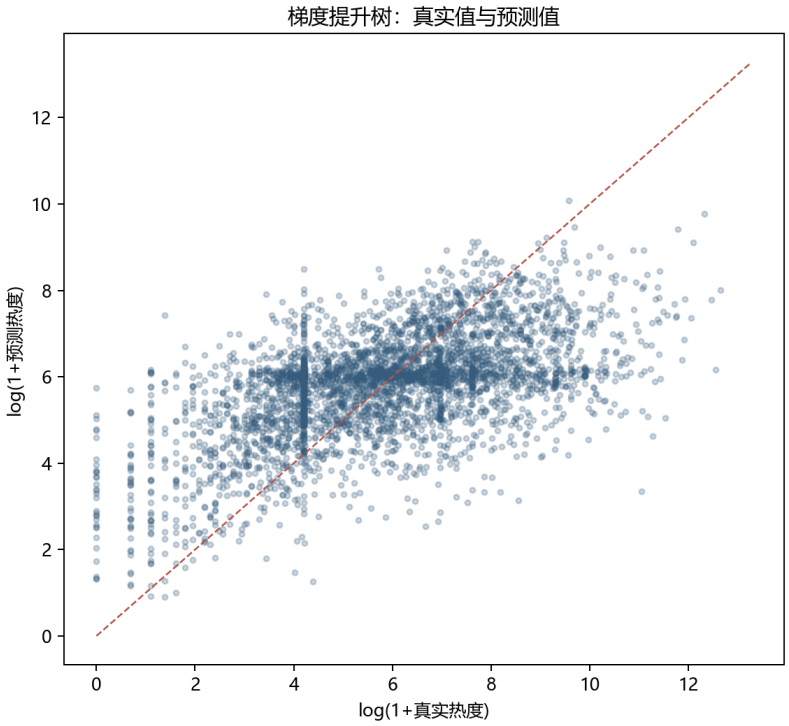


Figure 15.2: 梯度提升树在对数尺度上的真实热度与预测热度

但仍无法解释极端爆款造成的大部分原始方差。平台临时流量分配、突发热点、站外传播和早期互动速度没有包含在现有发布前特征中，而这些因素可能决定最极端的传播结果。因此，本模型适合用于发布前的相对热度排序、候选内容筛选和资源粗分配，不适合把单条笔记的点预测视为确定性承诺。

后续应按发布时间建立训练、验证和测试窗口，并按博主分组检查跨集合泄漏；在获得稳定配对的原始图片、完整文本语义表示和发布者历史序列后，再比较 BERT、视觉编码器及多模态融合模型。若目标转为发布后的早期预测，则可加入前 1 小时、2 小时和 6 小时互动序列，并使用 LSTM 或时序 Transformer，但必须明确区分“发布前潜力预测”和“发布后趋势外推”两种业务任务。综合本轮结果，推荐使用梯度提升树进行发布前排序，并在验证集按候选名额选择 Top-K；对极端爆款的绝对量预测则应输出区间或分位数，而不是单一点估计。

VI

Part VI: 统一实验总结

16 统一实验设置 81

16.1 数据口径与任务划分

16.2 评价原则与复现材料

17 分类与回归结果的统一比较 83

17.1 分类任务：排序、覆盖与误报的权衡

17.2 回归任务：相对排序优于绝对量预测

17.3 跨任务一致的特征信号

18 有效性边界与后续验证 85

18.1 本轮实际完成范围

18.2 内部与外部有效性限制

18.3 下一轮验证顺序



16. 统一实验设置

16.1 数据口径与任务划分

本研究的实证部分使用相同的数据清洗规则和发布前特征完成分类与回归两项任务。三个业务数据压缩包共提供 323,598 条原始记录；按笔记链接去重，在链接缺失时按编号、标题和博主组合去重，并剔除互动指标缺失或为负的记录后，得到 199,473 条有效笔记。两项任务均从有效样本中分层抽取 60,000 条记录，并使用固定随机种子划分 48,000 条训练样本和 12,000 条测试样本。

统一热度指标定义为

$$y = \text{点赞数} + \text{收藏数} + 4 \times \text{评论数}. \tag{16.1}$$

分类任务将全体有效样本中热度达到第 80 百分位（2,134）的笔记记为高热度，正类比例为 20.01%；回归任务直接预测连续热度，并在训练时对目标使用 $\log(1+y)$ 变换，以减弱极端长尾样本对平方损失的支配。

输入统一为 10 项发布前可获得的结构化特征：粉丝量对数、标题长度、正文长度、标签数、感叹号数、问号数、Emoji 数、情感得分、星期和是否标注发布地。点赞、收藏、评论及其派生量均未进入输入特征，从而避免将目标本身泄漏给模型。缺失值填补和标准化参数只在训练集上拟合。

16.2 评价原则与复现材料

分类任务以 PR-AUC 为主要排序指标，并同时报告 ROC-AUC、精确率、召回率和 F1。回归任务以 RMSLE 为主要误差指标，并辅以 MAE、RMSE、R^2、Spearman 相关系数和 Top 20% 召回率。选择这些指标的原因是，分类正类只占约 20%，而连续热度具有明显右偏和长尾；在这两种情况下，仅依据准确率或原始尺度 RMSE 都可能给出片面的结论。

第 10 章 Notebook 记录了分类模型的数据审计、测试集指标、分类报告和随机森林特征重要性；热度回归 Notebook 记录了对应的数据审计、模型指标、排列重要性以及最佳模型逐条预测。实验表格均由这些机器可读输出整理，不使用没有代码和结果文件支持的多模态、消融或统计显著性数值。



17. 分类与回归结果的统一比较

17.1 分类任务：排序、覆盖与误报的权衡

分类实验表明，梯度提升树的 PR-AUC 和 ROC-AUC 分别为 0.440 和 0.736，均为五个模型中的最高值，适合作为候选笔记排序模型。随机森林与多层感知机的 PR-AUC 分别为 0.424 和 0.423，说明在当前 10 项表格型特征上，增加神经网络复杂度没有带来优于树模型的泛化效果。

固定 0.5 阈值下，不同模型呈现明显的业务取舍。梯度提升树的精确率最高，为 0.600，但召回率只有 0.169；线性 SVM 的召回率最高，为 0.651，但精确率为 0.302。逻辑回归取得最高 F1（0.414）。因此，有限名额的精准推荐更适合使用梯度提升树或 Top-K 排序，广覆盖初筛更适合使用类别加权的线性模型。表10.1和表12.1给出了完整指标与混淆矩阵。

17.2 回归任务：相对排序优于绝对量预测

回归实验中，梯度提升树取得最低 RMSLE（1.849）和最高 Spearman 相关系数（0.515），其 Top 20% 召回率为 0.429；Extra Trees 取得相同的 Top 20% 召回率，RMSLE 略高，为 1.862。随机森林取得最低 RMSE 和唯一为正的 R^2，但 R^2 也只有 0.004。完整结果见表15.1。

这些结果说明，结构化发布前特征能够有效改善热度数量级判断和相对排序，却无法解释极端爆款造成的大部分原始方差。模型的合理用途是候选内容排序和资源粗分配，而不是对单篇笔记给出确定性的互动量承诺。若业务必须给出绝对量，应进一步采用分位数回归或预测区间，并报告区间覆盖率。

17.3 跨任务一致的特征信号

分类随机森林的重要性和回归梯度提升树的排列重要性都将粉丝量对数列为首要特征。正文长度、标题长度、情感得分、星期和位置标记在两项任务中提供了不同程度的补充信息。这种跨任务一致性说明，发布者既有影响力是当前数据中最稳定的预测信号，内容表达与发布时间则贡献增量信息。

需要强调的是，特征重要性衡量预测贡献而非因果效应。粉丝量较高与热度较高同时出现，不等于单纯增加粉丝数就会以相同比例提高某一篇笔记的互动；正文长度、情感和星期等变量也可能与账号类型、内容主题及平台流量机制共同变化。因此，本研究的结果适合支持风险可控的候选排序，不应被解释为确定性的运营因果规则。



18. 有效性边界与后续验证

18.1 本轮实际完成范围

本轮实证已经完成结构化特征上的五个分类模型和五个学习型回归模型，并提供可执行 Notebook 与机器可读结果。CNN、RNN/LSTM、BERT、图网络、多模态融合、多任务学习和消融实验没有纳入数值比较。现有数据缺少与每条笔记稳定对应的原始图片张量、严格按时间排列的发布者历史序列和用户---笔记传播边；在这些条件不满足时构造伪图像、伪序列或伪传播图，会引入缺乏业务含义的结构并削弱结论可信度。

因此，本报告将深度文本、视觉和传播模型保留为后续研究方案，而不宣称其已经取得性能提升。只有在补齐输入数据、固定训练与测试口径并保存完整实验输出后，才能将这些模型加入与当前基准的公平比较。

18.2 内部与外部有效性限制

当前实验采用分层随机划分，适合在固定样本分布上比较算法，但不能替代面向未来内容的时间外验证。同一博主可能同时出现在训练集和测试集，模型也可能部分利用稳定的账号风格与粉丝基础。因此，现有指标应理解为同分布基准性能，而不是上线后的无偏性能估计。

数据还缺少平台曝光量、推荐流量、站外传播、热点生命周期和发布后早期互动速度。它们可能决定极端爆款，却无法从当前 10 项发布前特征中恢复。样本主要来自美妆和家电领域，结论能否迁移到旅行、教育或本地生活等领域也仍需独立验证。

18.3 下一轮验证顺序

后续工作应首先按发布时间建立训练、验证和测试窗口，并按博主分组检查跨集合泄漏；随后在验证集完成阈值选择和概率校准，再锁定流程并只在测试集评估一次。完成这些基础验证后，才应依次加入文本语义、图片和发布者历史特征。每次扩展都应与相同数据切分下的结构化基准比较，并通过消融实验确认新增信息的独立贡献。

在当前证据范围内，推荐的应用流程是“梯度提升排序、验证集选择阈值或 Top-K、按业务成本输出候选、定期进行时间外复核”。这一流程与现有数据能力相匹配，也为未来更复杂的多模态模型提供了可复现基线。

VII

Part VII: 结论与展望

19 研究结论 89
19.1 主要发现
19.2 实践含义

20 研究局限与未来工作 91
20.1 研究局限
20.2 未来工作
20.3 总结



19. 研究结论

19.1 主要发现

本研究围绕小红书笔记热度的影响因素与发布前预测展开分析，形成了从数据清洗、探索性分析、特征构造到分类和回归建模的完整流程。三个业务数据压缩包共包含 323,598 条原始记录，经统一去重和有效性检查后保留 199,473 条笔记。研究使用“点赞数 + 收藏数 +4× 评论数”衡量互动热度，并以 10 项不包含发布后互动的结构化特征完成两类预测任务。

探索性分析与模型结果共同表明，发布者粉丝基础是最稳定的热度信号；内容长度、情感表达、标签、发布时间和位置元数据提供了较弱但可利用的增量信息。部分变量与热度之间存在非线性关系，因此树模型整体上比线性模型具有更好的排序能力。不过，这些关系来自观察数据，只能解释为统计关联和预测信号，不能直接推断为因果效应。

分类任务中，梯度提升树取得最高 PR-AUC（0.440）和 ROC-AUC（0.736），适合对潜在高热度笔记排序；线性 SVM 取得最高召回率（0.651），适合低成本的广覆盖初筛；逻辑回归取得最高默认阈值 F1（0.414），可作为易解释基准。回归任务中，梯度提升树取得最低 RMSLE（1.849）、最高 Spearman 相关系数（0.515）和 0.429 的 Top 20% 召回率。接近 0 的原始尺度 R^2 同时说明，当前模型能够改善相对排序，却难以准确预测极端爆款的绝对互动量。

19.2 实践含义

在现有证据范围内，模型更适合充当内容决策的辅助排序工具，而不是自动化承诺工具。对于候选名额有限的运营场景，可使用梯度提升树按预测分数输出 Top-K；对于不希望漏掉潜在爆款的初筛场景，可使用类别加权的线性模型，并由人工或第二阶段模型处理较

多的假阳性。任何阈值都应在独立验证集上根据误报与漏报成本确定，不能机械采用 0.5。

特征重要性可帮助识别值得进一步分析的方向，但不应被转写为“增加正文长度必然提高热度”等确定性建议。更稳妥的做法是将模型发现用于提出运营假设，再通过随机实验、准实验或严格的时间外回测验证其效果。



20. 研究局限与未来工作

20.1 研究局限

第一，当前基准采用分层随机划分，尚未完成按发布时间的外推测试，也未完全排除同一博主跨训练集和测试集带来的账号信息复用。第二，输入主要是文本表层和账号结构化特征，没有稳定配对的图片、完整文本语义、曝光量、传播网络与早期互动序列。第三，样本集中于美妆和家电领域，跨领域泛化能力尚未验证。第四，互动热度是研究构造指标，评论权重取 4 具有业务解释，但仍需通过敏感性分析检验不同权重下结论是否稳定。

此外，极端爆款受到平台临时流量、突发热点和站外传播影响，这些信息在当前数据中不可观测。因而，模型对数量级和排序的改善不能消除社交媒体传播本身的高度不确定性。

20.2 未来工作

近期工作应优先完成时间外划分、按博主分组验证、阈值优化与概率校准，并报告跨时间窗口和跨领域的性能变化。对于回归任务，可进一步比较分位数回归、Tweedie 损失或两阶段模型，为长尾热度提供区间预测。

在数据条件允许后，可使用中文预训练语言模型提取标题与正文语义，使用视觉编码器提取封面和配图特征，并在稳定笔记标识下进行晚期融合。若能够获得严格按时间排序的发布者历史和用户---笔记交互边，可进一步研究时序模型与图网络。所有新增模型都应在相同的数据切分和无泄漏约束下与当前结构化基准比较，并保留可执行 Notebook、环境说明和机器可读结果。

20.3 总结

本研究证明，有限的发布前结构化特征已经能够为小红书笔记热度提供优于随机基线的排序信息，但对极端传播结果的解释能力仍然有限。相比追求未经验证的复杂模型，更可靠的路径是先建立可复现基准、明确使用边界，再通过时间外验证和新增模态逐步扩展。由此形成的研究框架既能够支持当前的内容筛选任务，也为后续多模态和动态传播研究保留了清晰接口。